



دانشگاه صنعتی شریف
دانشکده مهندسی کامپیوتر

پایان نامه کارشناسی ارشد
مهندسی کامپیوتر گرایش هوش مصنوعی و رباتیک

مدیریت فراموشی در یادگیری پیوسته با کمک روش های یادگیری ژرف

نگارش

فاطمه رائیجیان

استاد راهنما

دکتر حمید بیگی

شهریور ۱۴۰۵



به نام خدا
دانشگاه صنعتی شریف
دانشکده مهندسی کامپیوتر

پایان نامه کارشناسی ارشد

این پایان نامه به عنوان تحقق بخشی از شرایط دریافت درجه کارشناسی ارشد است.

عنوان: مدیریت فراموشی در یادگیری پیوسته با کمک روش های یادگیری ژرف

نگارش: فاطمه رائیجیان

کمیته ممتحنین

امضاء: استاد راهنما: دکتر حمید بیگی

امضاء: استاد ممتحن داخلی:

امضاء: استاد ممتحن خارجی:

تاریخ:



اظهارنامه

(اصالت متن و محتوای پایان نامه کارشناسی ارشد)

عنوان پایان نامه: مدیریت فراموشی در یادگیری پیوسته با کمک روش های یادگیری ژرف

استاد راهنما: دکتر حمید بیگی

این جانب فاطمه رائجیان اظهار می دارم:

۱. متن و نتایج علمی ارائه شده در این پایان نامه اصیل بوده و زیر نظر استادان نام برده شده در بالا تهیه شده است.
۲. متن پایان نامه به این صورت در هیچ جای دیگری منتشر نشده است.
۳. متن و نتایج مندرج در این پایان نامه، حاصل تحقیقات این جانب به عنوان دانشجوی کارشناسی ارشد دانشگاه صنعتی شریف است.
۴. کلیه مطالبی که از منابع دیگر در این پایان نامه مورد استفاده قرار گرفته، با ذکر مرجع مشخص شده است.

نگارنده: فاطمه رائجیان

تاریخ:

امضاء:

نتایج تحقیقات مندرج در این پایان نامه و دستاوردهای مادی و معنوی ناشی از آن (شامل فرمول ها، توابع کتابخانه ای، نرم افزارها، سخت افزارها و مواردی که قابلیت ثبت اختراع دارد) متعلق به دانشگاه صنعتی شریف است. هیچ شخصیت حقیقی یا حقوقی بدون کسب اجازه از دانشگاه صنعتی شریف حق فروش و ادعای مالکیت مادی یا معنوی بر آن یا ثبت اختراع از آن را ندارد. همچنین، کلیه حقوق مربوط به چاپ، تکثیر، نسخه برداری، ترجمه، اقتباس و موارد مشابه در محیط های مختلف اعم از الکترونیکی، مجازی یا فیزیکی برای دانشگاه صنعتی شریف محفوظ است. نقل مطلب با ذکر ماخذ بلامانع است.

نگارنده: فاطمه رائجیان

تاریخ:

امضاء:

استاد راهنما: دکتر حمید بیگی

تاریخ:

امضاء:

سپاس‌گزاری

سپاسگزارم از استاد راهنمای گرامی، جناب آقای دکتر حمید بیگی، برای راهنمایی‌های علمی، دقت نظر و حمایت مستمر در مسیر انجام این پژوهش. همچنین از خانواده‌ی عزیزم برای همراهی، صبوری و پشتیبانی بی‌دریغشان در تمام مراحل تحصیل و نگارش این پایان‌نامه قدردانی می‌کنم.

چکیده

سامانه‌های یادگیری پیوسته^۱ پس از استقرار نیز باید بتوانند درخواست حذف دانش را اجرا کنند. در یادگیری افزایشی وظیفه^۲، شناسه‌ی وظیفه هنگام پیش‌بینی در دسترس است. در این چارچوب، فراموشی انتخابی^۳ باید رفتار مدل روی یک وظیفه را سرکوب کند، بی‌آنکه عملکرد آن روی وظیفه‌های دیگر افت محسوسی داشته باشد. دشواری اصلی از هم‌پوشانی پیراسنجه‌ها^۴ سرچشمه می‌گیرد؛ زیرا یک وزن ممکن است در چند وظیفه نقش داشته باشد و تغییر آن به همه‌ی آن وظیفه‌ها آسیب بزند. چارچوب PALL دانش وظیفه‌ها را در زیرشبکه‌های جداگانه سازمان می‌دهد، اما تفاوت اهمیت وزن‌های مشترک برای وظیفه‌های نگه‌داری شده را در نظر نمی‌گیرد.

این پایان‌نامه نسخه‌ی توسعه‌یافته‌ی PALL را با نام EPALL معرفی می‌کند. این روش وزن‌های مشترک میان زیرشبکه‌ی هدف و زیرشبکه‌های فعال را بر پایه‌ی بزرگی شیب زیان وظیفه‌های نگه‌داری شده رتبه‌بندی می‌کند. سپس مهم‌ترین وزن‌ها را هنگام ترمیم، با یک جمله‌ی لنگر^۵ ℓ_2 نزدیک به مقدار پیش از حذف نگه می‌دارد. مسیر PALL-Adapter که از لایه‌های تطبیق کم‌پیراسنجه استفاده می‌کند نیز به‌عنوان گزینه‌ای اکتشافی بررسی می‌شود.

در مقایسه‌ی یازده روش با هشت بذر روی Split-CIFAR، EPALL دقت وظیفه‌ی فراموش شده را به سطح حدس تصادفی می‌رساند (۰/۴۸۶۳ و ۰/۰۹۵۹) و دقت وظیفه‌های نگه‌داری شده را نزدیک به CLPU حفظ می‌کند. با این حال، CLPU به ۱/۶ تا ۲/۲ برابر حافظه‌ی بیشتر نیاز دارد. اختلاف جفتی دقت EPALL و PALL روی هر دو مجموعه داده، پس از اصلاح هولم برای شش آزمون هم‌زمان، معنادار است ($p = ۰/۰۴۶۹$). بیشترین افت دقت روی CIFAR-100 از ۰/۰۲۲۲ به ۰/۰۰۵۶ کاهش می‌یابد؛ اما این کاهش روی CIFAR-10 پس از همان اصلاح از نظر آماری معنادار نیست. در یک آزمون گسترده شامل ۳۰۰ اجرا، بیشترین افت PALL با دیرتر شدن درخواست افزایش می‌یابد، در حالی که این مقدار برای EPALL تقریباً ثابت می‌ماند. در بررسی تنگی نیز میزان بهبود با هم‌پوشانی اندازه‌گیری شده، همبستگی رتبه‌ای مثبت و معناداری دارد.

بررسی جداگانه‌ی اجزای روش نشان می‌دهد که رتبه‌بندی وزن‌ها بر پایه‌ی حساسیت، با بودجه‌ی ثابت، مؤلفه‌ی مؤثر EPALL است. در مسیر PALL-Adapter نیز نتایج نشان می‌دهند که سرکوب وظیفه‌ی هدف از بازنشانی لایه‌ی تطبیق مخصوص همان وظیفه ناشی می‌شود، نه از نقاب نرم^۶. ارزیابی حمله‌ی استنتاج عضویت^۷ نشان می‌دهد که پس از درخواست حذف، تشخیص عضو بودن نمونه‌های هدف برای EPALL آسان‌تر می‌شود، اما PALL اصلی چنین تغییری ندارد. هیچ‌یک از این نتایج، حذف دقیق یا گواهی شده را اثبات نمی‌کند.

کلیدواژه‌ها: یادگیری پیوسته، یادگیری‌زدایی ماشینی، فراموشی انتخابی، هم‌پوشانی پیراسنجه‌ها

¹Continual Learning

²Task-Incremental Learning

³Selective Forgetting

⁴Parameter Overlap

⁵Anchor

⁶Soft Mask

⁷Membership Inference Attack (MIA)

فهرست مطالب

۱	مقدمه	۱
۱	۱-۱ زمینه و انگیزه	۱
۳	۲-۱ تعریف مسئله	۳
۳	۳-۱ چالش اصلی: هم‌پوشانی پیراسنجه‌ها	۳
۴	۴-۱ پرسش‌های پژوهش	۴
۵	۵-۱ حدود و دامنه‌ی ادعاها	۵
۶	۶-۱ مشارکت‌های پژوهش	۶
۷	۷-۱ معیارهای موفقیت	۷
۸	۸-۱ ساختار پایان‌نامه	۸
۹	۲ مفاهیم پایه و مرور کارهای پیشین	۹
۹	۱-۲ مفاهیم پایه	۹
۹	۱-۱-۲ یادگیری بانظارت و بهینه‌سازی مبتنی بر شیب	۹
۱۰	۲-۱-۲ سنجه‌های اهمیت پیراسنجه	۱۰
۱۰	۳-۱-۲ معماری‌های استفاده‌شده	۱۰
۱۱	۴-۱-۲ حافظه‌ی محدود و بازپخش	۱۱
۱۱	۲-۲ یادگیری پیوسته	۱۱
۱۱	۱-۲-۲ سه حالت یادگیری	۱۱

۱۲	۲-۲-۲ روش‌های مبتنی بر تنظیم
۱۳	۳-۲-۲ روش‌های مبتنی بر بازیخش
۱۴	۴-۲-۲ تصویر شیب
۱۴	۵-۲-۲ جداسازی پیراسنجه و زیرشبکه‌های تنک
۱۵	۳-۲ یادگیری‌زدایی ماشینی
۱۵	۱-۳-۲ فراموشی دقیق و بازآموزی
۱۶	۲-۳-۲ فراموشی تقریبی
۱۶	۳-۳-۲ تضمین‌های صوری و مرزهای آن
۱۷	۴-۳-۲ یادگیری‌زدایی در بستر یادگیری پیوسته
۱۸	۴-۲ یادگیری کم‌پیراسنجه
۱۹	۵-۲ ارزیابی فراموشی و حریم خصوصی
۱۹	۱-۵-۲ معیارهای رفتاری
۱۹	۲-۵-۲ حمله‌ی استنتاج عضویت
۲۰	۳-۵-۲ مرجع بازآموزی و ارزیابی رسمی
۲۰	۶-۲ مقایسه‌ی مفهومی و جایگاه این پژوهش

۳ روش پیشنهادی ۲۳

۲۳	۱-۳ صورت‌بندی مسئله
۲۳	۱-۱-۳ نمادگذاری
۲۴	۲-۱-۳ هدف مسئله
۲۴	۳-۱-۳ سازوکار اثری PALL
۲۵	۲-۳ محدودیت فراموشی بی‌قید
۲۵	۳-۳ روش پیشنهادی EPALL
۲۶	۱-۳-۳ هم‌پوشانی ساختاری
۲۷	۲-۳-۳ رتبه‌بندی حساسیت و انتخاب بودجه

۲۷	۳-۳-۳	ترمیم لنگردار
۲۸	۴-۳-۳	الگوریتم کامل
۳۰	۵-۳-۳	کنترل‌های مؤلفه‌ای
۳۰	۶-۳-۳	تحلیل پیچیدگی
۳۱	۴-۳	مسیر اکتشافی PALL-Adapter
۳۱	۱-۴-۳	معماری
۳۲	۲-۴-۳	فراموشی سه مرحله‌ای
۳۳	۳-۴-۳	دامنه‌ی واقعی نقاب نرم
۳۴	۵-۳	تحلیل نظری با دامنه‌ی محدود
۳۴	۱-۵-۳	نمادگذاری و افراز
۳۴	۲-۵-۳	فرض‌ها
۳۵	۳-۵-۳	کران بالای افت زیرمرحله و یکنوایی آن نسبت به p
۳۸	۴-۵-۳	چرا این کران، افت آغاز تا پایان را کران نمی‌زند
۳۸	۶-۳	ضوابط دسترسی به داده
۳۹	۷-۳	دیدگاه یکپارچه و جمع‌بندی فصل

۴ آزمایش‌ها و نتایج

۴۰	۱-۴	طراحی آزمایش
۴۰	۱-۱-۴	مجموعه داده‌های ارزیابی و تقسیم وظیفه‌ها
۴۱	۲-۱-۴	سه طرح آزمایشی مجزا
۴۱	۳-۱-۴	معماری‌ها و ابرپیراسنجه‌ها
۴۲	۴-۱-۴	بذرها و سخت‌افزار
۴۲	۲-۴	معیارهای ارزیابی
۴۳	۳-۴	مقایسه‌ی اصلی استاندارد
۴۵	۱-۳-۴	تفسیر نتایج اصلی

۵۰	۲-۳-۴ تحلیل جفتی و آزمون معناداری
۵۲	۴-۴ آزمون موقعیت درخواست
۵۵	۵-۴ بررسی تنکی و هم پوشانی اندازه گیری شده
۵۷	۶-۴ انتساب سازوکار EPALL
۶۰	۷-۴ وضعیت آزمایشی پیش آموزش دیده ی PEFT
۶۱	۸-۴ انتساب مؤلفه های PALL-Adapter: یک نتیجه ی منفی
۶۳	۱-۸-۴ نقاب نرم پیوسته: بررسی شدت
۶۵	۹-۴ نسخه های PALL زیر طرح آزمایشی هم پوشانی سنگین
۶۷	۱۰-۴ هزینه: دامنه ی ترمیم و حافظه ی مورد نیاز
۶۷	۱-۱۰-۴ نسبت اسمی دامنه ی ترمیم
۶۸	۲-۱۰-۴ محاسبه ی حافظه ی مورد نیاز
۶۸	۱۱-۴ ارزیابی حریم خصوصی و ماندگاری
۶۸	۱-۱۱-۴ حمله ی استنتاج عضویت اصلاح شده
۷۰	۲-۱۱-۴ آماره ی تفکیک پذیری حمله ی آستانه
۷۲	۳-۱۱-۴ نسبت هنجار شیب
۷۳	۴-۱۱-۴ مرجع بازآموزی هم روش
۷۳	۵-۱۱-۴ ماندگاری سرکوب
۷۶	۱۲-۴ مطالعات حساسیت
۷۶	۱-۱۲-۴ انتخاب لنگر
۷۷	۲-۱۲-۴ معیار اهمیت: بزرگی شیب در برابر انرژی تعارض
۷۸	۳-۱۲-۴ انتقال میان معماری با ViT
۷۹	۴-۱۲-۴ عرض گلوگاه لایه ی تطبیق
۸۱	۱۳-۴ تهدیدهای اعتبار
۸۲	۱۴-۴ جمع بندی یافته ها

۸۳	۵ جمع‌بندی و کارهای آینده
۸۳	۵-۱ خلاصه‌ی کار انجام‌شده
۸۴	۵-۲ پاسخ به پرسش‌های پژوهش
۸۵	۵-۳ مشارکت‌های نهایی
۸۶	۵-۴ محدودیت‌ها
۸۸	۵-۵ کارهای آینده
۸۹	۵-۶ سخن پایانی
۹۱	مراجع
۹۹	واژه‌نامه
۱۰۲	پیوست

فهرست جداول

۲۱	۱-۲ مقایسه‌ی مفهومی روش‌های مرتبط
۴۴	۱-۴ مقایسه‌ی هم‌تراز روی Split-CIFAR-10
۴۵	۲-۴ مقایسه‌ی هم‌تراز روی Split-CIFAR-100
۵۰	۳-۴ اختلاف‌های جفتی EPALL و PALL اصلی
۵۱	۴-۴ آزمون‌های دقیق معناداری جفتی با اصلاح Holm
۵۳	۵-۴ بیشترین افت در پنج درجه‌ی موقعیت درخواست
۵۵	۶-۴ رگرسیون‌های تجمیعی روی هم‌پوشانی اندازه‌گیری‌شده
۵۶	۷-۴ بررسی تنکی و هم‌پوشانی اندازه‌گیری‌شده
۵۸	۸-۴ کنترل‌های مستقیم سازوکار EPALL
۵۸	۹-۴ اختلاف‌های جفتی کنترل‌های EPALL
۶۰	۱۰-۴ وضعیت آزمایشی پیش‌آموزش دیده‌ی PEFT
۶۲	۱۱-۴ کنترل‌های مؤلفه‌ای PALL-Adapter
۶۴	۱۲-۴ بررسی شدت نقاب نرم پیوسته
۶۶	۱۳-۴ نسخه‌های PALL زیر طرح آزمایشی هم‌پوشانی سنگین
۶۸	۱۴-۴ محاسبه‌ی حافظه‌ی موردنیاز
۶۹	۱۵-۴ حمله‌ی استنتاج عضویت با پیش‌پردازش هم‌تراز
۷۱	۱۶-۴ آماره‌ی تفکیک‌پذیری حمله‌ی آستانه
۷۲	۱۷-۴ نسبت هنجار شیب فراموشی به نگهداری

۷۳	۱۸-۴ ارزیابی مرجع بازآموزی هم‌روش
۷۴	۱۹-۴ ارزیابی ماندگاری سرکوب وظیفه‌ی فراموش شده
۷۶	۲۰-۴ مطالعه‌ی انتخاب لنگر روی هشت بذر
۷۸	۲۱-۴ مطالعه‌ی معیار اهمیت
۷۸	۲۲-۴ انتقال میان معماری روی بدنه‌ی ViT-T/8
۷۹	۲۳-۴ بررسی عرض گلوگاه لایه‌ی تطبیق
۱۰۲	۱-۵ پیکربندی کامل آزمایش‌ها

فهرست تصاویر

۱-۱	چرخه‌ی عملیاتی فراموشی انتخابی	۲
۲-۱	شهود هم‌پوشانی پیراسنجه‌ها	۴
۱-۲	رده‌بندی مفهومی روش‌های مرتبط	۲۱
۱-۳	سازوکار EPALL	۲۶
۲-۳	معماری PALL-Adapter	۳۲
۳-۳	یکنوایی کران بالای افت زیرمرحله نسبت به شدت محافظت	۳۷
۱-۴	دقت نهایی به تفکیک مجموعه‌داده و وضعیت آزمایشی	۴۷
۲-۴	بیشترین افت به تفکیک مجموعه‌داده و وضعیت آزمایشی	۴۸
۳-۴	دقت وظیفه‌ی حذف‌شده به تفکیک مجموعه‌داده و وضعیت آزمایشی	۴۹
۴-۴	پاسخ بیشترین افت به موقعیت درخواست	۵۴
۵-۴	موازنه‌ی دامنه‌ی ترمیم و کیفیت	۶۷
۶-۴	ترکیب حافظه‌ی موردنیاز	۶۹
۷-۴	AUC حمله‌ی عضویت پیش و پس از درخواست	۷۰
۸-۴	مسیر فاصله تا شانس وظیفه‌ی فراموش‌شده پس از حذف	۷۵
۹-۴	بررسی عرض گلوگاه لایه‌های تطبیق	۸۰
۱۰-۴	نقشه‌ی حرارتی دقت یک اجرای نماینده	۸۰

فصل ۱

مقدمه

۱-۱ زمینه و انگیزه

شبکه‌های عصبی عمیق در دو دهه‌ی گذشته به ابزار اصلی یادگیری بازنمایی از داده‌های ادراکی تبدیل شده‌اند [۱، ۲]. با این حال، آموزش متعارف این شبکه‌ها بر یک فرض ساده استوار است: کل مجموعه داده از ابتدا در دسترس است، نمونه‌ها به‌طور تصادفی مرتب می‌شوند و مدل چند بار روی همین توزیع ثابت آموزش می‌بیند. سامانه‌های واقعی معمولاً در چنین شرایطی کار نمی‌کنند. داده‌ها به‌صورت جریانی می‌رسند، مفاهیم تازه پس از استقرار مدل ظاهر می‌شوند و آموزش دوباره‌ی مدل از ابتدا پس از هر تغییر، از نظر محاسباتی و اقتصادی به‌صرفه نیست.

یادگیری پیوسته^۱ یا یادگیری مادام‌العمر^۲ پاسخی پژوهشی به این وضعیت است. در این رویکرد، مدل باید دنباله‌ای از وظیفه‌ها را یکی پس از دیگری بیاموزد و دانش پیشین را از دست ندهد [۳، ۴، ۵]. دشواری اصلی این حوزه فراموشی فاجعه‌بار^۳ است. به‌روزرسانی‌های مبتنی بر شیب برای وظیفه‌ی جدید، همان پیراسنجه‌هایی را تغییر می‌دهند که وظیفه‌های پیشین به آن‌ها وابسته‌اند؛ در نتیجه، عملکرد مدل روی وظیفه‌های قدیمی به‌سرعت افت می‌کند [۶، ۷]. بخش عمده‌ی پژوهش‌های یادگیری پیوسته به این پرسش می‌پردازند که چگونه می‌توان دانش انباشته را در برابر به‌روزرسانی‌های آینده حفظ کرد.

هم‌زمان، فشارهای حقوقی و اجتماعی نیازی متفاوت را مطرح کرده‌اند. مقررات حفاظت از داده، مانند مقررات عمومی حفاظت از داده‌ی اتحادیه‌ی اروپا^۴ [۸] و قانون حریم خصوصی مصرف‌کننده‌ی کالیفرنیا^۵

¹Continual Learning

²Lifelong Learning


³Catastrophic Forgetting

⁴General Data Protection Regulation (GDPR)

⁵California Consumer Privacy Act (CCPA)

[۹]، حق فراموش شدن^۶ را برای افراد به رسمیت می‌شناسند. اگر داده‌های یک فرد یا یک دامنه‌ی مشخص باید از سامانه حذف شوند، حذف رکوردها از پایگاه داده کافی نیست. مدلی که با آن داده‌ها آموزش دیده است، ممکن است همچنان اثر آن‌ها را در وزن‌های خود نگه دارد و این اثر در حمله‌های استنتاجی آشکار شود [۱۰، ۱۱]. یادگیری‌زدایی ماشینی^۷ به‌عنوان زمینه‌ای پژوهشی شکل گرفته است تا این مشکل را برطرف کند [۱۲، ۱۳].

تقاطع این دو حوزه، مسئله‌ی این پایان‌نامه را شکل می‌دهد. یک سامانه‌ی یادگیری پیوسته پس از استقرار، هم باید در برابر فراموشی ناخواسته مقاوم باشد و هم بتواند فراموشی خواسته‌شده را به‌درستی اجرا کند. این دو نیاز در برابر یکدیگر قرار می‌گیرند. هر روشی که دانش گذشته را تثبیت کند، حذف عمدی بخشی از آن دانش را دشوارتر می‌سازد؛ از سوی دیگر، حذف بی‌قید ممکن است دانشی را که باید حفظ شود نیز از بین ببرد. شکل ۱-۱ این چرخه‌ی عملیاتی را نشان می‌دهد.



شکل ۱-۱: چرخه‌ی عملیاتی یک سامانه‌ی یادگیری پیوسته‌ی پاسخ‌گو به درخواست حذف. مدل وظیفه‌ها را به‌ترتیب می‌آموزد؛ در نقطه‌ای یک درخواست فراموشی برای یک وظیفه‌ی مشخص می‌رسد؛ سامانه باید رفتار مدل روی آن وظیفه را سرکوب کند و همان مدل باید روی وظیفه‌های باقی‌مانده در سطح پیشین خود کار کند. پس از حذف، دنباله ادامه می‌یابد و سامانه باید ضمن حفظ وظیفه‌های باقی‌مانده، توانایی یادگیری وظیفه‌های تازه را نیز حفظ کند.

^۶Right to be Forgotten

^۷Machine Unlearning

۲-۱ تعریف مسئله

این پایان نامه، یادگیری افزایشی وظیفه^۸ را در حضور درخواست حذف یک وظیفه بررسی می کند. صورت ساده ی مسئله چنین است.

مدلی با پیراسنجه های θ دنباله ای از وظیفه ها $\mathcal{T} = \langle T_1, T_2, \dots, T_n \rangle$ را به ترتیب می آموزد. هنگام آموزش وظیفه ی T_i ، فقط داده های همان وظیفه و یک حافظه ی بازپخش^۹ با ظرفیت ثابت در دسترس اند. هنگام پیش بینی، شناسه ی وظیفه مشخص است و مدل از سر طبقه بند مربوط به همان وظیفه استفاده می کند. در نقطه ای از این دنباله، یک درخواست فراموشی^{۱۰} برای وظیفه ی f دریافت می شود. پس از پردازش این درخواست، دو هدف دنبال می شوند:

- **سرکوب وظیفه ی هدف.** دقت مدل روی وظیفه ی f به دقت حدس تصادفی نزدیک می شود. این مقدار برای یک وظیفه ی دوکلاسه 0.5 و برای یک وظیفه ی ده کلاسه 0.1 است. بنابراین، اگر c_f دقت حدس تصادفی باشد، مقدار $|A_f - c_f|$ باید کوچک باشد.
- **حفظ وظیفه های دیگر.** افت دقت مدل روی مجموعه ی وظیفه های فعال $\mathcal{T}_a = \mathcal{T} \setminus \{f\}$ ، هم در میانگین و هم برای آسیب پذیرترین وظیفه، تا جای ممکن کوچک نگه داشته می شود.

این پایان نامه سرکوب رفتار مدل روی یک وظیفه را هم ارز حذف کامل داده نمی داند. هنگام پردازش درخواست، فقط نمونه های ذخیره شده ی همان وظیفه از حافظه ی بازپخش مدل حذف می شوند. این پژوهش درباره ی حذف داده های خام، نقاط واریسی ذخیره شده، نسخه های پشتیبان یا نسخه های بیرونی ادعایی ندارد. بخش ۵-۱ این محدودیت ها را توضیح می دهد.

۳-۱ چالش اصلی: هم پوشانی پیراسنجه ها

دشواری مسئله از ساختار مشترک شبکه سرچشمه می گیرد. یک شبکه ی پر ظرفیت، دانش هر وظیفه را میان تعداد زیادی وزن توزیع می کند و بخشی از این وزن ها میان چند وظیفه مشترک اند. اگر روی وظیفه ی هدف یک گام یادگیری زدایی بی قید اجرا شود، برای مثال صعود از روی شیب^{۱۱} زیان همان وظیفه یا پاک سازی مبتنی بر فیشر^{۱۲} [۱۴]، وزن های مورد نیاز وظیفه های نگه داری شده نیز ممکن است تغییر کنند. افت دقت

⁸Task-Incremental Learning


⁹Replay Buffer

¹⁰Forgetting Request

¹¹Gradient Ascent

¹²Fisher-based Scrubbing

این وظیفه‌ها پیامد مستقیم همین تغییر است. در این پایان‌نامه، این پدیده هم‌پوشانی پیراسنجه‌ها^{۱۳} نامیده می‌شود. شکل ۱-۲ مفهوم آن را نشان می‌دهد.



شکل ۱-۲: شهود هم‌پوشانی پیراسنجه‌ها. مسیرهای مربوط به وظیفه‌ی هدف و وظیفه‌های نگهداری‌شده، مجموعه‌ای از وزن‌ها را به اشتراک می‌گذارند. به‌روزرسانی بی‌قید مسیر هدف می‌تواند این وزن‌های مشترک را نیز تغییر دهد و دقت وظیفه‌های فعال را کاهش دهد.

چارچوب یادگیری مادام‌العمر حریم‌خصوصی‌آگاه^{۱۴} [۱۵] دانش هر وظیفه را به‌صورت پیمانه‌ای، در یک زیرشبکه‌ی تنک^{۱۵} با نقاب دودویی^{۱۶} ذخیره می‌کند. هنگام دریافت درخواست حذف، وزن‌های همان زیرشبکه بازنشانی یا بازسازی می‌شوند و سپس وظیفه‌های نگهداری‌شده ترمیم می‌شوند. PALL میان وزن‌های مشترک، بر پایه‌ی میزان اهمیت آن‌ها برای وظیفه‌های نگهداری‌شده، تفاوتی قائل نمی‌شود. در نتیجه، وقتی هم‌پوشانی زیاد است، بازنشانی یا تغییر یک ناحیه‌ی مشترک کوچک اما مهم می‌تواند هم‌زمان به چند وظیفه‌ی فعال آسیب بزند. در مقابل، تغییر یک ناحیه‌ی مشترک بزرگ اما کم‌اهمیت ممکن است اثر اندکی داشته باشد. این تفاوت، انگیزه‌ی اصلی روش پیشنهادی این پایان‌نامه است.

۴-۱ پرسش‌های پژوهش

این پایان‌نامه در پنج پرسش، کیفیت حذف، هزینه، نقش هم‌پوشانی، سهم اجزای روش و استفاده از لایه‌های تطبیق را بررسی می‌کند.

RQ1. آیا می‌توان با شناسایی صریح هم‌پوشانی ساختاری میان زیرشبکه‌ی وظیفه‌ی هدف و زیرشبکه‌های

¹³Parameter Overlap

¹⁴Privacy-Aware Lifelong Learning (PALL)

¹⁵Sparse Subnetwork

¹⁶Binary Mask

فعال، و محافظت از زیرمجموعه‌ی حساس آن، هم‌زمان به سرکوب هدف در سطح تصادفی و به نگه‌داری بهتر از PALL اصلی رسید؟

RQ2. در مقایسه با جداسازی کامل، یعنی نگه‌داری یک شبکه‌ی مستقل برای هر وظیفه‌ی فعال در روش CLPU [۱۶]، روش مبتنی بر مدل مشترک تا چه اندازه عملکرد مشابهی دارد و این عملکرد چه مقدار حافظه و زمان پردازش درخواست نیاز دارد؟

RQ3. آیا با افزایش هم‌پوشانی، محافظت از وزن‌های مشترک اهمیت بیشتری پیدا می‌کند؟ این پرسش هم با آزمون موقعیت درخواست و هم با تغییر تنگی زیرشبکه‌ها بررسی می‌شود.

RQ4. کدام مؤلفه‌ی سازوکار پیشنهادی واقعاً منشأ بهبود است؟ به‌طور مشخص، آیا فیلتر صریح اشتراک، رتبه‌بندی حساسیت، بودجه‌ی محافظت و جمله‌ی لنگر هر یک سهم قابل‌اندازه‌گیری دارند؟

RQ5. آیا استفاده از لایه‌های تطبیق کم‌پیراسنجه روی بدنه‌ی ثابت، نتیجه‌ی نهایی درخواست حذف را بهبود می‌دهد، یا تغییر مشاهده‌شده فقط از بازنشانی لایه‌ی مخصوص وظیفه‌ی هدف ناشی می‌شود؟

پرسش پنجم آگاهانه به‌شکلی مطرح شده است که پاسخ منفی هم برای آن معتبر باشد. یکی از دستاوردهای این پایان‌نامه دقیقاً همین است: نتیجه‌ی بررسی اجزای روش برای مسیر لایه‌ی تطبیق منفی است و به‌جای پنهان‌کردن، به‌عنوان یافته گزارش می‌شود.

۵-۱ حدود و دامنه‌ی ادعاها

برای جلوگیری از برداشت فراتر از شواهد، محدودیت‌های این پژوهش از ابتدا به‌صورت زیر تعریف می‌شوند. نتیجه‌گیری‌های فصل‌های بعد نیز در همین محدوده بیان می‌شوند.

۱. **نوع شواهد.** نتایج این پایان‌نامه تجربی‌اند و حذف گواهی‌شده^{۱۷} را اثبات نمی‌کنند. تضمین‌های نظری موجود فقط برای مدل‌های محدب یا شرایط الگوریتمی خاص ارائه شده‌اند و لزوماً در محیط غیرمحدب و دنباله‌ای این پژوهش برقرار نیستند [۱۷، ۱۸، ۱۹].

۲. **سطح وظیفه، نه سطح رکورد.** واحد فراموشی، یک وظیفه با شناسه‌ی مشخص است. حذف یک نمونه‌ی تک یا یک کلاس درون وظیفه در دامنه‌ی این کار نیست.

¹⁷Certified Removal

۳. دامنه‌ی حذف داده. فقط نمونه‌های وظیفه‌ی هدف از حافظه‌ی بازپخش مدل حذف می‌شوند. این پژوهش درباره‌ی پاک‌شدن داده‌های خام روی دیسک، نقاط واری، نسخه‌های پشتیبان یا نسخه‌های بیرونی ادعایی ندارد.

۴. شناسه‌ی وظیفه در استنتاج لازم است. رابط روش به شناسه‌ی وظیفه نیاز دارد و حالت افزایشی کلاس^{۱۸} بدون شناسه پوشش داده نمی‌شود.

۵. محدودیت ارزیابی حریم خصوصی. ارزیابی این پژوهش از حمله‌ی استنتاج عضویت^{۱۹} مبتنی بر آستانه‌ی زیان استفاده می‌کند [۱۰]. نتیجه‌ی نزدیک به ۰/۵ فقط نشان می‌دهد این حمله توان تشخیص کافی نداشته است و نشانه‌ی حذف موفق نیست. برای ادعای قوی‌تر، حمله‌های پیشرفته‌تر [۱۱] یا ارزیابی رسمی حریم خصوصی^{۲۰} [۲۰] لازم است.

۶. محدودیت زمان اجرا. زمان پردازش درخواست روی یک پیکربندی سخت‌افزاری مشخص اندازه‌گیری شده است. بنابراین، این زمان‌ها برای مقایسه‌ی تقریبی روش‌ها روی همان سخت‌افزار مناسب‌اند، اما مقایسه‌ی دقیق کارایی روی سامانه‌های متفاوت را ممکن نمی‌کنند.

۷. تعداد محدود بذرها. بخشی از تحلیل‌ها با دو یا سه بذر انجام شده‌اند. این نتایج فقط به صورت توصیفی گزارش می‌شوند و ادعای معناداری آماری به مواردی محدود است که آزمون دقیق جفتی برای آن‌ها انجام شده باشد.

۶-۱ مشارکت‌های پژوهش

مشارکت‌های این پایان‌نامه در چهار محور روش پیشنهادی، ارزیابی تجربی، بررسی اجزای روش و محاسبه‌ی هزینه‌ها خلاصه می‌شوند.

یک. محافظت از وزن‌های مشترک و مهم. نسخه‌ی توسعه‌یافته‌ی PALL با نام EPALL معرفی می‌شود. این روش هم‌پوشانی ساختاری میان زیرشبکه‌ی هدف و مجموعه‌ی زیرشبکه‌های فعال را می‌سنجد، وزن‌های مشترک را بر پایه‌ی بزرگی شیب زیان وظیفه‌های نگه‌داری شده رتبه‌بندی می‌کند و وزن‌های مهم را هنگام ترمیم با یک جمله‌ی لنگر l_2 نزدیک به مقدار پیش از حذف نگه می‌دارد. فصل ۳ این سازوکار را به‌طور کامل توضیح می‌دهد.

¹⁸Class-Incremental

¹⁹Membership Inference Attack

²⁰Formal Privacy Audit

دو. ارزیابی هم‌تراز و دو آزمون مکمل برای هم‌پوشانی. یازده روش با هشت بذر روی Split-CIFAR مقایسه می‌شوند. در هر بذر، همه‌ی روش‌ها دنباله‌ی یکسانی از وظیفه‌ها و درخواست‌ها را دریافت می‌کنند و چهار معیار دقت نگه‌داری، میزان فراموشی، سرکوب وظیفه‌ی هدف و زمان پردازش درخواست با تحلیل جفتی گزارش می‌شوند. همچنین، یک آزمون گسترده شامل ۳۰۰ اجرا با پنج موقعیت از پیش تعیین‌شده برای درخواست و یک بررسی تنکی زیرشبکه‌ها انجام می‌شود. آزمون نخست فقط نشانه‌ای تقریبی از هم‌پوشانی موردانتظار فراهم می‌کند. در بررسی دوم، تغییر تنکی دامنه‌ی گسترده‌ای از هم‌پوشانی اندازه‌گیری شده ایجاد می‌کند؛ اما چون ظرفیت مدل نیز هم‌زمان تغییر می‌کند، نمی‌توان اثر مستقل هم‌پوشانی را از اثر تغییر ظرفیت جدا کرد.

سه. بررسی جداگانه‌ی اجزای روش. برای هر دو روش پیشنهادی، حالت‌های آزمایشی هم‌ترازی طراحی می‌شوند که در هر یک فقط یک جزء تغییر می‌کند. نتایج EPALL نشان می‌دهند رتبه‌بندی حساسیت به روشنی مفید است، در حالی که دو جزء دیگر بهبود مستقل و قابل اندازه‌گیری ایجاد نمی‌کنند. در PALL Adapter نیز مقایسه‌ی حالت‌ها نشان می‌دهد عامل اصلی سرکوب وظیفه‌ی هدف، بازنشانی لایه‌ی تطبیق مخصوص همان وظیفه است و نقاب نرم بهبود مستقلی ایجاد نمی‌کند. این نتیجه‌ی منفی نیز به‌عنوان بخشی از یافته‌ها گزارش می‌شود.

چهار. محاسبه‌ی مستقیم هزینه‌ها. به‌جای استفاده از نسبت پیراسنجه‌های به‌روزشده به‌عنوان تنها شاخص کارایی، مقدار حافظه‌ی موردنیاز مستقیماً روی دنباله‌های هم‌تراز محاسبه می‌شود. تفاوت میان این مقدار و نسبت پیراسنجه‌های درگیر در ترمیم نیز توضیح داده می‌شود.

۷-۱ معیارهای موفقیت

معیارهای ارزیابی این پژوهش در فصل ۴ بر پایه‌ی موارد زیر گزارش و تفسیر می‌شوند. این معیارها هم حفظ وظیفه‌های دیگر و هم میزان سرکوب وظیفه‌ی هدف را در بر می‌گیرند.

- فاصله‌ی دقت وظیفه‌ی فراموش شده تا دقت حدس تصادفی گزارش می‌شود و مقدار نزدیک به صفر مطلوب است.

- تغییر دقت وظیفه‌های نگه‌داری شده نسبت به PALL اصلی، با تحلیل جفتی روی بذرهای یکسان گزارش می‌شود.

- بیشترین افت دقت میان وظیفه‌های فعال با PALl اصلی مقایسه می‌شود. علامت این معیار حفظ می‌شود تا بهبود احتمالی یک وظیفه به‌اشتباه به‌صورت افت صفر گزارش نشود.
- زمان پردازش درخواست برای همه‌ی روش‌ها گزارش می‌شود، حتی اگر نتیجه به سود روش پیشنهادی نباشد.

۸-۱ ساختار پایان‌نامه

بقیه‌ی پایان‌نامه چنین سازمان یافته است. فصل ۲ مفاهیم پایه و کارهای پیشین را در چهار محور یادگیری پیوسته، یادگیری‌زدایی ماشینی، یادگیری کم‌پیراسنجه و ارزیابی حریم خصوصی مرور می‌کند. در پایان این فصل، جایگاه پژوهش در یک جدول مقایسه‌ای و خلاصه پژوهشی به‌روشنی بیان می‌شود. فصل ۳ صورت‌بندی مسئله، سازوکار EPALL، الگوریتم، تحلیل پیچیدگی و مسیر اکتشافی PALl-Adapter را ارائه می‌کند. این فصل همچنین توضیح می‌دهد که چرا تحلیل نظری ارائه‌شده، افت عملکرد آغاز تا پایان را کران‌بندی نمی‌کند. فصل ۴ طراحی آزمایش‌ها، معیارها و نتایج را گزارش می‌کند؛ از مقایسه‌ی اصلی و آزمون‌های معناداری جفتی تا آزمون موقعیت درخواست، برآورد حافظه‌ی موردنیاز، ارزیابی حریم خصوصی و بررسی حساسیت. فصل ۵ یافته‌ها را در قالب پاسخ به پرسش‌های پژوهش جمع‌بندی می‌کند، محدودیت‌ها را برمی‌شمارد و مسیرهای آینده را پیشنهاد می‌دهد. پیوست ۵-۶ جزئیات بازتولیدپذیری، پیکربندی کامل ابرپیراسنجه‌ها و نگاشت گروه‌های آزمایش به برجسب‌های مستقل را در بر می‌گیرد.

فصل ۲

مفاهیم پایه و مرور کارهای پیشین

این فصل زمینه‌ی لازم برای فهم روش پیشنهادی را فراهم می‌کند. ساختار آن از عام به خاص است: نخست مفاهیم پایه‌ی یادگیری عمیق و اجزایی که در آزمایش‌ها به کار می‌روند مرور می‌شوند؛ سپس یادگیری پیوسته و خانواده‌های راه‌حل آن؛ آنگاه یادگیری‌زدایی ماشینی و تلاقی آن با یادگیری پیوسته؛ پس از آن یادگیری کم‌پیراسنجه؛ و در پایان روش‌شناسی ارزیابی فراموشی و حریم خصوصی. فصل با یک جدول مقایسه‌ی مفهومی و بیان صریح خلأ پژوهشی بسته می‌شود. برای مرورهای جامع یادگیری پیوسته می‌توان به [۴، ۵، ۲۱، ۲۲] و برای مرورهای یادگیری‌زدایی به [۲۳، ۲۴] رجوع کرد.

۱-۲ مفاهیم پایه

۱-۱-۲ یادگیری بانظارت و بهینه‌سازی مبتنی بر شیب

یک شبکه‌ی طبقه‌بند را با $f(\cdot; \theta)$ نشان می‌دهیم که ورودی x را به برداری از امتیازهای خام^۱ می‌نگارد. آموزش بانظارت، کمینه‌سازی مخاطره‌ی تجربی^۲ است:

$$\hat{R}(\theta) = \frac{1}{|D|} \sum_{(x,y) \in D} \ell(f(x; \theta), y), \quad (1-2)$$

که در آن ℓ معمولاً زیان بی‌نظمی متقاطع^۳ است. کمینه‌سازی با شیب کاهشی تصادفی^۴ [۲۵] و به‌روزرسانی SGD $\theta \leftarrow \theta - \eta \nabla_{\theta} \hat{R}_B(\theta)$ روی دسته‌های کوچک B انجام می‌شود. همه‌ی آزمایش‌های این پایان‌نامه از SGD

¹Logits

²Empirical Risk

³Cross-Entropy

⁴Stochastic Gradient Descent (SGD)

با تکانه استفاده می‌کنند؛ دلیل این انتخاب، حذف اثر تطبیقی بهینه‌سازهای مبتنی بر ممان دوم است، چون در حالت فراموشی، حالت انباشته‌ی بهینه‌ساز خودش می‌تواند اثری از وظیفه‌ی حذف‌شده حمل کند.

بردار شیب در این پایان‌نامه دو نقش دارد و تفکیک این دو نقش مهم است. نقش اول، نقش متعارف آن به‌عنوان جهت به‌روزرسانی است. نقش دوم — که سازوکار پیشنهادی بر آن استوار است — استفاده از بزرگی مؤلفه‌های شیب به‌عنوان یک سنجه‌ی محلی از اهمیت پیراسنجه^۵ است: اگر $|\partial_i \mathcal{L}_{\text{retain}}|$ بزرگ باشد، جابه‌جایی کوچک در درایه‌ی i زیان وظایف نگه‌داری‌شده را به‌طور محسوس تغییر می‌دهد.

۲-۱-۲ سنجه‌های اهمیت پیراسنجه

پژوهش‌های یادگیری پیوسته چند سنجه‌ی اهمیت پیشنهاد کرده‌اند و انتخاب میان آن‌ها به موازنه‌ی دقت و هزینه بستگی دارد. ماتریس اطلاعات فیشر^۶ در EWC [۷] از میانگین مربع شیب لگاریتم درست‌نمایی برآورد می‌شود و مبنای نظری روشنی دارد، اما محاسبه‌ی آن به یک گذر کامل روی داده‌ها نیاز دارد. هوشمندی سیناپسی^۷ [۲۶] اهمیت را در طول آموزش انباشته می‌کند و سیناپس‌های آگاه از حافظه^۸ [۲۷] از حساسیت خروجی به تغییر وزن‌ها استفاده می‌کنند. توابع نفوذ^۹ [۲۸] اثر یک نمونه‌ی آموزشی بر پیراسنجه‌ها را تقریب می‌زنند و پیوند مفهومی نزدیکی با یادگیری‌زدایی دارند.

در این پایان‌نامه، سنجه‌ی پیش‌فرض بزرگی شیب روی حافظه‌ی بازپخش وظایف نگه‌داری‌شده است. دلیل این انتخاب صرفاً عمل‌گرایانه است: یک گذر پس‌رو روی حافظه‌ی محدود کافی است و هزینه‌ی آن نسبت به حلقه‌ی ترمیم ناچیز است. در بخش ۴-۱۲-۲ یک جانشین مبتنی بر انرژی تعارض شیب‌ها^{۱۰} نیز به‌طور تجربی سنجیده می‌شود که نتیجه‌ی آن وابسته به مجموعه داده است.

۳-۱-۲ معماری‌های استفاده‌شده

آزمایش‌ها بر دو خانواده‌ی معماری استوارند. خانواده‌ی نخست شبکه‌های باقی‌مانده^{۱۱} یا ResNet [۲۹] است. اتصال باقی‌مانده‌ی $y = \mathcal{F}(x) + x$ مسیری کوتاه برای جریان شیب ایجاد می‌کند و آموزش شبکه‌های عمیق را پایدار می‌سازد. در این کار ResNet-18 برای CIFAR-10 و TinyImageNet و اجراهای پیش‌آموزش‌دیده، و ResNet-34 برای اجراهای اصلی CIFAR-100 به‌کار می‌رود. خانواده‌ی دوم مبدل

^۵Parameter Importance

^۶Fisher Information Matrix

^۷Synaptic Intelligence

^۸Memory Aware Synapses

^۹Influence Functions

^{۱۰}Gradient-Conflict Energy

^{۱۱}Residual Networks

بینایی^{۱۲} [۳۰] است که تصویر را به وصله‌ها تقسیم و با لایه‌های توجه پردازش می‌کند؛ از این خانواده یک نسخه‌ی کوچک به‌عنوان آزمون انتقال میان‌معماری استفاده می‌شود.

مقدارگذاری اولیه نیز در جای‌جای روش نقش دارد. بازنشانی درایه‌های وظیفه‌ی هدف از توزیع کایمینگ^{۱۳} [۳۱] نمونه می‌گیرد؛ همین انتخاب در لایه‌های تطبیق هم برای نگاشت کاهش ابعاد تکرار می‌شود، در حالی که نگاشت افزایش ابعاد با صفر مقدار می‌گیرد تا لایه‌ی تطبیق در لحظه‌ی تولد، تابع همانی باشد.

۴-۱-۲ حافظه‌ی محدود و بازپخش

فرض دسترسی‌نداشتن به داده‌ی وظایف گذشته در عمل بسیار سخت‌گیرانه است. راه‌حل رایج، نگه‌داشتن یک حافظه‌ی رویدادی^{۱۴} کوچک است. در این کار بودجه‌ی بازپخش ۵۰۰ نمونه است و — نکته‌ی مهم — این بودجه از پیش میان وظایف افزای می‌شود و پس از یک درخواست حذف، سهم آزادشده به وظایف دیگر بازتوزیع نمی‌شود. دلیل این محدودیت، جلوگیری از یک اثر مداخله‌گر است: اگر بودجه بازتوزیع شود، بخشی از بهبود مشاهده‌شده پس از فراموشی می‌تواند صرفاً ناشی از بزرگ‌ترشدن حافظه‌ی وظایف باقی‌مانده باشد و نه ناشی از سازوکار فراموشی.

۲-۲ یادگیری پیوسته

۱-۲-۲ سه حالت یادگیری

پیکربندی‌های یادگیری پیوسته را می‌توان بر اساس اطلاعات موجود در استنتاج به سه حالت یادگیری تقسیم کرد [۲۱]: افزایشی وظیفه^{۱۵} که شناسه‌ی وظیفه در استنتاج در دسترس است؛ افزایشی دامنه^{۱۶} که مجموعه‌ی برچسب‌ها ثابت است و توزیع ورودی تغییر می‌کند؛ و افزایشی کلاس^{۱۷} که مدل باید بدون شناسه، میان همه‌ی کلاس‌های دیده‌شده تمایز بگذارد. این پایان‌نامه در حالت نخست کار می‌کند. این انتخاب یک محدودیت واقعی است، اما برای مسئله‌ی حذف در سطح وظیفه ضروری است: مفهوم «فراموش کردن وظیفه‌ی f » تنها زمانی خوش‌تعریف است که مرزهای وظیفه در سطح رابط سامانه شناخته باشند.

¹²Vision Transformer

¹³Kaiming Initialization

¹⁴Episodic Memory

¹⁵Task-Incremental

¹⁶Domain-Incremental

¹⁷Class-Incremental

تفاوت این سه حالت یادگیری را می‌توان دقیق‌تر بیان کرد. فرض کنید مدل تابعی از ورودی x و شناسه‌ی وظیفه t باشد. در حالت افزایشی وظیفه، مدل $p(y | x, t)$ را می‌آموزد و در استنتاج هر دو ورودی در دسترس‌اند؛ عملاً این یعنی هر وظیفه می‌تواند سر طبقه‌بند خودش را داشته باشد و مسئله‌ی تمایز میان کلاس‌های وظایف مختلف اصلاً مطرح نمی‌شود. در حالت افزایشی دامنه، فضای برچسب ثابت است و مدل همچنان $p(y | x)$ را می‌آموزد، اما توزیع ورودی در طول زمان جابه‌جا می‌شود. دشوارترین حالت، حالت افزایشی کلاس است: مدل باید $p(y | x)$ را روی اجتماع همه‌ی کلاس‌های دیده‌شده بیاموزد بدون آنکه بداند نمونه از کدام وظیفه آمده است، و بنابراین باید مرزهایی میان کلاس‌هایی بکشد که هرگز در یک دسته‌ی آموزشی کنار هم ظاهر نشده‌اند.

این تفکیک برای مسئله‌ی حذف پیامد مستقیم دارد. واحد حذف در این پایان‌نامه یک وظیفه‌ی کامل است، و «وظیفه» تنها در حالت نخست یک شیء صریح در رابط سامانه است. در حالت افزایشی کلاس، درخواست حذف باید در سطح کلاس یا رکورد بیان شود، که مسئله‌ی متفاوتی است: در آنجا نمی‌توان یک سر طبقه‌بند یا یک زیرشبکه‌ی مشخص را کنار گذاشت، چون دانش کلاس حذف‌شونده در همان مرزهایی پخش است که کلاس‌های باقی‌مانده را از هم جدا می‌کنند. بنابراین انتخاب حالت افزایشی وظیفه در این کار یک ساده‌سازی دلبخواهی نیست، بلکه شرط خوش‌تعریفی صورت مسئله است؛ در عوض، تعمیم روش به دو حالت دیگر در بخش ۴-۵ به عنوان محدودیت ثبت می‌شود.

۲-۲-۲ روش‌های مبتنی بر تنظیم

نخستین خانواده‌ی راه‌حل، جابه‌جایی پیراسنجه‌های مهم را جریمه می‌کند. EWC [۷] جمله‌ی $\sum_i F_i(\theta_i - \theta_i^*)^2$ را با وزن‌های فیشر اضافه می‌کند؛ SI [۲۶] و MAS [۲۷] همان قالب را با سنج‌های اهمیت متفاوت پیاده می‌کنند. یادگیری بدون فراموشی^{۱۸} یا LwF [۳۲] به جای جریمه‌ی وزن، خروجی مدل جدید را به خروجی مدل قدیم نزدیک نگه می‌دارد و در واقع یک تقطیر دانش^{۱۹} [۳۳] خودارجاع است.

شهود مشترک این خانواده ساده است: اگر بدانیم کدام پیراسنجه‌ها برای وظایف گذشته حیاتی‌اند، می‌توانیم به جای نگه‌داشتن داده، خود پیراسنجه‌ها را نگه داریم. اختلاف روش‌ها در پاسخ به این پرسش است که «اهمیت» چگونه اندازه‌گیری شود. EWC از قطر ماتریس اطلاعات فیشر استفاده می‌کند، که برابر امید مربع شیب لگاریتم درست‌نمایی است و بنابراین حساسیت محلی خروجی مدل به هر پیراسنجه را می‌سنجد. SI همان کمیت را به صورت برخت و در طول مسیر بهینه‌سازی انباشته می‌کند و به یک گذر جداگانه نیاز ندارد. LwF مسیر متفاوتی می‌رود و به جای پیراسنجه‌ها، رفتار مدل را مقید می‌کند: خروجی

¹⁸Learning without Forgetting

¹⁹Knowledge Distillation

نرم مدل پیشین روی داده‌ی جدید به‌عنوان هدف تقطیر به‌کار می‌رود، پس هیچ داده‌ای از وظایف گذشته لازم نیست.

دو محدودیت مشترک این خانواده در ادبیات ثبت شده است. نخست، جریمه سراسری است و روی همه‌ی پیراسنجه‌ها اعمال می‌شود؛ با افزایش تعداد وظایف، جمله‌های جریمه روی هم انباشته می‌شوند و ظرفیت یادگیری وظیفه‌ی تازه را می‌بلعند. دوم، تقریب قطری فیشر همبستگی میان پیراسنجه‌ها را نادیده می‌گیرد، در حالی که آسیب واقعی اغلب از حرکت هم‌زمان گروهی از وزن‌ها می‌آید.

پیوند این خانواده با کار حاضر نزدیک است، اما جهت آن معکوس. جمله‌ی لنگر l_2 در روش پیشنهادی از نظر شکل ریاضی همان قالب EWC است؛ تفاوت در این است که در EWC هدف، محافظت در برابر یادگیری وظیفه‌ی بعدی است و مجموعه‌ی محافظت‌شده کل پیراسنجه‌های مهم است، در حالی که در این کار هدف، محافظت در برابر فراموش کردن است و مجموعه‌ی محافظت‌شده به هم‌پوشانی ساختاری میان زیرشبکه‌ی هدف و زیرشبکه‌های فعال محدود می‌شود. همچنین یک نکته‌ی تجربی مهم در فصل ۴ روشن می‌شود: EWC و LwF در معیار بیشترین افت عالی‌اند اما در سرکوب وظیفه‌ی هدف شکست می‌خورند، چون سازوکار آن‌ها اساساً برای حفظ ساخته شده است، نه برای حذف.

۳-۲-۲ روش‌های مبتنی بر بازپخش

خانواده‌ی دوم، نمونه‌های گذشته را در حافظه نگه می‌دارد و در آموزش وظیفه‌ی جدید بازپخش می‌کند. بازپخش تجربه^{۲۰} ساده‌ترین شکل آن است و iCaRL [۳۴] آن را با نمونه‌های شاخص و طبقه‌بندی نزدیک‌ترین میانگین ترکیب می‌کند. بازپخش تجربه‌ی تاریک^{۲۱} یا DER++ [۳۵] علاوه بر برجسب‌ها، امتیازهای خام ذخیره‌شده را نیز تطبیق می‌دهد و به همین دلیل اطلاعات غنی‌تری از رفتار گذشته‌ی مدل حمل می‌کند. جایگزین مولد این خانواده، بازپخش نمونه‌های ساختگی است [۳۶].

زیان ترمیمی روش پیشنهادی مستقیماً از این خط می‌آید: جمله‌ی $\mathcal{L}_{DER}$ همان تطبیق امتیازهای خام ذخیره‌شده است. دلیل این انتخاب آن است که پس از یک درخواست حذف، هدف ما بازگرداندن رفتار پیشین مدل روی وظایف فعال است و امتیازهای خام ذخیره‌شده دقیقاً همان رفتار را ثبت کرده‌اند.

اندازه‌ی حافظه در این خانواده یکی از عوامل تعیین‌کننده در طراحی است. حافظه‌ی بازپخش نسخه‌ای از داده‌های کاربر را نگه می‌دارد؛ بنابراین اگر پس از درخواست حذف یک وظیفه، نمونه‌های بازپخش آن همچنان باقی بمانند، داده‌های آن وظیفه هنوز در سامانه حضور دارند و ادعای حذف پذیرفتنی نیست. به همین دلیل، حذف نمونه‌های بازپخش وظیفه‌ی هدف بخشی از عملیات حذف در این پایان‌نامه است و

²⁰Experience Replay

²¹Dark Experience Replay

فقط یک جزئیات پیاده‌سازی نیست. بودجه‌ی حافظه پس از حذف دوباره میان وظیفه‌ها توزیع نمی‌شود تا همه‌ی روش‌ها با بودجه‌ی یکسان مقایسه شوند.

۴-۲-۲ تصویر شیب

حافظه‌ی مبتنی بر شیب رویدادی^{۲۲} یا GEM [۳۷] و نسخه‌ی میانگین‌گیری‌شده‌ی آن A-GEM [۳۸] به‌روزرسانی وظیفه‌ی جدید را طوری تصویر می‌کنند که ضرب داخلی آن با شیب وظایف گذشته منفی نشود. این خانواده از نظر ایده نزدیک‌ترین کار به سازوکار این پایان‌نامه است: در هر دو، شیب وظایف نگه‌داری‌شده به‌روزرسانی را مقید می‌کند. تفاوت کلیدی در محل اعمال قید است. GEM یک تصویر سراسری در فضای شیب انجام می‌دهد و همه‌ی درایه‌ها را به‌طور یکنواخت تحت تأثیر قرار می‌دهد؛ روش این پایان‌نامه یک ناحیه‌ی انتخاب‌شده از درایه‌های مشترک را شناسایی و در همان‌جا مهار می‌کند. این تفاوت هم مفهومی است و هم عملی: انتخاب ناحیه‌ای اجازه می‌دهد بقیه‌ی به‌روزرسانی آزادانه در خدمت فراموشی باقی بماند.

۵-۲-۲ جداسازی پیراسنجه و زیرشبکه‌های تنک

خانواده‌ی چهارم، پیراسنجه‌ها را به‌ازای هر وظیفه جدا می‌کند. PackNet [۳۹] پس از آموزش هر وظیفه هرس می‌کند و وزن‌های باقی‌مانده را قفل می‌کند؛ نقاب توجه سخت^{۲۳} یا HAT [۴۰] نقاب‌های واحد‌محور یاد می‌گیرد؛ و SupSup [۴۱] تنها نقاب‌های دودویی را روی یک بدنه‌ی تصادفی و ثابت می‌آموزد. شبکه‌های پیش‌رونده^{۲۴} [۴۲] در انتهای دیگر این طیف قرار دارند و ظرفیت را به‌ازای هر وظیفه رشد می‌دهند.

مبنای نظری این خانواده به فرضیه‌ی بلیت بخت‌آزمایی^{۲۵} [۴۳] و به نتیجه‌ی مکمل آن [۴۴] می‌رسد: زیرشبکه‌های قابل‌آموزش با کارایی خوب، درون شبکه‌های چگال و حتی درون شبکه‌های تصادفی وجود دارند. یادگیری پیوسته‌ی زیرشبکه‌ی برنده^{۲۶} یا WSN [۴۵] این ایده را به یادگیری پیوسته می‌آورد و برای هر وظیفه یک نقاب دودویی می‌آموزد. PALL نقاب‌های هر وظیفه‌ی خود را از همین خط به ارث می‌برد و همین ارث‌بری است که مفهوم هم‌پوشانی ساختاری میان دو وظیفه را خوش‌تعریف می‌کند: هم‌پوشانی، اشتراک مجموعه‌ای دو نقاب است و لازم نیست با یک سنجه‌ی پیوسته تقریب زده شود. این نکته پایه‌ی

²²Gradient Episodic Memory

²³Hard Attention to the Task

²⁴Progressive Networks

²⁵Lottery Ticket Hypothesis

²⁶Winning Subnetwork Continual Learning

مستقیم بخش ۳-۳ است.

چارچوب PALL [۱۵] همین ایده را برای حذف به کار می‌گیرد. برای هر وظیفه، یک نقاب دودویی تنک روی وزن‌های شبکه آموخته و ذخیره می‌شود تا هر وظیفه فقط از زیرشبکه‌ی خود استفاده کند. در زمان حذف، نقاب وظیفه‌ی هدف بازنشانی، سر طبقه‌بند مربوط به آن پاک و نمونه‌های بازپخش آن وظیفه از حافظه حذف می‌شوند. مزیت این طراحی آن است که هزینه‌ی حذف به اندازه‌ی داده وابسته نیست و برخلاف روش‌های مبتنی بر صعود از روی شیب، به بهینه‌سازی روی داده‌های در حال حذف نیاز ندارد.

نقطه‌ی ضعف روش و انگیزه‌ی این پایان‌نامه در همین بخش آشکار می‌شود. نقاب‌های وظیفه‌های مختلف کاملاً جدا نیستند. در یک شبکه با تنکی ثابت، هرچه تعداد وظیفه‌ها بیشتر شود، اشتراک نقاب‌ها نیز افزایش می‌یابد. در نتیجه، بازنشانی زیرشبکه‌ی هدف ممکن است وزن‌هایی را تغییر دهد که وظیفه‌های فعال هنوز به آن‌ها وابسته‌اند. PALL برای جبران این آسیب، پس از بازنشانی یک مرحله‌ی ترمیم روی داده‌های بازپخش وظیفه‌های باقی‌مانده اجرا می‌کند؛ اما در این مرحله میان وزن‌های مشترک و غیرمشترک تفاوتی گذاشته نمی‌شود و سازوکاری برای پیشگیری از آسیب وجود ندارد. پژوهش حاضر همین کاستی را هدف قرار می‌دهد.

۳-۲ یادگیری زدایی ماشینی

۱-۳-۲ فراموشی دقیق و بازآموزی

مرجع مفهومی یادگیری زدایی، بازآموزی کامل مدل روی داده‌ی باقی‌مانده است. چون این کار پرهزینه است، SISA [۱۳] داده را به بخش‌های جدا افراز می‌کند، یک عضو گروه را روی هر بخش آموزش می‌دهد و در زمان حذف تنها عضو آسیب‌دیده را بازآموزی می‌کند. آموزش فراموش‌کار^{۲۷} [۴۶] به روزرسانی‌های هر دسته را ذخیره می‌کند تا بعداً کم شود. کارهای دیگری برای مدل‌های ساده مانند خوشه‌بندی k-means حذف دقیق ارائه کرده‌اند [۴۷].

معنای دقیق «دقیق» در این خانواده اهمیت دارد. یک سازوکار حذف را دقیق می‌نامیم هرگاه توزیع مدل خروجی پس از حذف نمونه‌ی z ، با توزیع مدلی که از ابتدا بدون z آموزش دیده است یکسان باشد. این تعریف بر توزیع مدل‌ها بنا شده و نه بر رفتار یک مدل منفرد؛ به همین دلیل صرف افت دقت روی داده‌ی حذف‌شده، شاهدی برای حذف دقیق نیست. بازآموزی کامل به‌طور بدیهی این تعریف را برآورده می‌کند و به همین دلیل مرجع مفهومی این حوزه است.

²⁷ Amnesiac Training

هزینه‌ی این مرجع یکی از مسائل اصلی این حوزه است. بازآموزی کامل به نگهداری دائمی داده‌های خام و تکرار تمام هزینه‌ی آموزش در هر درخواست نیاز دارد. در محیط پیوسته که درخواست‌ها به صورت جریانی می‌رسند، این هزینه برای هر درخواست دوباره پرداخت می‌شود. رویکردهای افزایی مانند SISA هزینه را کاهش می‌دهند، اما دو پیامد دارند: کاهش دقت، چون هر عضو گروه فقط بخشی از داده‌ها را می‌بیند، و افزایش حافظه‌ی موردنیاز، چون چند مدل باید هم‌زمان نگهداری شوند. همین موازنه در مقایسه با روش جداسازی کامل نیز بررسی می‌شود.

۲-۳-۲ فراموشی تقریبی

خانواده‌ی تقریبی به جای بازآموزی، وزن‌ها را مستقیماً ویرایش می‌کند. [۱۴] یک به‌روزرسانی مبتنی بر فشار برای پاک کردن اطلاعات پیشنهاد می‌دهد؛ [۴۸] روش‌های حذف تقریبی برای مدل‌های خطی ارائه می‌کند؛ فراموشی مرزی^{۲۸} [۴۹] مرزهای تصمیم خروجی را جابه‌جا می‌کند تا سرعت به‌دست آورد؛ و [۵۰] از یک جفت معلم خوب و بد برای هدایت فراموشی استفاده می‌کند. دو کار اخیرتر به این پایان‌نامه نزدیک‌ترند و در آزمایش‌ها به عنوان خط پایه به کار می‌روند: یادگیری زدایی برجستگی^{۲۹} یا SalUn [۵۱] به‌روزرسانی را به وزن‌های پرنفوذ محدود می‌کند، و میرا کردن انتخابی سیناپسی^{۳۰} یا SSD [۵۲] پیراسنجه‌ها را بر پایه‌ی اهمیت فیشری میرا می‌کند و برای این کار به هیچ گام آموزشی نیاز ندارد.

SalUn از منظر این پایان‌نامه اهمیت مفهومی خاصی دارد، چون آن هم به‌روزرسانی را روی یک زیرمجموعه‌ی انتخاب‌شده متمرکز می‌کند. اما جهت انتخاب متفاوت است: SalUn درایه‌های پرنفوذ را برای تغییر/دن انتخاب می‌کند، در حالی که روش این پایان‌نامه درایه‌های حساس به نگهداری را برای تغییر/دن انتخاب می‌کند.

۲-۳-۳ تضمین‌های صوری و مرزهای آن

یک شاخه‌ی نظری برای مدل‌های محدب، تضمین حذف ارائه می‌دهد. پژوهش [۱۷] مفهوم حذف داده‌ی گواهی‌شده^{۳۱} را با تعریفی شبیه به حریم خصوصی تفاضلی^{۳۲} [۵۳] معرفی می‌کند. پژوهش [۱۸] الگوریتم‌های مبتنی بر کاهش شیب با تضمین ارائه می‌دهد و [۱۹] موازنه‌ی میان تعمیم و حذف را بررسی می‌کند.

²⁸Boundary Unlearning

²⁹Saliency Unlearning

³⁰Selective Synaptic Dampening

³¹Certified Data Removal

³²Differential Privacy

باید صریح گفت که این تضمین‌ها به تنظیم این پایان‌نامه منتقل نمی‌شوند. آموزش دنباله‌ای یک شبکه‌ی عمیق غیرمحدب، با نقاب‌های وابسته به تاریخ و یک حافظه‌ی بازپخش که خودش تابعی از دنباله‌ی درخواست‌ها است، هیچ‌یک از پیش‌فرض‌های آن قضایا را برآورده نمی‌کند. به همین دلیل، همه‌ی ادعاهای این پایان‌نامه تجربی برچسب می‌خورند. بحث سازوکارهای «یادگیری برای فراموش کردن» در [۵۴] آمده است.

برای آنکه روشن باشد چه چیزی منتقل نمی‌شود، صورت آرام‌شده‌ی این تضمین را می‌آوریم. الگوریتم حذف U را نسبت به الگوریتم آموزش A و مجموعه داده‌ی D یک حذف (ϵ, δ) می‌نامیم هرگاه برای هر نمونه‌ی $z \in D$ و هر مجموعه‌ی اندازه‌پذیر S از مدل‌ها، رابطه‌ی

$$\Pr [U(A(D), z) \in S] \leq e^\epsilon \Pr [A(D \setminus z) \in S] + \delta \quad (2-2)$$

و رابطه‌ی متقارن آن برقرار باشد. این صورت‌بندی عمداً به تعریف حریم خصوصی تفاضلی [۵۳] شبیه است و مانند آن، گزاره‌ای درباره‌ی توزیع خروجی الگوریتم است و نه درباره‌ی یک اجرای منفرد.

سه پیش‌فرض این قضایا در تنظیم ما نقض می‌شوند. نخست، اثبات‌ها به محدب‌بودن تابع هزینه و یکتایی کمینه تکیه دارند تا بتوانند فاصله‌ی پیراسنجه‌ها را کران‌دار کنند؛ یک شبکه‌ی عمیق هیچ‌کدام را ندارد. دوم، فرض می‌شود مسیر آموزش تنها از راه داده به آن وابسته است، در حالی که اینجا نقاب‌های زیرشبکه خودشان تابعی از ترتیب وظایف‌اند و تاریخ اجرا را در ساختار مدل رمز می‌کنند. سوم، حافظه‌ی بازپخش محدود، خود تابعی از دنباله‌ی درخواست‌هاست؛ پس حتی اگر به روزرسانی حذف کران‌دار می‌بود، وضعیت اولیه‌ای که روی آن اعمال می‌شود به داده‌ی حذف‌شونده وابسته است. به همین سه دلیل، در این پایان‌نامه هیچ عدد ϵ گزارش نمی‌شود و هر ادعای حذف، تجربی و مشروط بیان می‌گردد.

۲-۳-۴ یادگیری زدایی در بستر یادگیری پیوسته

تلاقی این دو حوزه، موضوع پژوهش حاضر است و چند مرجع مهم دارد. نخست، CLPU [۱۶] یک مرجع مبتنی بر جداسازی کامل است. در پیاده‌سازی ارزیابی‌شده، هر وظیفه‌ی فعال شبکه‌ی کامل خود را دارد و با دریافت درخواست حذف، شبکه‌ی مربوط به همان وظیفه کنار گذاشته می‌شود. در نتیجه، تداخل میان وظیفه‌ها از نظر ساختاری رخ نمی‌دهد و بیشترین افت همواره صفر است. هزینه‌ی این جداسازی، افزایش حافظه‌ی موردنیاز با تعداد وظیفه‌ها است. این پایان‌نامه CLPU را به عنوان مرجع جداسازی کامل در نظر می‌گیرد و در بخش ۴-۱۰ حافظه‌ی موردنیاز آن را مستقیماً محاسبه می‌کند.

PALL [۱۵] نقطه‌ی شروع فنی این کار است. PALL برای هر وظیفه یک زیرشبکه‌ی تنک می‌آموزد، نقاب آن را ذخیره می‌کند و در زمان درخواست، بر اساس اینکه یک درایه در نقاب‌های تاریخی و پشتیبان‌های

ذخیره شده چه وضعیتی دارد، آن را بازنشانی یا بازسازی می‌کند و سپس وظایف نگه‌داری شده را ترمیم می‌کند. آنچه PALL فراهم می‌کند، ساختاری است که هم‌پوشانی را قابل اندازه‌گیری می‌سازد؛ آنچه فراهم نمی‌کند، تفکیک درایه‌های مشترک بر حسب حساسیت نگه‌داری است.

نزدیک‌ترین کار به صورت مسئله‌ی ما یادگیری با فراموشی انتخابی^{۳۳} [۵۵] است که یک کلاس را با کدهای یادیار پاک می‌کند در حالی که یادگیری ادامه دارد؛ همین جفت‌شدگی یادگیری و حذف در راهبرد پادگرا برای فراموشی انتخابی مادام‌العمر [۵۶] نیز تکرار می‌شود. تفاوت تنظیم ما با هر دو در آن است که یک مدل مشترک با حافظه‌ی بازپخش کران‌دار نگه می‌داریم و وزن‌های هم‌پوشان را مستقیماً ویرایش می‌کنیم، نه آنکه فراموشی را از راه هدف یادگیری اعمال کنیم.

دو پژوهش جدیدتر دامنه‌ی ارزیابی را گسترش می‌دهند. UnCLe [۵۷] پیراسنجه‌های مخصوص هر وظیفه را تولید می‌کند و بازگشت وظیفه پس از حذف^{۳۴} را بدون داده‌های نگه‌داری شده بررسی می‌کند. CATA [۵۸] حذف دنباله‌ای و ماندگاری آن را برای مدل‌های بینایی-زبان، از طریق تجمیع بردار وظیفه و پرهیز از تعارض، مطالعه می‌کند. پژوهش [۵۹] نیز نشان می‌دهد تقطیر کنترل‌شده می‌تواند یادگیری و حذف را با حافظه‌ی ثابت هم‌زمان پشتیبانی کند. درس مشترک این پژوهش‌ها آن است که دقت بلافاصله پس از درخواست، شاهد کافی نیست و ماندگاری سرکوب باید جداگانه ارزیابی شود. بخش ۴-۱۱-۵ همین ارزیابی را انجام می‌دهد.

۴-۲ یادگیری کم‌پیراسنجه

یادگیری کم‌پیراسنجه^{۳۵} آموزش را به پیمانه‌های فشرده‌ی درج‌شده در یک شبکه‌ی منجمد محدود می‌کند. لایه‌های تطبیق گلوگاهی^{۳۶} [۶۰] یک نگاشت کاهش ابعاد، یک غیرخطیت ReLU [۶۱] و یک نگاشت افزایش ابعاد را در قالب یک بلوک باقی‌مانده ترکیب می‌کنند:

$$h \leftarrow h + W_{up} \sigma(W_{down} h), \quad W_{down} \in \mathbb{R}^{r \times d}, \quad W_{up} \in \mathbb{R}^{d \times r}, \quad r \ll d. \quad (۳-۲)$$

انطباق کم‌رتبه^{۳۷} یا LoRA [۶۲] به‌جای افزودن یک پیمانه، به‌روزرسانی وزن را با حاصل ضرب دو ماتریس کم‌رتبه‌ی $\Delta W = BA$ بیان می‌کند. لایه‌های تطبیق باقی‌مانده‌ی چندحوزه‌ای [۶۳]، زیرساخت‌های اشتراک لایه‌ی تطبیق [۶۴]، نسخه‌های فشرده‌تر [۶۵، ۶۶] و روش‌های مبتنی بر پیشوند و راهنمای ورودی [۶۷]،

³³Learning with Selective Forgetting (LSF)

³⁴Post-Deletion Task Relapse

³⁵Parameter-Efficient Fine-Tuning (PEFT)

³⁶Bottleneck Adapters

³⁷Low-Rank Adaptation

[۶۸] این خانواده را تکمیل می‌کنند. پیش‌نویس اخیر BID-LoRA [۶۹] ترکیب مشابهی از یادگیری پیوسته و یادگیری زدایی را بررسی می‌کند.

بررسی این خانواده در پایان‌نامه دو دلیل دارد. نخست، اگر بدنه‌ی اصلی ثابت باشد، هنگام حذف فقط بخش کوچکی از پیراسنجه‌ها تغییر می‌کنند. دوم، در یک لایه‌ی تطبیق مشترک و باریک، هم‌پوشانی میان وظیفه‌ها متمرکز است؛ بنابراین انتظار می‌رود سازوکار آگاه از هم‌پوشانی در این بخش اثر روشنی داشته باشد. فصل ۴ نشان می‌دهد این انتظار برآورده نمی‌شود و نتیجه‌ی منفی نیز در گزارش حفظ شده است.

۵-۲ ارزیابی فراموشی و حریم خصوصی

۱-۵-۲ معیارهای رفتاری

سنجش کیفیت فراموشی معمولاً با معیارهای رفتاری آغاز می‌شود: دقت روی وظیفه‌ی هدف پس از درخواست، دقت روی وظایف نگه‌داری شده و اختلاف این دو نسبت به یک مرجع. نکته‌ی ظریفی که در این معیارها اغلب نادیده گرفته می‌شود، جهت مطلوب دقت وظیفه‌ی حذف‌شده است. کاهش این دقت تا صفر مطلوب نیست، چون مدلی که روی وظیفه‌ی حذف‌شده به‌طور نظام‌مند اشتباه می‌کند، همچنان اطلاعاتی از آن وظیفه حمل می‌کند و یک حمله‌کننده می‌تواند از همین سوگیری برای تشخیص عضویت استفاده کند. هدف درست، رساندن دقت به سطح تصادفی است؛ یعنی مدل باید نسبت به وظیفه‌ی حذف‌شده بی‌اطلاع به نظر برسد و نه بدرفتار. به همین دلیل در این پایان‌نامه هر جا دقت وظیفه‌ی هدف گزارش می‌شود، معیار داوری فاصله‌ی آن تا سطح تصادفی است و نه مقدار خام آن. تمام جدول‌های فصل ۴ بر همین اساس تفسیر می‌شوند.

۲-۵-۲ حمله‌ی استنتاج عضویت

حمله‌ی استنتاج عضویت^{۳۸} [۷۰، ۱۰] تلاش می‌کند تشخیص دهد آیا یک نمونه‌ی مشخص در آموزش مدل حضور داشته است یا نه؛ از این رو، به‌عنوان یک آزمون تجربی حریم خصوصی به‌کار می‌رود. نسخه‌ی ساده‌ی این حمله از آستانه‌ی زیان استفاده می‌کند. دو نکته درباره‌ی این معیار مهم است. نخست، پیش‌پردازش نمونه‌های عضو و غیرعضو باید یکسان باشد؛ در غیر این صورت، تفاوت مشاهده‌شده ممکن است فقط از پیش‌پردازش متفاوت ناشی شود. دوم، حمله‌ی مبتنی بر آستانه‌ی زیان ممکن است توان تشخیص کمی داشته باشد. حمله‌های قوی‌تر مبتنی بر مدل‌های سایه [۱۱] و ارزیابی‌های جامع‌تر [۷۱] می‌توانند تفاوتی را

³⁸Membership Inference Attack (MIA)

آشکار کنند که آزمون ساده تشخیص نمی‌دهد. بنابراین، نتیجه‌ی نزدیک به ۰/۵ فقط نشان می‌دهد حمله‌ی به‌کاررفته تفاوتی پیدا نکرده است و نشانه‌ی حذف موفق نیست.

خانواده‌ی حمله‌های دیگر نیز زمینه‌ی تهدید را کامل می‌کنند: وارون‌سازی مدل^{۳۹} [۷۲] و استخراج داده‌ی آموزشی از مدل‌های زبانی [۷۳] نشان می‌دهند اثر داده در وزن‌ها تا چه اندازه قابل بازیابی است.

۲-۵-۳ مرجع بازآموزی و ارزیابی رسمی

یک ارزیابی دقیق‌تر، مقایسه‌ی مدل فراموش‌کرده با یک نمونه‌ی تازه از همان روش است که از ابتدا بدون وظیفه‌ی هدف آموزش دیده باشد. سنجه‌های مقایسه شامل توافق پیش‌بینی، فاصله‌ی جنسن-شانون^{۴۰} میان توزیع‌های خروجی، فاصله‌ی ℓ_2 امتیازهای خام و شباهت کسینوسی ویژگی‌ها است. در سوی صوری، [۲۰] روشی برای ارزیابی حریم خصوصی با یک اجرای آموزش ارائه می‌دهد و حریم خصوصی تفاضلی^{۴۱} [۵۳] چارچوب نظری استاندارد این حوزه است. بخش ۴-۱۱-۴ مرجع بازآموزی هم‌روش را برای EPALL گزارش می‌کند: نتیجه شاهده‌ی برای هم‌ارزی با بازآموزی دقیق فراهم نمی‌کند، هرچند بدون یک خط پایه‌ی «بازآموزی در برابر بازآموزی» نمی‌توان از آن، حذف دقیق توزیعی را به‌طور صوری رد کرد.

شکل ۲-۱ مسیر مفهومی ادبیات را از حفظ دانش گذشته تا حذف انتخابی آگاه از هم‌پوشانی خلاصه می‌کند. این شکل یک رده‌بندی مفهومی است و نه ترتیب تاریخی یا مقایسه‌ی تجربی.

۲-۶ مقایسه‌ی مفهومی و جایگاه این پژوهش


جدول ۲-۱ روش‌های مرتبط را از چهار جنبه مقایسه می‌کند: مشترک‌بودن مدل میان وظیفه‌ها، پشتیبانی از حذف در سطح وظیفه، مدیریت مستقیم هم‌پوشانی پیراسنجه‌ها و تغییر حافظه‌ی موردنیاز با افزایش تعداد وظیفه‌ها.

تفسیر این جدول، خلأ پژوهشی را روشن می‌کند. روش‌های تنظیم و بازپخش، سازوکار حذف در سطح وظیفه ندارند. روش‌های یادگیری‌زدایی عمومی مانند SSD و SalUn سازوکار حذف دارند، اما ساختار وظیفه‌ای مدل را در نظر نمی‌گیرند و، چنان‌که فصل ۴ نشان می‌دهد، در محیط پیوسته دقت وظیفه‌ی هدف را به سطح حدس تصادفی نمی‌رسانند. CLPU با جداسازی کامل، هم‌پوشانی را از بین می‌برد؛ بهای این جداسازی، رشد خطی حافظه‌ی موردنیاز است. روش‌هایی مانند WSN و PackNet نقاب‌های مربوط به

³⁹Model Inversion

⁴⁰Jensen-Shannon

⁴¹Differential Privacy



شکل ۱-۲: رده بندی مفهومی روش های مرتبط و جایگاه این پایان نامه. مسیر از روش های حفظ دانش در یادگیری پیوسته و جداسازی پیراسنجه ها، به یادگیری زدایی و سپس حذف وظیفه ای آگاه از هم پوشانی می رسد. این رده بندی برای سازمان دهی مفاهیم است و ادعای تجربی یا ترتیب تاریخی ندارد.

جدول ۱-۲: مقایسه ی مفهومی نزدیک ترین روش های مرتبط بر چهار محور تصمیم گیری این پایان نامه. دو سطر پایانی روش های پیشنهادی این کار هستند.

روش	مدل مشترک	حذف سطح مدیریت مستقیم هم پوشانی وظیفه	رشد حافظه ی مورد نیاز
EWC [۷]	بله	خیر	ثابت
LwF [۳۲]	بله	خیر	ثابت
ER / DER++ [۳۵]	بله	خیر	فقط حافظه
GEM / A-GEM [۳۷]	بله	خیر	فقط حافظه
PackNet [۳۹]	بله	خیر	نقاب
WSN [۴۵]	بله	خیر	نقاب دارد، وزن منجمد
			نقاب دارد، برای حذف به کار نقاب نمی رود
SSD [۵۲]	بله	بله	فقط میرا کردن اهمیتی
SalUn [۵۱]	بله	بله	انتخاب وزن برای تغییر
CLPU [۱۶]	خیر	بله	به طور ساختاری لازم نیست
PALL [۱۵]	بله	بله	نقاب ذخیره، مشترک ها بی رتبه
EPALL	بله	بله	محافظة رتبه بندی شده ی مشترک
PALL-Adapter	بله	بله	نقاب نرم (ارزیابی شده، بی اثر)
			لایه ی تطبیق به ازای وظیفه

هر وظیفه را می سازند، اما از آن‌ها برای حذف استفاده نمی کنند. PALL این دو ایده را به هم پیوند می دهد، ولی وزن های مشترک را بر پایه ی اهمیتشان رتبه بندی نمی کند.

این پایان نامه خلاصه ی مانده را در یک سامانه ی دارای مدل مشترک بررسی می کند. با استفاده از نقاب هر وظیفه، هم پوشانی ساختاری محاسبه می شود؛ سپس وزن های مشترک بر پایه ی حساسیت وظیفه های نگه داری شده رتبه بندی می شوند و فقط زیرمجموعه ی مهم آن ها هنگام ترمیم محافظت می شود. فصل بعد این ایده را به یک الگوریتم مشخص تبدیل می کند.

فصل ۳

روش پیشنهادی

فصل پیشین نشان داد که نقاب هر وظیفه در دسترس است، اما PALL از این نقاب‌ها برای تشخیص اهمیت وزن‌های مشترک استفاده نمی‌کند. منظور از درایه در روابط این فصل، یک مؤلفه از بردار پیراسنجه‌ها، یعنی یک وزن منفرد شبکه، است. ابتدا مسئله و سازوکار اصلی PALL صورت‌بندی می‌شوند. سپس دلیل آسیب به وزن‌های مشترک بررسی و روش اصلی پایان‌نامه، EPALL، همراه با الگوریتم و تحلیل پیچیدگی معرفی می‌شود. در ادامه، مسیر اکتشافی PALL-Adapter و تحلیل نظری محدود آن ارائه می‌شوند. در پایان نیز ضوابط دسترسی به داده و محدودیت ادعاهای دو روش توضیح داده می‌شوند.

یادداشت نام‌گذاری. روش اصلی این پایان‌نامه، نسخه‌ی توسعه‌یافته‌ی PALL با نام EPALL است (En-PALL). در کد پیاده‌سازی، گزارش‌های اجرا و برچسب‌های آزمایش، همین روش با شناسه‌ی `pall_modified` ثبت شده است. هر دو نام به یک الگوریتم اشاره می‌کنند.

۳-۱ صورت‌بندی مسئله

۳-۱-۱ نمادگذاری

دنباله‌ی وظایف را با $\mathcal{T} = \{1, \dots, n\}$ و مجموعه‌داده‌ی وظیفه‌ی t را با D_t نشان می‌دهیم؛ کلاس‌های وظایف مختلف مجزا هستند. شبکه با پیراسنجه‌های $\theta \in \mathbb{R}^d$ و یک سر طبقه‌بند به‌ازای هر وظیفه پیاده می‌شود. حافظه‌ی بازپخش $\mathcal{B}$ برای هر وظیفه‌ی t سه‌گانه‌ی (x, y, h) نگه می‌دارد که h امتیازهای خام ثبت‌شده در پایان آموزش همان وظیفه است. سامانه دنباله‌ای از درخواست‌ها^۱ را پردازش می‌کند؛ هر

^۱Requests

درخواست یا $\text{learn}(t)$ است یا $\text{forget}(t)$.

پس از دریافت $\text{forget}(f)$ ، مجموعه‌ی وظایف فعال $\setminus \{t \in \mathcal{T} : t \text{ آموزش دیده و حذف نشده}\}$ $\mathcal{T}_a$ است. دقت وظیفه‌ی t در لحظه‌ی r را با $A_t(r)$ و سطح تصادفی آن را با c_t نشان می‌دهیم. زیان نگه‌داری روی حافظه‌ی وظایف فعال چنین است:

$$\mathcal{L}_{\text{retain}}(\theta) = \frac{1}{|\mathcal{T}_a|} \sum_{t \in \mathcal{T}_a} \mathbb{E}_{(x,y,h) \sim \mathcal{B}_t} [\ell(f(x; \theta, t), y)]. \quad (1-3)$$

۲-۱-۳ هدف مسئله

هدف عملیاتی درخواست فراموشی، یافتن پیراسنجه‌های جدید θ' است که هم‌زمان دو شرط را برآورده کند:

$$|A_f(\theta') - c_f| \rightarrow 0 \quad \text{و} \quad \max_{t \in \mathcal{T}_a} (A_t(\theta) - A_t(\theta')) \rightarrow 0. \quad (2-3)$$

شرط اول سرکوب هدف و شرط دوم حفظ بدترین وظیفه‌ی فعال است. عمداً از بیشینه و نه میانگین استفاده شده است: یک سامانه‌ی مستقر با میانگین خوب اما یک وظیفه‌ی ویران‌شده، از دید کاربران آن وظیفه شکست خورده است.

۳-۱-۳ سازوکار ارثی PALL

PALL [۱۵] برای هر وظیفه‌ی t یک نقاب دودویی $M_t \in \{0, 1\}^d$ می‌آموزد که زیرشبکه‌ی همان وظیفه را مشخص می‌کند؛ این نقاب با امتیازهای قابل یادگیری^۲ و در سطح تنکی هدف به‌دست می‌آید و پس از آموزش ذخیره می‌شود [۴۴، ۴۵]. استنتاج وظیفه‌ی t با $f(x; \theta \odot M_t, t)$ انجام می‌گیرد.

در زمان درخواست فراموشی، PALL سه کار انجام می‌دهد. نخست، نقاب M_f را از مجموعه‌ی فعال کنار می‌گذارد و نمونه‌های بازپخش وظیفه‌ی هدف را حذف می‌کند. دوم، وزن‌های نقاب هدف را بر پایه‌ی وضعیت آن‌ها در نقاب‌های تاریخی و پشتیبان‌های ذخیره‌شده بازنشانی یا بازسازی می‌کند. سوم، یک مرحله‌ی ترمیم روی حافظه‌ی وظیفه‌های فعال اجرا می‌کند تا افت جانبی جبران شود.

نکته‌ای که در گام دوم مهم است و در فصل ۴ به آن باز می‌گردیم این است که بازنشانی شاخه‌محور است. اینکه یک درایه بازنشانی می‌شود یا حفظ می‌شود، به این بستگی دارد که وظیفه‌ی هدف پیش از وظایف فعال آموزش دیده باشد یا پس از آن‌ها، و اینکه پشتیبان تنک برای آن درایه ذخیره شده باشد یا نه. EPALL این منطق شاخه‌محور را دست‌نخورده به ارث می‌برد؛ نوآوری آن جای دیگری است.

²Learnable Scores

۲-۳ محدودیت فراموشی بی قید

فرض کنید در پاسخ به درخواست، به جای سازوکار ساختاریافته، یک گام بی قید در جهت افزایش زیان وظیفه‌ی هدف برداشته شود:

$$\theta' = \theta + \eta \nabla_{\theta} \mathcal{L}_f(\theta). \quad (۳-۳)$$

اثر این گام بر یک وظیفه‌ی فعال t را می‌توان با بسط مرتبه‌ی اول تقریب زد:

$$\mathcal{L}_t(\theta') - \mathcal{L}_t(\theta) \approx \eta \langle \nabla_{\theta} \mathcal{L}_t(\theta), \nabla_{\theta} \mathcal{L}_f(\theta) \rangle. \quad (۴-۳)$$

عبارت سمت راست، ضرب داخلی شیب وظیفه‌ی فعال و شیب وظیفه‌ی هدف است. اگر این دو شیب همسو باشند، آسیب جانبی مثبت و بزرگ است. اما ضرب داخلی یک مقدار انباشته روی همه‌ی d درایه است و همین انباشتگی، اطلاعات مهمی را پنهان می‌کند:

$$\langle \nabla \mathcal{L}_t, \nabla \mathcal{L}_f \rangle = \underbrace{\sum_{i \in S_{\text{share}}} \partial_i \mathcal{L}_t \partial_i \mathcal{L}_f}_{\text{ناحیه‌ی مشترک}} + \underbrace{\sum_{i \notin S_{\text{share}}} \partial_i \mathcal{L}_t \partial_i \mathcal{L}_f}_{\text{ناحیه‌ی غیرمشترک}}. \quad (۵-۳)$$

در جمله‌ی دوم، درایه‌ها بیرون زیرشبکه‌ی وظایف فعال قرار دارند و بنابراین $|\partial_i \mathcal{L}_t|$ در آن‌ها کوچک است. پس انتظار می‌رود سهم آن جمله کوچک باشد و بخش عمده‌ی آسیب جانبی از جمله‌ی نخست بیاید. تأکید می‌شود که این یک استدلال ساختاری است و نه اندازه‌گیری: سهم نسبی دو جمله در این کار به‌طور تجربی تفکیک نشده است. مهم‌تر آنکه درون همان جمله‌ی نخست هم توزیع یکنواخت نیست: چند درصد از درایه‌های مشترک، $|\partial_i \mathcal{L}_t|$ بزرگی دارند و بخش عمده‌ی مجموع را می‌سازند.

دو نتیجه‌ی طراحی از این تحلیل بیرون می‌آید. نتیجه‌ی اول، مهارکردن همه‌ی به‌روزرسانی — آن‌گونه که یک تصویر سراسری در سبک GEM [۳۷] می‌کند — لازم نیست و هزینه‌ی آن کندشدن فراموشی است. نتیجه‌ی دوم، مهارکردن همه‌ی ناحیه‌ی مشترک هم لازم نیست، چون بخش بزرگی از آن کم‌اهمیت است. راه‌حل درست، مهارکردن حساس‌ترین زیرمجموعه‌ی ناحیه‌ی مشترک است. این دقیقاً کاری است که EPALL می‌کند و بخش ۴-۶ همین سه گزینه را به‌طور تجربی مقایسه می‌کند.

۳-۳ روش پیشنهادی EPALL

شکل ۱-۳ کل سازوکار را در سه بخش خلاصه می‌کند: مسئله، قاعده‌ی انتخاب، و رویه‌ی زمان درخواست. بخش‌های بعدی هر سه را باز می‌کنند.



شکل ۳-۱: سازوکار EPALL. الف) مسیر وظیفه‌ی هدف و مسیرهای وظیفه‌های نگهداری شده، وزن‌هایی را به اشتراک می‌گذارند؛ بنابراین بازنشانی ساده ممکن است به وظیفه‌های دیگر آسیب بزند. ب) EPALL وزن‌های مجموعه‌ی $S_{share} = M_f \cap M_r$ را بر پایه‌ی حساسیت وظیفه‌های نگهداری شده رتبه‌بندی و مهم‌ترین بخش را با نسبت ρ محافظت می‌کند. ج) پس از اندازه‌گیری‌های لازم روی هدف، نمونه‌های بازپخش هدف حذف می‌شوند، اجتماع نقاب‌های نگهداری شده ساخته می‌شود، لنگرها ذخیره می‌شوند و بازنشانی شاخه‌محور PALL و ترمیم لنگردار اجرا می‌شوند. این فرایند یک روش تجربی است و حذف گواهی شده را تضمین نمی‌کند.

۳-۳-۱ هم‌پوشانی ساختاری

M_f نقاب دودویی ذخیره‌شده‌ی وظیفه‌ی درخواست‌شده برای حذف و M_r اجتماع نقاب‌های وظایف نگهداری شده است:

$$M_r = \bigvee_{t \in T_a} M_t. \quad (۳-۶)$$

پشتیبان مشترک^۳ این دو، ناحیه‌ای است که هر تغییر در آن هم‌زمان به مسیر هدف و به حداقل یک مسیر فعال مربوط می‌شود:

$$S_{share} = M_f \cap M_r. \quad (۳-۷)$$

اهمیت این تعریف در دقیق‌بودن آن است. چون نقاب‌ها دودویی و ذخیره‌شده‌اند، S_{share} یک اشتراک مجموعه‌ای است و به هیچ تقریب یا آستانه‌گذاری نیاز ندارد. این همان مزیتی است که اثربری از خط زیرشبکه‌های نقاب‌دار [۴۵] فراهم می‌کند و در روش‌های بدون نقاب در دسترس نیست.

³Shared Support

۲-۳-۳ رتبه‌بندی حساسیت و انتخاب بودجه

همه‌ی درایه‌های S_{share} اهمیت یکسانی ندارند. برای هر $i \in S_{\text{share}}$ یک امتیاز حساسیت محاسبه می‌شود:

$$q_i = |\nabla_i \mathcal{L}_{\text{retain}}|, \quad (۸-۳)$$

که در آن شیب با یک گذر پس‌رو روی حافظه‌ی بازپخش وظایف فعال و روی زیرشبکه‌ی هر وظیفه محاسبه می‌شود. سپس با یک نسبت محافظت^۴ $\rho \in (0, 1]$ ، زیرمجموعه‌ی بحرانی انتخاب می‌شود:

$$S_{\text{crit}} = \left\{ q_i \text{ بر حسب } S_{\text{share}} \text{ برتر } \lceil \rho |S_{\text{share}}| \rceil \right\}. \quad (۹-۳)$$

مقدار پیش‌فرض $\rho = 0.2$ است. توجیه این انتخاب در بخش ۲-۳ آمد: سهم غالب آسیب‌جانی از بخش بالایی توزیع q_i می‌آید، پس یک بودجه‌ی کوچک کافی است و بودجه‌ی بزرگ‌تر بی‌جهت فراموشی را کند می‌کند.

یک جانشین برای معادله‌ی (۸-۳) نیز پیاده‌سازی شده است: انرژی تعارض شیب‌ها^۵

$$q_i^{\text{conf}} = \text{ReLU}(-\nabla_i \mathcal{L}_f \cdot \nabla_i \mathcal{L}_{\text{retain}}), \quad (۱۰-۳)$$

که وزن‌هایی را هدف می‌گیرد که فراموشی و نگهداری در آن‌ها مستقیماً با یکدیگر رقابت می‌کنند. این معیار به شیب وظیفه‌ی هدف نیاز دارد و بنابراین باید پیش از حذف نمونه‌های بازپخش هدف محاسبه شود. این محدودیت، ترتیب گام‌های الگوریتم را تعیین می‌کند. بخش ۲-۱۲-۴ نشان می‌دهد نتیجه‌ی این معیار به مجموعه داده وابسته است؛ از این رو، بزرگی شیب معیار پیش‌فرض باقی می‌ماند.

۳-۳-۳ ترمیم لنگردار

پس از اعمال بازنشانی شاخه‌محور ارثی، نقاب ترمیم اسمی به صورت $M_f \cap M_r$ ساخته می‌شود و حلقه‌ی ترمیم تنها روی همان درایه‌ها گام برمی‌دارد. تابع هدف ترمیم چنین است:

$$\mathcal{L}_{\text{repair}} = \alpha \mathcal{L}_{\text{DER}} + \beta \mathcal{L}_{\text{CE}} + \lambda \sum_{i \in S_{\text{crit}}} (\theta_i - \theta_i^{\text{anchor}})^2. \quad (۱۱-۳)$$

سه جمله سه نقش متفاوت دارند. $\mathcal{L}_{\text{DER}}$ امتیازهای خام ذخیره‌شده را تطبیق می‌دهد و بنابراین رفتار پیشین مدل را باز می‌گرداند [۳۵]. $\mathcal{L}_{\text{CE}}$ از برچسب‌های وظایف نگهداری شده استفاده می‌کند و اطلاعات مستقیم

^۴Protection Ratio

^۵Gradient-Conflict Energy

طبقه‌بندی می‌دهد. جمله‌ی سوم، جمله‌ی لنگر^۶، رانش را روی درایه‌های بحرانی انتخاب‌شده محدود می‌کند. ضریب پیش‌فرض $\lambda = 1$ است.

از نظر شکل ریاضی، جمله‌ی سوم همان قالب EWC [۷] است، اما دو تفاوت اساسی دارد که در بخش ۲-۲-۲ اشاره شد و اینجا صریح می‌شود: دامنه‌ی اعمال آن به S_{crit} محدود است و نه کل پیراسنجه‌ها، و هدف آن مهار یک عملیات حذف است و نه یک عملیات یادگیری.

انتخاب لنگر. دو گزینه برای θ^{anchor} وجود دارد. گزینه‌ی نخست θ^{old} است، یعنی مقدار وزن بلافاصله پیش از درخواست؛ این طبیعی‌ترین انتخاب برای هدف نگه‌داری است اما یک ایراد مفهومی جدی دارد: θ^{old} خودش در آموزش وظیفه‌ی فراموش‌شونده شکل گرفته و بنابراین اطلاعاتی از همان وظیفه حمل می‌کند. لنگرزدن یک عملیات حذف به مرجعی که خودش وابسته به داده‌ی حذف‌شونده است، از نظر مفهومی خودشکن است. گزینه‌ی دوم θ^{reinit} است، نمونه‌ای تازه از توزیع مقدارگذاری اولیه که به‌طور ساختاری از هر داده‌ای مستقل است.

این استدلال مفهومی به‌تنهایی θ^{reinit} را پیشنهاد می‌کند، اما دو نکته این انتخاب را تضعیف می‌کنند. نخست، لنگر فقط روی $S_{crit} \subseteq M_f \cap M_r$ عمل می‌کند، در حالی که فراموشی از راه بازنشانی ناحیه‌ی مخصوص هدف $M_f \setminus M_r$ رخ می‌دهد. بنابراین، لنگر برای حفظ وظیفه‌های دیگر به‌کار می‌رود و نه برای فراموشی؛ کشاندن وزن‌های مشترک به مقادیر تصادفی می‌تواند دانشی را که وظیفه‌های نگه‌داری‌شده در آن وزن‌ها دارند تخریب کند. دوم، θ^{reinit} استقلال کامل از داده را ایجاد نمی‌کند، زیرا شاخه‌های بازنشانی همچنان از پشتیبان‌های تنک وابسته به داده‌های پیشین استفاده می‌کنند. مقایسه‌ی بخش ۴-۱۲-۱ با هشت بذر نیز نشان می‌دهد که پس از اصلاح هولم برای آزمون‌های متعدد، هیچ معیاری از نظر آماری معنادار نیست و نتایج CIFAR-100 از θ^{old} پشتیبانی می‌کنند. بنابراین، θ^{old} در پیاده‌سازی پیش‌فرض استفاده می‌شود و محدودیت مفهومی آن در بخش ۴-۵ توضیح داده می‌شود.

۴-۳-۳ الگوریتم کامل

الگوریتم ۱ کل فرایند پردازش درخواست را نشان می‌دهد. هر کمیت مبتنی بر شیب که به داده‌های وظیفه‌ی هدف نیاز دارد، پیش از حذف نمونه‌های بازپخش آن محاسبه می‌شود. پس از حذف، دیگر دسترسی به داده‌های هدف انجام نمی‌شود.

سه نکته‌ی پیاده‌سازی مهم است. نخست، گام ۲ یک محدودیت الزامی است. یک بررسی خودکار

⁶Anchor

Algorithm 1 EPALL: request-time selective forgetting of task f

Input: weights θ , per-task masks $\{M_t\}$, rehearsal memory $\mathcal{B}$, active tasks $\mathcal{T}_a$, protection ratio ρ , anchor weight λ , repair steps K

Output: updated weights θ' with task f suppressed

- 1: copy M_f ; if conflict scoring is selected, cache its forget gradient while $\mathcal{B}_f$ is available
 - 2: delete $\mathcal{B}_f$; remove M_f from the active mask set $\triangleright$ no target-data access beyond this point
 - 3: $M_r \leftarrow \bigvee_{t \in \mathcal{T}_a} M_t$; $S_{\text{share}} \leftarrow M_f \wedge M_r$
 - 4: $q_i \leftarrow |\nabla_i \mathcal{L}_{\text{retain}}|$ for $i \in S_{\text{share}}$ $\triangleright$ one backward pass on $\mathcal{B}$
 - 5: $S_{\text{crit}} \leftarrow \text{top } \lceil \rho |S_{\text{share}}| \rceil$ coordinates of S_{share} by q_i
 - 6: cache anchors $\theta^{\text{anchor}}|_{S_{\text{crit}}}$ and the sparse retained-task backups the inherited reset branches require
 - 7: apply PALL's branch-dependent target reset/reconstruction
 - 8: $M_{\text{repair}} \leftarrow M_f \wedge M_r$ $\triangleright$ nominal retained-repair mask
 - 9: **for** $k = 1$ **to** K **do**
 - 10: sample retained rehearsal entries from $\mathcal{B}$
 - 11: $\mathcal{L} \leftarrow \alpha \mathcal{L}_{\text{DER}} + \beta \mathcal{L}_{\text{CE}} + \lambda \sum_{i \in S_{\text{crit}}} (\theta_i - \theta_i^{\text{anchor}})^2$
 - 12: backward; zero gradients outside M_{repair} ; optimizer step
 - 13: **end for**
 - 14: rebuild the active union mask; discard request-only target state
 - 15: **return** θ
-

اطمینان می‌دهد که پس از حذف نمونه‌های بازپخش هدف، هیچ دسترسی دوباره‌ای به داده‌های آموزشی یا مجموعه‌ی نگه‌داری‌شده‌ی آن وظیفه انجام نشود. دوم، گام ۶ فقط پشتیبان‌های تنک موردنیاز بازنشانی را ذخیره می‌کند و این پشتیبان‌ها در محاسبه‌ی حافظه‌ی موردنیاز در بخش ۴-۱۰ شمرد می‌شوند. سوم، پس از پایان درخواست، داده‌های موقت آن، از جمله لنگرها و نقاب بایگانی‌شده، کنار گذاشته می‌شوند؛ مگر آنکه اجرا برای ارزیابی برون‌خط انجام شده باشد.

۵-۳-۳ کنترل‌های مؤلفه‌ای

برای اینکه ادعای سازوکاری قابل آزمون باشد، چهار کنترل هم‌تراز پیاده‌سازی شده است که هر یک تنها یک جزء الگوریتم ۱ را عوض می‌کند و بقیه‌ی زمان‌بندی درخواست را دست‌نخورده می‌گذارد:

بدون جریمه‌ی ℓ_2 . $\lambda = 0$. توجه شود که این کنترل محافظت را بر نمی‌دارد: ناحیه‌ی بحرانی همچنان شناسایی می‌شود و پشتیبان‌های تنک آن نیز ساخته می‌شوند؛ تنها جمله‌ی جریمه‌ی ℓ_2 از تابع هدف حذف می‌شود. بنابراین نام درست آن «بدون جریمه‌ی ℓ_2 » است و نه «بدون محافظت»، و آنچه جدا می‌کند سهم شدت مهار است و نه سهم کل سازوکار.

فقط هم‌پوشانی. کل S_{share} محافظت می‌شود، بدون هیچ رتبه‌بندی. این کنترل نشان می‌دهد آیا رتبه‌بندی حساسیت ارزشی افزون بر خود فیلتر ساختاری دارد.

بودجه‌ی تصادفی. همان تعداد درایه‌ی کنترل کامل محافظت می‌شود، اما به‌طور تصادفی یکنواخت از میان S_{share} انتخاب می‌شود. این کنترل، اثر *اندازه‌ی بودجه* را از اثر کیفیت انتخاب جدا می‌کند. توجه شود که نمونه‌گیری از S_{share} انجام می‌شود و نه از M_f ؛ اگر از M_f نمونه گرفته می‌شد، درایه‌های منحصر به هدف در بودجه وارد می‌شدند که شیب‌شان بعداً در ترمیم نقاب می‌شود و در نتیجه بودجه‌ی مؤثر کنترل از کنترل کامل کوچک‌تر می‌شد.

رتبه‌بندی بدون هم‌پوشانی. رتبه‌بندی با همان q_i روی کل زیرشبکه‌ی هدف انجام می‌شود، بدون اعمال صریح فیلتر M_r . این کنترل می‌سنجد که آیا اشتراک صریح اطلاعاتی افزون بر رتبه‌بندی دارد.

نتایج این چهار کنترل در بخش ۴-۶ گزارش می‌شود و — چنان‌که خواهیم دید — یکی از آن‌ها نتیجه‌ای می‌دهد که ساده‌سازی روش را پیشنهاد می‌کند.

۶-۳-۳ تحلیل پیچیدگی

هزینه‌ی افزوده‌ی EPALL نسبت به PALL اصلی سه جزء دارد. جزء اول، محاسبه‌ی q_i است که یک گذر پس‌رو روی حافظه‌ی بازپخش وظایف فعال لازم دارد؛ هزینه‌ی آن $\mathcal{O}(|B| \cdot C_{\text{bwd}})$ است که C_{bwd} هزینه‌ی یک گذر پس‌رو است. چون $|B| = 500$ و ثابت است، این جزء با تعداد وظایف رشد نمی‌کند. جزء دوم، انتخاب $\lceil \rho |S_{\text{share}}| \rceil$ درایه‌ی برتر است که با انتخاب مرتبه‌ای در $\mathcal{O}(|S_{\text{share}}|)$ یا با مرتب‌سازی در $\mathcal{O}(|S_{\text{share}}| \log |S_{\text{share}}|)$ انجام می‌شود و در هر حال از $\mathcal{O}(d)$ فراتر نمی‌رود. جزء سوم، ارزیابی جمله‌ی لنگر در هر گام ترمیم است که $\mathcal{O}(|S_{\text{crit}}|)$ و بنابراین حداکثر $\mathcal{O}(\rho d)$ است.

از نظر حافظه، EPALL علاوه بر نقاب‌های PALL، مقادیر لنگر روی S_{crit} را نگه می‌دارد که $O(\rho|S_{share}|)$ است و پس از پایان درخواست آزاد می‌شود.

مجموع این هزینه‌ها از نظر نظری کوچک است، اما در عمل زمان پردازش درخواست را افزایش می‌دهد؛ زیرا یک گذر پس‌رو اضافه و جمله‌ی لنگر در هر یک از K گام ترمیم محاسبه می‌شوند. بخش ۴-۳ نشان می‌دهد EPALL روی CIFAR-10 حدود ۲/۱ ثانیه و روی CIFAR-100 حدود ۱۲/۱ ثانیه از PALL اصلی کندتر است. این نتیجه، موازنه‌ی میان حفظ بهتر وظیفه‌ها و افزایش زمان پردازش را نشان می‌دهد.

۴-۳ مسیر اکتشافی PALL-Adapter

بخش‌های پیشین روش اصلی را کامل کردند. این بخش مسیر دومی را معرفی می‌کند که برای کاهش دامنه‌ی به‌روزرسانی طراحی شد، اما نتیجه‌ی نهایی آن منفی بود. این مسیر به دو دلیل گزارش می‌شود: طراحی و ارزیابی آن بخشی از پژوهش انجام‌شده است و پنج حالت آزمایشی هم‌تراز آن می‌توانند الگویی برای بررسی اجزای روش‌های مشابه باشند.


۱-۴-۳ معماری

لایه‌های استخراج ویژگی θ_{base} منجمد می‌شوند و تنها سه گروه پیراسنجه آموزش پذیر می‌مانند: یک لایه‌ی تطبیق گلوگاهی مشترک^۷ با پیراسنجه‌های ϕ_s ، یک لایه‌ی تطبیق مخصوص وظیفه^۸ با پیراسنجه‌های ϕ_t به‌ازای هر وظیفه، و یک طبقه‌بند مشترک که از طریق برش سطری مخصوص وظیفه استفاده می‌شود. هر دو لایه‌ی تطبیق، بلوک‌های باقی‌مانده‌ی گلوگاهی استاندارد پس از بدنه با غیرخطیت ReLU هستند [۶۰، ۶۱] و به‌ترتیب اعمال می‌شوند: نخست مشترک، سپس مخصوص وظیفه. شکل ۲-۳ این ساختار را نشان می‌دهد.

مقدارگذاری اولیه‌ی لایه‌های تطبیق به گونه‌ای است که در لحظه‌ی تولد، پیمانۀ تابع همانی باشد: نگاشت کاهش ابعاد از توزیع کایمینگ [۳۱] نمونه می‌گیرد و نگاشت افزایش ابعاد با صفر مقدار می‌گیرد. در نتیجه درج لایه‌ی تطبیق به یک شبکه‌ی آموزش دیده، رفتار آن را در ابتدا تغییر نمی‌دهد.

^۷Shared Bottleneck Adapter

^۸Task-Specific Adapter



شکل ۳-۲: معماری PAL-Adapter. بدنه‌ی استخراج ویژگی منجمد است. جریان اطلاعات از لایه‌ی تطبیق مشترک ϕ_s می‌گذرد، سپس به لایه‌ی تطبیق مخصوص وظیفه‌ی ϕ_t می‌رسد و در پایان از برش سطری متناظر در طبقه‌بند مشترک عبور می‌کند. تنها همین سه گروه در آموزش و در درخواست فراموشی تغییر می‌کنند.

۳-۴-۲ فراموشی سه‌مرحله‌ای

مراحل فراموشی در این مسیر ترتیب مشخصی دارند تا شیب‌های وابسته به هدف پیش از حذف نمونه‌های بازپخش آن محاسبه شوند.

مرحله یک: اندازه‌گیری هم‌پوشانی. شیب‌های قدرمطلق لایه‌ی تطبیق مشترک روی حافظه‌ی هدف و حافظه‌ی نگهداری شده محاسبه می‌شوند و با نسبت‌های آستانه‌ای، دو مجموعه تعریف می‌شود: S_{forget} شامل درایه‌های با بالاترین شیب هدف، و S_{active} شامل درایه‌های با بالاترین شیب نگهداری. اشتراک آن‌ها ناحیه‌ی بحرانی است:

$$S_{\text{crit}} = S_{\text{forget}} \cap S_{\text{active}}, \quad (۱۲-۳)$$

و $[\alpha_p | S_{\text{crit}}]$ درایه‌ی برتر آن بر حسب بزرگی شیب نگهداری، مجموعه‌ی دارای حفاظت سخت^۹ H را می‌سازد. توجه شود که این مجموعه‌ها با مجموعه‌های نقاب‌محور بخش ۳-۳ متفاوت‌اند: آن‌ها از نقاب‌های دودویی ذخیره‌شده می‌آیند و این‌ها از رتبه‌بندی شیب.

^۹Hard-Protected

مرحله دو: بازنشانی هدف و به‌روزرسانی نقاب نرم. لایه‌ی تطبیق مخصوص وظیفه‌ی هدف با همان قاعده‌ی مقدارگذاری اولیه بازنشانی می‌شود و برش طبقه‌بند آن پاک می‌شود. سپس لایه‌ی تطبیق مشترک در جهت رسیدن به توزیع یکنواخت روی کلاس‌های وظیفه‌ی هدف بهینه می‌شود، با این تفاوت که گام هر درایه در یک ضریب مقیاس ضرب می‌شود:

$$m_{\text{soft}}(i) = \begin{cases} 0, & i \in H, \\ 1 - p, & i \in S_{\text{crit}} \setminus H, \\ 1, & i \in S_{\text{forget}} \setminus S_{\text{active}}, \\ 0, & \text{در غیر این صورت,} \end{cases} \quad (13-3)$$

که $p \in [0, 1]$ شدت محافظت است. منطق این چهار حالت روشن است: ناحیه‌ی دارای حفاظت سخت تکان نمی‌خورد؛ باقی ناحیه‌ی بحرانی با ضریب کاهش یافته حرکت می‌کند؛ ناحیه‌ی منحصر به هدف آزادانه به‌روز می‌شود؛ و درایه‌های بیرون S_{forget} اصلاً هدف این مرحله نیستند.

مرحله‌ی سه: صعود طبقه‌بند و ترمیم. برش طبقه‌بند وظیفه‌ی هدف با استفاده از شیب فراموشی محاسبه‌شده پیش از بازنشانی، یک گام صعود از روی شیب انجام می‌دهد. سپس نمونه‌های بازپخش هدف حذف می‌شوند و همه‌ی پیراسنجه‌های آموزش‌پذیر برای چند گام کوتاه روی حافظه‌ی وظیفه‌های نگه‌داری شده ترمیم می‌شوند.

۳-۴-۳ دامنه‌ی واقعی نقاب نرم

نکته‌ی مهمی که پیش از هر تحلیل نظری باید تصریح شود، این است: ضریب m_{soft} تنها جابه‌جایی لایه‌ی تطبیق مشترک را در طول زیرمرحله هدف-یکنواخت کنترل می‌کند. این ضریب یک نقاب محافظت دائمی نیست و دقت نگه‌داری آغاز تا پایان را کران نمی‌زند، چون سه عامل دیگر هم نقطه‌ی پایان را جابه‌جا می‌کنند: بازنشانی لایه‌ی تطبیق هدف، صعود مبتنی بر شیب طبقه‌بند، و ترمیم پایانی که نقاب‌نشته است. علاوه بر این، چون لایه‌ی تطبیق مشترک نهایی تابعی از شیب‌های حافظه‌ی هدف می‌ماند، این مسیر نه فراموشی دقیق است و نه گواهی‌شده از نظر حریم خصوصی.

۵-۳ تحلیل نظری با دامنه‌ی محدود

این بخش یک گزاره‌ی دقیق درباره‌ی همان چیزی اثبات می‌کند که نقاب نرم واقعا کنترل می‌کند: تغییر مخاطره‌ی وظایف فعال در طول زیرمرحله نقاب نرم. سپس بخش ۳-۵-۴ توضیح می‌دهد چرا این گزاره به افت آغاز تا پایان تعمیم نمی‌یابد، و چرا این محدودیت با یافته‌ی تجربی فصل ۴ سازگار است.

۱-۵-۳ نمادگذاری و افراز

در سراسر این تحلیل، بدنه‌ی منجمد θ_{base} و لایه‌های تطبیق مخصوص وظیفه ثابت‌اند؛ پس تنها پیراسنجه‌های متغیر و در نتیجه تنها منبع تداخل میان‌وظیفه‌ای در این زیرمرحله، وزن‌های لایه‌ی تطبیق مشترک $\phi \triangleq \phi_s \in \mathbb{R}^{d_s}$ هستند. $\phi^{(\cdot)}$ مقدار آن در آغاز زیرمرحله و $\phi^{(N)}$ مقدار آن پس از N گام است. به‌روزرسانی هر درایه چنین است:

$$\phi_i^{(k+1)} = \phi_i^{(k)} - \eta m_i g_i^{(k)}, \quad g_i^{(k)} \triangleq \partial_i \mathcal{L}_{\text{unlearn}}(\phi^{(k)}), \quad (14-3)$$

که $m_i = m_{\text{soft}}(i) \in [0, 1]$ در طول N گام ثابت است، چون نقاب یک‌بار در مرحله یک محاسبه می‌شود. مجموعه‌ی اندیس‌ها به چهار ناحیه‌ی مجزا افراز می‌شود:

$$\begin{aligned} \mathcal{F}^o &\triangleq S_{\text{forget}} \setminus S_{\text{active}} & (m_i = 1), \\ \mathcal{S} &\triangleq S_{\text{crit}} \setminus H & (m_i = 1 - p), \\ H &\subseteq S_{\text{crit}} & (m_i = 0), \\ \mathcal{N} &\triangleq \{1, \dots, d_s\} \setminus S_{\text{forget}} & (m_i = 0). \end{aligned} \quad (15-3)$$

تعریف ۱-۳ (مخاطره‌ی نگه‌داری و افت زیرمرحله) برای هر وظیفه‌ی فعال $t \in \mathcal{T}_a$ ، مخاطره‌ی آن را به‌صورت تابعی از لایه‌ی تطبیق مشترک با $R_t(\phi) \triangleq \mathbb{E}_{(x,y) \sim D_t}[\ell(f(x; \phi), y)]$ تعریف می‌کنیم. افتی که مسیر زیرمرحله $\phi^{(\cdot)} \rightarrow \phi^{(N)}$ بر وظیفه‌ی t تحمیل می‌کند برابر $\Delta_t \triangleq R_t(\phi^{(N)}) - R_t(\phi^{(\cdot)})$ است. تأکید می‌شود که Δ_t افت همین زیرمرحله است و نه بیشترین افت گزارش‌شده در فصل ۴.

۲-۵-۳ فرض‌ها

فرض ۱-۳ (همواری مخاطره‌ی نگه‌داری) هر R_t روی پوشش محدب مسیر β -هموار است:

$$\|\nabla R_t(\phi) - \nabla R_t(\phi')\|_2 \leq \beta \|\phi - \phi'\|_2$$

فرض ۲-۳ (کران داری شیب‌های فراموشی) $|g_i^{(k)}| \leq G$ به‌طور یکنواخت روی مسیر؛ در نتیجه جابه‌جایی انباشته‌ی هر درایه از $NG \Gamma_i \triangleq |\sum_{k=\bullet}^{N-1} g_i^{(k)}| \leq NG$ پیروی می‌کند.

فرض ۳-۳ (تمرکز حساسیت نگه‌داری روی ناحیه‌ی مشترک) $\epsilon \geq 0$ وجود دارد که $|\partial_i R_t(\phi^{(\bullet)})| \leq \epsilon$ برای هر $i \in \mathcal{F}^\circ$ و هر $t \in \mathcal{T}_a$.

فرض ۳-۳ یک فرض اضافی درباره‌ی تک‌تک مخاطره‌های نگه‌داری است و از قاعده‌ی انتخاب الگوریتم به‌تنهایی نتیجه نمی‌شود. الگوریتم درایه‌ها را با بزرگی شیب تجمیعی وظایف نگه‌داری رتبه‌بندی می‌کند؛ در نتیجه، خنثی‌شدن شیب‌های وظایف مختلف می‌تواند یک درایه با مشتق بزرگ برای یک وظیفه‌ی منفرد را بیرون مجموعه‌ی انتخابی نگه دارد. بنابراین لم بعدی مشروط به برقرار بودن این تمرکز است و اگر کوچک‌ترین ϵ معتبر بزرگ باشد، کران می‌تواند بی‌فایده شود.

۳-۵-۳ کران بالای افت زیرمرحله و یکنوایی آن نسبت به p

لم ۴-۳ (کران بالای افت زیرمرحله) فرض‌های ۱-۳ تا ۳-۳ را برقرار بگیرید و $\eta > 0$ و N را ثابت کنید. برای هر وظیفه‌ی فعال t ، انرژی تداخل بحرانی^{۱۰} را چنین تعریف کنید:

$$E_t^{\text{crit}} \triangleq \eta \sum_{i \in \mathcal{S}_{\text{crit}}} |\partial_i R_t(\phi^{(\bullet)})| \Gamma_i, \quad (16-3)$$

و انرژی پس‌مانده‌ی منحصر به هدف را $C_t \triangleq \eta \sum_{i \in \mathcal{F}^\circ} \Gamma_i$. آنگاه به‌روزرسانی نقاب نرم با شدت محافظت p در کران زیر صدق می‌کند:

$$\Delta_t^{\text{soft}} \leq (1-p) E_t^{\text{crit}} + \epsilon C_t + \frac{\beta}{\gamma} \eta^\gamma N^\gamma G^\gamma (|\mathcal{F}^\circ| + (1-p)|\mathcal{S}|), \quad (17-3)$$

حال آنکه به‌روزرسانی بی‌قید ($m_i = 1$ روی کل $\mathcal{S}_{\text{forget}}$) از کران زیر پیروی می‌کند:

$$\Delta_t^{\text{unc}} \leq E_t^{\text{crit}} + \epsilon C_t + \frac{\beta}{\gamma} \eta^\gamma N^\gamma G^\gamma |\mathcal{S}_{\text{forget}}|. \quad (18-3)$$

سمت راست (۱۷-۳) را کران جانشین می‌نامیم و با $B_t(p)$ نشان می‌دهیم.

اثبات. وظیفه‌ی فعال t را ثابت می‌گیریم و جابه‌جایی کل لایه‌ی تطبیق مشترک را $\delta \triangleq \phi^{(N)} - \phi^{(\bullet)}$ می‌نامیم. با جمع‌بستن (۱۴-۳) روی N گام و ثابت‌بودن m_i :

$$\delta_i = -\eta m_i \sum_{k=\bullet}^{N-1} g_i^{(k)} \implies |\delta_i| \leq \eta m_i \Gamma_i \leq \eta m_i NG, \quad (19-3)$$

¹⁰Critical Interference Energy

که از نابرابری مثلثی و فرض ۲-۳ می‌آید.

گام ۱ (بسط همواری). طبق فرض ۱-۳، کران بالای درجه دوم زیر را در نقطه‌ی پایه‌ی $\phi^{(\cdot)}$ می‌پذیرد:

$$\Delta_t \leq \langle \nabla R_t(\phi^{(\cdot)}), \delta \rangle + \frac{\beta}{4} \|\delta\|_2^2. \quad (20-3)$$

گام ۲ (جمله‌ی مرتبه‌ی اول). با افراز (۱۵-۳) و نابرابری مثلثی:

$$\begin{aligned} \langle \nabla R_t, \delta \rangle &\leq \sum_{i=1}^{d_s} |\partial_i R_t| |\delta_i| \\ &\leq \underbrace{\sum_{i \in \mathcal{F}^o} |\partial_i R_t| \eta \Gamma_i}_{m_i=1} + \underbrace{\sum_{i \in \mathcal{S}} |\partial_i R_t| (1-p) \eta \Gamma_i}_{m_i=1-p} + \underbrace{\sum_{i \in H \cup \mathcal{N}} |\partial_i R_t| \cdot 0}_{m_i=0}. \end{aligned} \quad (21-3)$$

جمله‌ی سوم به‌طور همانی صفر است. جمله‌ی نخست طبق فرض ۳-۳ حداکثر $\epsilon \eta \sum_{i \in \mathcal{F}^o} \Gamma_i = \epsilon C_t$ است. جمله‌ی دوم، چون $\mathcal{S} \subseteq S_{\text{crit}}$ و همه‌ی جملاتش نامنفی‌اند، حداکثر $(1-p) E_t^{\text{crit}}$ است. پس

$$\langle \nabla R_t, \delta \rangle \leq (1-p) E_t^{\text{crit}} + \epsilon C_t. \quad (22-3)$$

گام ۳ (جمله‌ی مرتبه‌ی دوم). از (۱۹-۳)، $|\delta_i|^2 \leq \eta^2 m_i^2 N^2 G^2$ ، و چون $m_i^2 = 1$ روی $\mathcal{F}^o$ ، $m_i^2 = (1-p)^2$ روی $\mathcal{S}$ ، و $m_i = 0$ در دو ناحیه‌ی دیگر:

$$\frac{\beta}{4} \|\delta\|_2^2 \leq \frac{\beta}{4} \eta^2 N^2 G^2 (|\mathcal{F}^o| + (1-p)^2 |\mathcal{S}|). \quad (23-3)$$

جای‌گذاری (۲۲-۳) و (۲۳-۳) در (۲۰-۳)، کران (۱۷-۳) را می‌دهد.

گام ۴ (خط پایه‌ی بی‌قید). برای به‌روزرسانی بی‌قید، $m_i = 1$ روی $S_{\text{forget}} = \mathcal{F}^o \cup S_{\text{crit}}$ و $m_i = 0$ روی $\mathcal{N}$. تکرار گام‌های ۲ و ۳ با این ضرب‌گرها، جمله‌ی بحرانی را بدون مقیاس‌دهی و جمله‌ی انحنا را برابر $\frac{\beta}{4} \eta^2 N^2 G^2 |S_{\text{forget}}|$ می‌دهد؛ یعنی دقیقاً (۱۸-۳).

□


نتیجه‌ی ۵-۳ (یکنوایی کران جانشین نسبت به شدت محافظت) کران جانشین $B_t(p) = (1 - \dots)$ روی $p \in [0, 1]$ مشتق‌پذیر و ناافزاینده است:

$$\frac{dB_t}{dp} = -E_t^{\text{crit}} - \beta \eta^2 N^2 G^2 |\mathcal{S}| (1-p) \leq 0. \quad (24-3)$$

پس با بزرگ‌شدن p کران کوچک‌تر می‌شود و نرخ کاهش آن دست‌کم E_t^{crit} است. در $p = 1$ — یا هم‌ارز، با گسترش H تا پوشش کل S_{crit} — سهم ناحیه‌ی بحرانی از کران کاملاً حذف می‌شود و تنها ϵC_t و جمله‌ی انحنای محدود به $\mathcal{F}^o$ باقی می‌ماند. افزون بر این $B_t(\cdot) \leq B_t^{\text{unc}}$ ، با تساوی دقیقاً وقتی $H = \emptyset$.

مشاهده‌ی ۳-۶ (آنچه از این کران نتیجه نمی‌شود) از $B_t(p)$ و $\Delta_t^{\text{soft}} \leq B_t(p)$ و $\Delta_t^{\text{unc}} \leq B_t(p)$ و $\Delta_t^{\text{unc}} \leq B_t(p)$ مقایسه‌ی دو کران بالا هیچ رابطه‌ای میان دو مقدار واقعی برقرار نمی‌کند: هر دو مقدار می‌توانند به اندازه‌ی دلخواه از کران خود پایین‌تر باشند و ترتیشان وارونه‌ی ترتیب کران‌ها شود. بنابراین ادعای این بخش تنها درباره‌ی کران بالای نظری است و نه درباره‌ی افت واقعی.

شکل ۳-۳ نشان می‌دهد که این کران جانشین با افزایش p بزرگ‌تر نمی‌شود. با این حال، کران (۳-۱۷) را نمی‌توان با گزارش‌های اجرا به‌طور مستقیم اعتبارسنجی کرد، زیرا طرف راست کران بر حسب مخاطره و افت اندازه‌گیری شده بر حسب دقت است و ثابت‌های ϵ و β نیز واسنجی نشده‌اند. از این رو، حتی مشاهده‌ی همبستگی رتبه‌ای میان این دو کمیت نیز اعتبار کران را تأیید نمی‌کند؛ بنابراین هیچ ادعایی در این پایان‌نامه بر پایه‌ی چنین مقایسه‌ای بنا نشده است.



شکل ۳-۳: کران بالای B_t افت یک وظیفه‌ی فعال در زیرمرحله نقاب نرم، بر حسب شدت محافظت p . مطابق نتیجه‌ی ۳-۵، مشتق dB_t/dp در سراسر بازه نامثبت است، پس کران هرگز افزایش نمی‌یابد؛ چون قدر مطلق شیب با بزرگ‌شدن p کاهش می‌یابد، منحنی نزولی و محدب است. محورها واسنجی نشده‌اند و شکل تنها جهت را نشان می‌دهد. تأکید می‌شود که این گزاره درباره‌ی کران است و نه درباره‌ی افت واقعی؛ مشاهده‌ی ۳-۶ همین تمایز را تصریح می‌کند.

۳-۵-۴ چرا این کران، افت آغاز تا پایان را کران نمی زند

لم ۳-۴ درست است، اما دامنه‌ی آن باریک است و این محدودیت دامنه باید صریح بماند. سه شکاف میان Δ_t در تعریف ۱-۳ و بیشترین افت گزارش شده در فصل ۴ وجود دارد:

۱. بازنشانی پیش از زیرمرحله. لایه‌ی تطبیق مخصوص وظیفه‌ی هدف و برش طبقه‌بند آن پیش از شروع زیرمرحله نقاب نرم بازنشانی می‌شوند. این جابه‌جایی در $\phi^{(*)}$ گنجانده شده است، پس تحلیل درباره‌ی اثر آن هیچ نمی‌گوید — در حالی که همان اثر می‌تواند بخش عمده‌ی تغییر نقطه‌ی پایان باشد.

۲. صعود طبقه‌بند. گام صعود مبتنی بر شیب روی برش طبقه‌بند هدف، بیرون از فضای ϕ_s عمل می‌کند و نقاب نرم آن را نمی‌بیند.

۳. ترمیم نقاب نشده. مرحله سه همه‌ی پیراسنجه‌های آموزش‌پذیر — از جمله درایه‌های H — را روی حافظه‌ی وظایف نگه‌داری شده به‌روز می‌کند. بنابراین حتی درایه‌هایی که در زیرمرحله قبل قفل بودند، در نقطه‌ی پایان جابه‌جا شده‌اند.

نتیجه‌ی این سه شکاف آن است که یکنوایی کران جانشین نسبت به p هیچ تضمینی روی معیار گزارش شده نمی‌سازد. به همین دلیل، این پایان‌نامه لم ۳-۴ را به‌عنوان توضیح سازوکار زیرمرحله ارائه می‌کند و نه به‌عنوان پشتوانه‌ی نظری برای نتایج تجربی، و اثر واقعی نقاب نرم را با کنترل‌های مؤلفه‌ای می‌سنجد. بخش ۴-۸ نشان می‌دهد آن کنترل‌ها هیچ سود قابل‌اندازه‌گیری برای نقاب نرم در نقطه‌ی پایان پیدا نمی‌کنند و سرکوب مشاهده‌شده را به بازنشانی مسیر هدف نسبت می‌دهند. این هم‌نشینی — یک کران درست با دامنه‌ی باریک، در کنار یک نتیجه‌ی تجربی منفی برای دامنه‌ی وسیع — تعارض نیست؛ دقیقاً همان چیزی است که از تفکیک دقیق دامنه‌ها انتظار می‌رود.

۳-۶ ضوابط دسترسی به داده

هر دو مسیر پیشنهادی یک محدودیت مشترک دارند. همه‌ی کمیت‌های مبتنی بر شیب که به داده‌های وظیفه‌ی هدف نیاز دارند، پیش از حذف نمونه‌های بازپخش آن محاسبه و ذخیره می‌شوند. پس از این مرحله، دسترسی تازه‌ای به داده‌های هدف انجام نمی‌شود. بررسی‌های خودکار این محدودیت را در ابتدا و انتهای بازه‌ی دسترسی کنترل می‌کنند و در صورت نقض آن، اجرا متوقف می‌شود.

فقط نمونه‌های وظیفه‌ی هدف از حافظه‌ی بازپخش مدل حذف می‌شوند. داده‌های خام روی دیسک، نقاط واری، نسخه‌های پشتیبان و نسخه‌های بیرونی در دامنه‌ی این فرایند نیستند. بودجه‌ی بازپخش نیز دوباره توزیع نمی‌شود؛ سهم آزادشده‌ی وظیفه‌ی حذف‌شده به وظیفه‌های باقی‌مانده اختصاص نمی‌یابد تا افزایش ظرفیت حافظه با اثر روش فراموشی اشتباه گرفته نشود.

۷-۳ دیدگاه یکپارچه و جمع‌بندی فصل

دو مسیر این فصل، دو شیوه‌ی اجرای یک ایده‌ی واحدند: ناحیه‌ی مشترک را بشناس، درون آن درایه‌های حساس به نگه‌داری را جدا کن، و تنها همان‌ها را مهار کن. تفاوت‌ها در سه محور است. محور اول، تعریف ناحیه‌ی مشترک: در EPALL این ناحیه اشتراک دقیق دو نقاب دودویی ذخیره‌شده است، در حالی که در PALL-Adapter از اشتراک دو مجموعه‌ی رتبه‌بندی‌شده‌ی مبتنی بر شیب می‌آید و بنابراین به آستانه‌ها حساس است. محور دوم، شکل مهار: EPALL یک جمله‌ی جریمه‌ی ℓ_2 در تابع هدف ترمیم به کار می‌برد که در طول کل حلقه‌ی ترمیم فعال است، در حالی که PALL-Adapter یک ضریب مقیاس روی گام به کار می‌برد که تنها در یک زیرمرحله فعال است. محور سوم، دامنه‌ی پیراسنجه‌ها: EPALL روی کل ظرفیت شبکه عمل می‌کند و PALL-Adapter روی پیمان‌های کوچک در یک بدنه‌ی منجمد.

همان‌طور که فصل بعد نشان می‌دهد، دو تفاوت نخست تعیین‌کننده‌اند. محافظت پایدار از یک ناحیه‌ی دقیق مؤثر است، اما مقیاس‌دهی موقت روی یک ناحیه‌ی تقریبی نتیجه‌ی نهایی را تغییر نمی‌دهد. بر پایه‌ی این نتیجه، EPALL روش اصلی پایان‌نامه است و PALL-Adapter فقط به عنوان یک گزینه‌ی اکتشافی و ارزیابی‌شده گزارش می‌شود.

فصل ۴

آزمایش‌ها و نتایج

این فصل روش‌های فصل ۳ را به‌طور تجربی ارزیابی می‌کند. نتایج بر پایه‌ی پرسش‌های پژوهش بخش ۴-۱ ارائه می‌شوند: ابتدا مقایسه‌ی اصلی و تحلیل جفتی آن (RQ1 و RQ2)، سپس آزمون موقعیت درخواست (RQ3) و بررسی اجزای هر دو روش (RQ4 و RQ5)، و در پایان محاسبه‌ی هزینه، ارزیابی حریم خصوصی و بررسی حساسیت.

یک قاعده‌ی گزارش‌دهی در سراسر فصل رعایت می‌شود: هر جدول تعداد بذرها را مشخص می‌کند، هیچ سلولی رتبه‌بندی نمی‌شود مگر آنکه معیار به‌تنهایی قابل تفسیر باشد، و نتایج با کمتر از پنج بذر صریحا توصیفی برچسب می‌خورند. مسیر بازتولید خروجی‌های تجمیعی و برچسب‌های آزمایش در پیوست مستند شده است.

۴-۱ طراحی آزمایش

۴-۱-۱ مجموعه داده‌های ارزیابی و تقسیم وظیفه‌ها

سه مجموعه داده‌ی عمومی به کار می‌روند. این مجموعه داده‌ها به گونه‌ای به وظیفه‌ها تقسیم می‌شوند که تعداد وظیفه و دشواری بازنمایی به تدریج افزایش یابد.

- CIFAR-10 [۷۴] به صورت ۵ وظیفه‌ی دو کلاسه؛ سطح تصادفی ۰/۵.
- CIFAR-100 [۷۴] در طرح آزمایشی هم پوشانی سنگین به صورت ۱۰ وظیفه‌ی پنج کلاسه (سطح تصادفی ۰/۲) و در طرح آزمایشی استاندارد به صورت وظیفه‌های ده کلاسه (سطح تصادفی ۰/۱).

• TinyImageNet [۷۵] به صورت ۲۰ وظیفه‌ی ده کلاس؛ سطح تصادفی ۰/۱.

۴-۱-۲ سه طرح آزمایشی مجزا

نکته‌ی روش شناختی مهم این است که آزمایش‌ها در سه طرح آزمایشی مجزا اجرا شده‌اند و نتایج آن‌ها با یکدیگر مخلوط نمی‌شوند. تنها استثنا بررسی تنگی بخش ۴-۵ است که افراز و دنباله‌ی طرح آزمایشی استاندارد را با بودجه‌ی ۳ دوره ترکیب می‌کند؛ همان‌جا تصریح شده که اعداد آن تنها درون خود جدول قابل مقایسه‌اند. سه طرح آزمایشی چنین‌اند:

طرح آزمایشی استاندارد. ۲۰ دوره به‌ازای هر وظیفه، بدنه‌ی آموزش دیده از صفر، هشت بذر $\{0, \dots, 7\}$. این طرح آزمایشی، مبنای مقایسه‌ی اصلی بخش ۴-۳ است.

طرح آزمایشی هم‌پوشانی سنگین. ۳ دوره به‌ازای هر وظیفه و افراز پنج‌کلاسه‌ی CIFAR-100. این طرح آزمایشی عمداً هم‌پوشانی بیشتری بین زیرشبکه‌ها ایجاد می‌کند و برای کنترل‌های مؤلفه‌ای EPALL و مقایسه‌ی سه نسخه‌ی PAL به کار می‌رود.

طرح آزمایشی پیش‌آموزش دیده. بدنه‌ی ImageNet [۷۶] منجمد. این طرح آزمایشی، فرض طبیعی روش‌های کم‌پیراسنجه را برقرار می‌کند و برای مقایسه‌ی LoRA و PAL-Adapter استفاده می‌شود.

در هر سه طرح آزمایشی، دنباله‌ی درخواست‌ها هر وظیفه را حداکثر یک‌بار آموزش می‌دهد، سه درخواست فراموشی دارد، و هیچ وظیفه‌ی حذف‌شده‌ای را دوباره معرفی نمی‌کند. درون هر بذر، همه‌ی روش‌ها دنباله‌ی درخواست یکسانی می‌بینند؛ همین جفت‌شدگی است که تحلیل جفتی بخش ۴-۳-۲ را ممکن می‌کند.

۴-۱-۳ معماری‌ها و ابرپیراسنجه‌ها

به‌جز آزمون ViT، اجراهای CIFAR-10، TinyImageNet و پیش‌آموزش دیده از نسخه‌های ResNet-18 و اجراهای اصلی CIFAR-100 از نسخه‌های ResNet-34 استفاده می‌کنند [۲۹]. بهینه‌ساز SGD [۲۵] با نرخ یادگیری ۰/۰۱، تکانه‌ی ۰/۹، تنظیم وزن $10^{-4} \times 5$ و اندازه‌ی دسته‌ی ۳۲ است. بودجه‌ی بازپخش ۵۰۰ نمونه و از پیش میان وظایف افراز می‌شود، بدون بازتوزیع پس از حذف. تنها استثنا، LoRA روی Split-CIFAR-100 است که نرخ یادگیری 10^{-3} می‌گیرد، چون با 10^{-2} واگرا می‌شود.

پیکربندی روش‌های پیشنهادی چنین است. EPALL: نسبت محافظت $\rho = 0.2$ و ضریب لنگر $\lambda = 1$. PALL-Adapter: گلوگاه وظیفه و گلوگاه مشترک ۱۶، $\alpha_p = 0.2$ ، $\alpha_f = 0.3$ ، $p = |S_{\text{crit}}|/|S_{\text{forget}}|$ ، رتبه‌ی LoRA برابر ۸. تنکی زیرشبکه ۰/۸ روی CIFAR-10 و TinyImageNet و ۰/۹ روی CIFAR-100 است. پیکربندی کامل آزمایش‌ها در جدول ۵-۱ در پیوست آمده است.

۴-۱-۴ بذرها و سخت‌افزار

مقایسه‌ی اصلی، حالت‌های آزمایشی مستقیم EPALL و تحلیل لنگر از بذرها $\{0, \dots, 7\}$ استفاده می‌کنند. جدول‌های پیش‌آموزش دیده، هم‌پوشانی زیاد و اجزای لایه‌ی تطبیق بر پایه‌ی بذرها $\{0, 1, 2\}$ هستند و تحلیل معیار اهمیت، ViT و ماندگاری از بذرها $\{0, 1\}$ استفاده می‌کنند. آزمون موقعیت درخواست و بررسی تنکی زیرشبکه هر دو پنج بذر $\{0, \dots, 4\}$ دارند و بررسی شدت نقاب پیوسته با سه بذر انجام شده است. مرجع بازآموزی با دو بذر ارزیابی شده است. ارزیابی اصلاح‌شده‌ی MIA برای EPALL سه بذر و برای PALL اصلی دو بذر دارد. حافظه نیز روی یک دنباله‌ی هم‌تراز محاسبه شده است. بررسی عرض گلوگاه با دو بذر فقط برای نشان‌دادن نبود روند یکنواخت به کار می‌رود. پیکربندی سخت‌افزاری و نرم‌افزاری اجراها، نسخه‌ی مخزن و درهم‌سازی دنباله‌های درخواست در پیوست آمده‌اند.

۴-۲ معیارهای ارزیابی

دقت نهایی نگه‌داری A_{final} (بیشتر بهتر). میانگین دقت روی وظایف فعال در پایان دنباله.

فراموشی میانگین F_{avg} (کمتر بهتر). برای درخواست r :

$$F_{\text{avg}}(r) = \frac{1}{|\mathcal{T}_{\text{trained}}|} \sum_t \left[\max_{k < r} A_t(k) - A_t(r) \right]. \quad (1-4)$$

این معیار روی همه‌ی وظایفی محاسبه می‌شود که تا لحظه‌ی r آموزش دیده‌اند، از جمله وظایفی که بعداً حذف شده‌اند. به همین دلیل F_{avg} وضعیت کل مسیر یادگیری پیوسته را می‌سنجد و نه اثر یک درخواست مشخص را؛ برای سنجش اثر یک درخواست از دو معیار بعدی استفاده می‌شود.

افت نگهداری F_u و بیشترین افت (کمتر بهتر). F_u اختلاف میانگین دقت وظایف نگهداری شده پیش و پس از یک درخواست است، و

$$\text{WorstDrop} = \max_{t \in T_a} (A_t^{\text{before}} - A_t^{\text{after}}). \quad (2-4)$$

این معیار علامت‌دار گزارش می‌شود و در صفر بریده نمی‌شود؛ بنابراین مقدار منفی به این معنا است که ترمیم، بدترین وظیفه را بهبود داده است و این اطلاعات با بریدن از دست می‌رفت.

دقت وظیفه‌ی فراموش شده A_u . بی‌درنگ پس از درخواست اندازه‌گیری می‌شود و همیشه از طریق $|A_u - c|$ خوانده می‌شود که c سطح تصادفی همان وظیفه است. تأکید می‌شود که این معیار «کمتر بهتر» نیست.

زمان درخواست T_f و نسبت دامنه‌ی ترمیم R_{upd} . زمان پردازش درخواست است و با `time.perf_counter` اندازه‌گیری می‌شود. چون فراخوانی‌های CUDA ناهم‌گام‌اند و پیش از خواندن ساعت `torch.cuda.synchronize` اجرا نمی‌شود، این مقدار ممکن است همه‌ی کارهای قرارگرفته در صف را در بر نگیرد. بنابراین، T_f فقط برای مقایسه‌ی تقریبی روش‌ها روی همین محیط اجرا مناسب است و زمان دقیق محاسبه را نشان نمی‌دهد. R_{upd} فقط نسبت اسمی پیراسنجه‌های آموزش‌پذیر در نقاب ترمیم را نشان می‌دهد و کل محاسبات، حافظه، زمان اجرا یا تعداد واقعی وزن‌های تغییریافته را اندازه نمی‌گیرد. به همین دلیل، بخش ۴-۱۰ حافظه‌ی موردنیاز را جداگانه محاسبه می‌کند. جدول‌ها بر پایه‌ی آخرین رویداد فراموشی هر اجرا تهیه شده‌اند و میانگین و انحراف معیار نمونه‌ای روی بذرها گزارش می‌شوند.

۳-۴ مقایسه‌ی اصلی استاندارد

جدول‌های ۴-۱ و ۴-۲ مقایسه‌ی اصلی این پایان‌نامه‌اند. در این مقایسه، یازده روش با هشت بذریابی می‌شوند و درون هر بذریک دنباله‌ی درخواست مشترک دارند. سطرها بر اساس فرض عملیاتی گروه‌بندی شده‌اند و نه بر اساس عملکرد، چون مقایسه‌ی مستقیم روشی که یک شبکه به‌ازای هر وظیفه نگه می‌دارد با روشی که یک مدل مشترک دارد، بی‌معنا است. SSD و SalUn از تجمیع اجراهای همان طرح آزمایشی می‌آیند؛ اجراهای تک‌بذری تنظیم SSD در این مقایسه وارد نشده‌اند.

جدول ۴-۱: مقایسه‌ی هم‌تراز روی Split-CIFAR-10 استاندارد؛ ۲۰ دوره به‌ازای هر وظیفه، هشت بذر، و درون هر بذر دنباله‌ی درخواست مشترک. سطرها بر اساس فرض عملیاتی گروه‌بندی شده‌اند و نام روش‌های این پایان‌نامه پررنگ است. هیچ سلول عددی رتبه‌بندی نشده، چون معیارها باید هم‌زمان خوانده شوند. سطح تصادفی دقت هدف ۰/۵ است. [†]سطرهای PEFT در این طرح آزمایشی روی بدنه‌ی منجمد با مقدارگذاری تصادفی می‌نشینند؛ وضعیت آزمایشی موردنظر آن‌ها در جدول ۴-۱۰ است.

خانواده	روش	دقت نهایی ↑	فراموشی ↓	بیشترین افت ↓	دقت هدف ۰/۵ → زمان (ث) ↓
جداسازی	CLPU	0.9500 ± 0.0169	0.2803 ± 0.0266	0.0000 ± 0.0000	0.5041 ± 0.0152
	DER++	0.8891 ± 0.0449	0.2773 ± 0.0535	0.0002 ± 0.0113	0.5937 ± 0.1343
	ER	0.8679 ± 0.0464	0.3022 ± 0.0471	0.0253 ± 0.0317	0.4918 ± 0.0521
یادگیری پیوسته	EWC	0.7258 ± 0.1421	0.2912 ± 0.0983	0.0000 ± 0.0000	0.8122 ± 0.2102
	LwF	0.9168 ± 0.0317	0.0781 ± 0.0448	0.0000 ± 0.0000	0.9469 ± 0.0280
یادگیری زدایی	SSD	0.8639 ± 0.0614	0.1814 ± 0.0938	0.0126 ± 0.0148	0.8453 ± 0.1589
	SalUn	0.8555 ± 0.0473	0.3168 ± 0.0527	0.0291 ± 0.0443	0.5039 ± 0.0986
	PALL	0.9346 ± 0.0218	0.2855 ± 0.0253	0.0119 ± 0.0104	0.4960 ± 0.0278
PALL کامل	EPALL	0.9433 ± 0.0160	0.2872 ± 0.0249	0.0027 ± 0.0031	0.4863 ± 0.0216
	LoRA [†]	0.7285 ± 0.0730	0.1539 ± 0.0457	0.0219 ± 0.0216	0.4936 ± 0.0132
[†] PEFT	PALL-Adapter [†]	0.7222 ± 0.0715	0.1556 ± 0.0428	0.0117 ± 0.0162	0.5097 ± 0.0349

جدول ۴-۲: مقایسه‌ی هم‌تراز روی Split-CIFAR-100 استاندارد؛ ۲۰ دوره به‌ازای هر وظیفه، هشت بذر، و درون هر بذر دنباله‌ی درخواست مشترک. سطح تصادفی دقت هدف ۰/۱ است. سایر نمادها مانند جدول ۴-۱.

خانواده	روش	دقت نهایی ↑	فراموشی ↓	بیشترین افت ↓	دقت هدف ۰/۱ → زمان (ث) ↓
جداسازی	CLPU	0.7355 ± 0.0069	0.1935 ± 0.0151	0.0000 ± 0.0000	0.1047 ± 0.0107
	DER++	0.6532 ± 0.0308	0.2459 ± 0.0209	0.0341 ± 0.0145	0.3443 ± 0.1913
	ER	0.5923 ± 0.0389	0.2797 ± 0.0277	0.0515 ± 0.0309	0.3956 ± 0.1079
یادگیری پیوسته	EWC	0.4359 ± 0.0522	0.3939 ± 0.0247	0.0000 ± 0.0000	0.4954 ± 0.2044
	LwF	0.6661 ± 0.0333	0.1540 ± 0.0152	0.0000 ± 0.0000	0.7132 ± 0.1180
	SSD	0.4529 ± 0.2101	0.4340 ± 0.1566	0.0295 ± 0.0365	0.2619 ± 0.0801
یادگیری‌زدایی	SalUn	0.5892 ± 0.0480	0.2869 ± 0.0270	0.0583 ± 0.0407	0.3967 ± 0.1222
	PALL	0.7223 ± 0.0168	0.2068 ± 0.0144	0.0222 ± 0.0138	0.1023 ± 0.0040
PALL کامل	EPALL	0.7371 ± 0.0093	0.1958 ± 0.0121	0.0056 ± 0.0062	0.0959 ± 0.0075
	LoRA [†]	0.2695 ± 0.0163	0.0652 ± 0.0128	0.0310 ± 0.0174	0.1042 ± 0.0095
[†] PEFT	PALL-Adapter [†]	0.2583 ± 0.0208	0.0755 ± 0.0080	0.0373 ± 0.0227	0.1061 ± 0.0072

۴-۳-۱ تفسیر نتایج اصلی


CLPU قوی‌ترین نتیجه را دارد و ادعای برتری بر آن مطرح نمی‌شود. پیاده‌سازی ارزیابی‌شده برای هر وظیفه‌ی فعال یک شبکه‌ی کامل نگه می‌دارد و فراموشی را با کنارگذاشتن شبکه‌ی همان وظیفه انجام می‌دهد. بنابراین، زمان درخواست کمتر از یک میلی‌ثانیه فقط هزینه‌ی حذف آن شبکه از ساختار داده را نشان می‌دهد و هزینه‌ی نگه‌داری شبکه‌های جداگانه را در بر نمی‌گیرد. CLPU در صورت پذیرفتنی بودن این جداسازی گزینه‌ی مناسبی است، اما از یک مدل مشترک استفاده نمی‌کند. بخش ۴-۱۰ حافظه‌ی موردنیاز آن را گزارش می‌کند.

میان روش‌های مدل‌مشترک، EPALL به مرجع جداسازی نزدیک می‌شود. روی CIFAR-10 فاصله‌ی A_{final} آن از CLPU کمتر از یک واحد درصد است (۰/۹۴۳۳ در برابر ۰/۹۵۰۰) و روی CIFAR-100 دو مقدار از نظر عددی نزدیک‌اند (۰/۷۳۷۱ در برابر ۰/۷۳۵۵). این نزدیکی نه برتری است و نه هم‌ارزی اثبات‌شده: اختلاف نسبت به پراکندگی بذرهای کوچک است و هیچ آزمون هم‌ارزی برای آن اجرا نشده است. هم‌زمان A_u را به سطح تصادفی می‌رساند (۰/۴۸۶۳ و ۰/۰۹۵۹) و بیشترین افت را در ۰/۰۰۲۷ و ۰/۰۰۵۶ نگه می‌دارد. بنابراین بدون دادن یک شبکه‌ی کامل به هر وظیفه، عملاً به همان نقطه می‌رسد.


ستون A_u روش‌های حفظ‌محور را رد می‌کند. EWC و LwF روی CIFAR-10 بیشترین افت صفر ثبت می‌کنند — که در نگاه اول عالی است — اما A_u آن‌ها $0/8122$ و $0/9469$ است؛ یعنی وظیفه‌ی هدف عملاً حذف نشده و بخش عمده‌ی رفتار آن حفظ شده است. به همین ترتیب، SSD روی CIFAR-10 با $A_u = 0/8453$ می‌ماند و هر دو روش SSD و SalUn روی CIFAR-100 با $0/2619$ و $0/3967$ به‌روشنی بالای هدف $0/1$ باقی می‌مانند. این دقیقاً نمونه‌ای است که چرا معیارها باید هم‌زمان خوانده شوند: هیچ‌یک از این دو ستون به‌تنهایی داوری درستی نمی‌دهد.

دو سطر PEFT تشخیصی‌اند و رقیب هم‌ظرفیت نیستند. در این طرح آزمایشی از صفر، هم LoRA و هم PALL-Adapter روی یک ResNet منجمد با مقدارگذاری تصادفی نشسته‌اند. دقت CIFAR-100 آن‌ها به‌طور مشابه پایین است ($0/2695$ و $0/2583$) به‌رغم آنکه سازوکار فراموشی‌شان متفاوت است، و هر دو با پیش‌آموزش دیده‌شدن بدنه بازیابی می‌شوند (جدول ۴-۱۰). این الگو به یک گلوگاه بازنمایی اشاره می‌کند و نه به گام فراموشی.


شکل ۴-۱ دقت نهایی نگه‌داری، شکل ۴-۲ بیشترین افت و شکل ۴-۳ دقت وظیفه‌ی فراموش شده را برای هر سه مجموعه داده و هر وضعیت آزمایشی موجود نشان می‌دهند. جداسازی هر معیار در یک صفحه‌ی افقی، خوانایی برجسته‌ها و بازه‌های اطمینان را در نسخه‌ی چاپی حفظ می‌کند.



شکل ۴-۱: دقت نهایی به تفکیک مجموعه داده و وضعیت آزمایشی. وضعیت‌های آزمایشی تجمیع نشده‌اند؛ میله‌ها میانگین جدول و خطاها بازه‌ی باز نمونه‌گیری ۹۵ درصد بذره‌ای اجرای کامل شده هستند.



شکل ۴-۲: بیشترین افت علامت‌دار به تفکیک مجموعه داده و وضعیت آزمایشی. وضعیت‌های آزمایشی تجمیع نشده‌اند؛ خط عمودی صفر حفظ شده و مقادیر منفی، بهبود پس از ترمیم را نشان می‌دهند.



شکل ۳-۴: A_u به تفکیک مجموعه داده و وضعیت آزمایشی. وضعیت‌های آزمایشی تجمیع نشده‌اند؛ خط‌چین سطح تصادفی هر مجموعه داده را نشان می‌دهد.

۲-۳-۴ تحلیل جفتی و آزمون معناداری

چون دنباله‌ها بر اساس بذر جفت شده‌اند، مقایسه‌ی مستقیم EPALL با PALL اصلی ممکن است. جدول ۳-۴ اختلاف‌های جفتی و بازه‌های باز نمونه‌گیری توصیفی را نشان می‌دهد.

جدول ۳-۴: اختلاف‌های جفتی (EPALL منهای PALL) روی بذرهای یکسان. مقدار مثبت برای دقت نهایی، فراموشی و بیشترین افت به سود EPALL است؛ ΔT_f منفی یعنی EPALL کندتر است. بازه‌های باز نمونه‌گیری روی هشت بذر هم‌تراز و توصیفی‌اند.

مجموعه داده	جفت	Δ دقت نهایی	Δ فراموشی	Δ بیشترین افت	ΔT_f (ث)
CIFAR-10	8	0.0087 [0.0034, 0.0151]	-0.0017 [-0.0078, 0.0033]	0.0092 [0.0029, 0.0157]	-2.10
CIFAR-100	8	0.0147 [0.0062, 0.0229]	0.0110 [0.0055, 0.0160]	0.0166 [0.0094, 0.0236]	-12.06

روی CIFAR-100 اختلاف A_{final} مثبت و برابر $+0.0147$ با بازه‌ی $[0.0062, 0.0229]$ است، با بهبود میانگین 0.0110 در F_{avg} و 0.0166 در بیشترین افت؛ هیچ‌یک از این سه بازه صفر را در بر نمی‌گیرد. روی CIFAR-10 افزایش دقت $+0.0087$ با بازه‌ی $[0.0034, 0.0151]$ و بهبود بیشترین افت 0.0092 با بازه‌ی $[-0.0078, 0.0033]$ است، در حالی که F_{avg} نتیجه‌ی مشخصی ندارد (-0.0017 با بازه‌ای که صفر را در بر می‌گیرد). هزینه‌ی این نگه‌داری، زمان درخواست است: EPALL حدود $2/10$ ثانیه روی CIFAR-10 و $12/06$ ثانیه روی CIFAR-100 از PALL اصلی کندتر است.

جدول ۴-۴ آزمون‌های دقیق یک‌طرفه را گزارش می‌کند. چون شش آزمون هم‌زمان انجام می‌شود، مقدار p خام به‌تنهایی کافی نیست و اصلاح Holm برای چندگانگی اعمال شده است. روی CIFAR-100 هر سه معیار به $p = 0.007812$ می‌رسند و هفت جفت از هشت جفت به سود EPALL است، با اندازه‌های اثر جفتی d_z برابر $1/11$ ، $1/51$ و $1/35$ ؛ هر سه پس از اصلاح Holm نیز در سطح 0.05 باقی می‌مانند. روی CIFAR-10 تنها A_{final} باقی می‌ماند ($p = 0.007812$ و پس از Holm برابر 0.0469).

جدول ۴-۴: آزمون دقیق یک طرفه‌ی رتبه‌های علامت‌دار ویلکاکسون (EPALL در برابر PALL) روی بذره‌های یکسان. چون شش آزمون هم‌زمان انجام می‌شود، ستون Holm مقدار p اصلاح‌شده برای چندگانگی را می‌دهد و ستون آخر نشان می‌دهد کدام آزمون در سطح ۰/۰۵ باقی می‌ماند. کف قابل‌دستیابی p برای هر سطر جداگانه است و یکسان نیست: برای سطرهای CIFAR-100 برابر ۰/۰۰۳۹۰۶ و برای دقت نهایی CIFAR-10 برابر ۰/۰۰۷۸۱۲ است. برای معیارهای «کمتر بهتر» علامت اختلاف وارونه شده تا مقدار مثبت همیشه به سود EPALL باشد.

داده	معیار	موافق/گره میانگین Δ	d_z	p خام	Holm	کف p	بقا
CIFAR-10	دقت نهایی	7 / 1	0.008656	0.9561	0.007812	0.046872	0.007812
CIFAR-10	بیشترین افت	5 / 2	0.009187	0.9308	0.03125	0.0625	0.015625
CIFAR-10	فراموشی	3 / 1	-0.00170	-0.1950	0.59375	0.59375	0.007812
CIFAR-100	دقت نهایی	7 / 0	0.014732	1.1141	0.007812	0.046872	0.003906
CIFAR-100	بیشترین افت	7 / 0	0.016625	1.5106	0.007812	0.046872	0.003906
CIFAR-100	فراموشی	7 / 0	0.011049	1.3487	0.007812	0.046872	0.003906

تفسیر این جدول باید محتاطانه بماند و دو تصحیح مهم دارد. نخست، بیشترین افت روی CIFAR-10 پس از اصلاح Holm معنادار نیست: مقدار خام ۰/۰۳۱۲۵ پس از اصلاح به ۰/۰۶۲۵ می‌رسد و از سطح ۰/۰۵ می‌گذرد. آزمون علامت همان معیار نیز به $p = ۰/۱۰۹$ می‌رسد، پس شاهد آن از دو جهت ضعیف است و در این پایان‌نامه به‌عنوان یافته‌ی معنادار گزارش نمی‌شود. دوم، کف p قابل‌دستیابی برای همه‌ی سطرها یکسان نیست: این کف به تعداد جفت‌های بدون تساوی بستگی دارد و برای سطرهای CIFAR-100 (بدون تساوی) برابر ۰/۰۰۳۹۰۶ است، نه ۰/۰۰۷۸۱۲. بنابراین مقادیر مشاهده‌شده‌ی CIFAR-100 روی کف نایستاده‌اند بلکه دو برابر آن هستند، و این یعنی توان آزمون کاملاً اشباع نشده است. تنها معیاری که در هیچ مجموعه‌داده‌ای بهبود پیوسته نشان نمی‌دهد F_{avg} روی CIFAR-10 است، که با علامت منفی اختلاف جفتی در جدول ۴-۳ سازگار است.

در مجموع، از شش آزمون، چهار آزمون پس از اصلاح هولم برای آزمون‌های متعدد همچنان معنادارند: هر سه معیار روی CIFAR-100 و دقت نهایی روی CIFAR-10.

یادداشت درباره‌ی تعداد بذر. نتایج این بخش بر هشت بذر (۰ تا ۷) استوارند که وضعیت کامل‌شده‌ی مخزن نتایج است. نسخه‌ی مقاله‌ی کنفرانسی همین کار بر پنج بذر (۰ تا ۴) بسته شده بود و اعداد آن با

اعداد این جا تفاوت جزئی دارد؛ جهت همه‌ی نتیجه‌گیری‌ها یکسان مانده است، اما مقادیر عددی و p ها متفاوت‌اند. هر جا در این پایان‌نامه عددی گزارش می‌شود، منبع آن وضعیت کنونی مخزن نتایج است و نه مقاله.

۴-۴ آزمون موقعیت درخواست

فرض اصلی EPALL این است که با افزایش هم‌پوشانی، محافظت از وزن‌های مشترک اهمیت بیشتری پیدا می‌کند. برای بررسی این فرض، آزمونی با پنج سطح از پیش تعیین‌شده طراحی شد: پنج سطح $\times$ شش روش $\times$ دو مجموعه داده $\times$ پنج بذری ۳۰۰ = اجرای هم‌تراز.

این آزمون، هم‌پوشانی را مستقیماً کنترل نمی‌کند. متغیری که میان سطوح تغییر می‌کند، موقعیت درخواست فراموشی در دنباله است؛ یعنی تعداد وظیفه‌هایی که پس از وظیفه‌ی هدف آموزش می‌بینند. این کمیت با K نشان داده می‌شود: برای CIFAR-10 برابر $K \in \{0, 1, 2, 3, 4\}$ و برای CIFAR-100 برابر $K \in \{0, 2, 4, 7, 9\}$ است. چون تقسیم کلاس‌ها و شناسه‌های وظیفه ثابت‌اند، کنترل مستقیم هم‌پوشانی نقاب‌ها به تغییر تقسیم داده نیاز دارد که در این پژوهش انجام نشده است.


در نتیجه، K فقط نشانه‌ای تقریبی از هم‌پوشانی موردانتظار است. با تغییر آن، هویت وظیفه‌ی هدف، زمان سپری‌شده از آموزش آن، ترتیب درخواست‌ها و مقدار آموزش پس از آن نیز هم‌زمان تغییر می‌کنند. این آزمون در سراسر پایان‌نامه آزمون موقعیت درخواست نامیده می‌شود و نتیجه‌ی آن فقط روندی توصیفی و سازگار با فرضیه است، نه شاهده‌ی برای اثر مستقل هم‌پوشانی. جدول ۴-۵ بیشترین افت را در همه‌ی حالت‌ها گزارش می‌کند.

جدول ۴-۵: بیشترین افت علامت دار در پنج درجه‌ی از پیش تعیین شده‌ی موقعیت درخواست، از بسیار کم تا بسیار زیاد؛ پنج بذر در هر خانه، شش روش و دو مجموعه داده، در مجموع ۳۰۰ اجرای هم تراز ($5 \times 2 \times 6 \times 5$). درجه‌ها تعداد وظایف آموزش دیده پس از وظیفه‌ی هدف را تغییر می‌دهند و هم پوشانی واقعی نقاب‌ها را کنترل نمی‌کنند؛ هم‌زمان با آن، هویت و سن وظیفه‌ی هدف نیز تغییر می‌کند. مقادیر LoRA و PALL-Adapter بازتاب کف ظرفیت روی بدنه‌ی منجمد تصادفی‌اند؛ تنها برای کامل بودن آورده شده‌اند.

مجموعه داده	روش	بسیار کم	کم	متوسط	زیاد	بسیار زیاد
CIFAR-10	CLPU	0.0000	0.0000	0.0000	0.0000	0.0000
	PALL	0.0134	0.0182	0.0308	0.0303	0.0363
	EPALL	0.0067	0.0078	0.0123	0.0127	0.0157
	SalUn	0.0339	0.0454	0.0271	0.0346	0.0371
	LoRA	-0.0075	0.0041	-0.0160	0.0049	0.0049
	PALL-Adapter	0.0054	0.0071	-0.0024	0.0002	0.0036
CIFAR-100	CLPU	0.0000	0.0000	0.0000	0.0000	0.0000
	PALL	0.0124	0.0144	0.0196	0.0296	0.0456
	EPALL	0.0064	0.0060	0.0064	0.0104	0.0164
	SalUn	0.0352	0.0568	0.0516	0.0712	0.0664
	LoRA	0.0868	0.0828	0.0788	0.0780	0.0528
	PALL-Adapter	0.0620	0.0588	0.0584	0.0564	0.0672

الگوی CIFAR-100 همان چیزی است که سازوکار پیش‌بینی می‌کرد: بیشترین افت PALL اصلی با افزایش شاخص موقعیت درخواست از ۰/۰۱۲۴ به ۰/۰۴۵۶ رشد می‌کند، در حالی که EPALL در بازه‌ی ۰/۰۰۶۰ تا ۰/۰۱۶۴ نسبتاً ثابت می‌ماند. روی CIFAR-10 همین ترتیب حفظ می‌شود اما در بازه‌ی کوچک‌تر. SalUn رفتاری مشابه PALL اصلی نشان می‌دهد و CLPU همان‌گونه که انتظار می‌رفت به‌طور ساختاری صفر می‌ماند، چون شبکه‌های مستقل امکان تداخل ندارند. شکل ۴-۴ همین روند را نمایش می‌دهد.

هشدار روش شناختی. این یک روند درجه‌به‌درجه و توصیفی است و هیچ ادعای علی از آن بیرون نمی‌آید، چون درجه هم‌زمان چند عامل را جابه‌جا می‌کند. هم پوشانی اندازه‌گیری شده میان روش‌ها متفاوت است و رگرسیون‌های تجمعی روی هم پوشانی اندازه‌گیری شده عمدتاً صفر را در بر می‌گیرند. جدول ۴-۶ این رگرسیون‌ها را گزارش می‌کند: تنها استثنا شیب CIFAR-100 مسیر لایه‌ی تطبیق است. توجه شود که



شکل ۴-۴: بیشترین افت در پنج درجه‌ی موقعیت درخواست برای چهار روش اصلی نمایش داده شده (میانگین پنج اجرای هم‌تراز هر درجه؛ کمتر بهتر). درجه‌های محور افقی از «بسیار کم» تا «بسیار زیاد»، تعداد وظایف آموزش دیده پس از وظیفه‌ی هدف را کدگذاری می‌کنند و شاخصی جانشین برای هم‌پوشانی مورد انتظارند، نه خود هم‌پوشانی. PALL اصلی با افزایش این شاخص بالا می‌رود، در حالی که EPALL نسبتاً ثابت می‌ماند؛ CLPU به‌طور ساختاری صفر است. دو روش دیگر در جدول ۴-۵ آمده‌اند.

سنجه‌ی محور افقی برای دو خانواده یکسان نیست — برای PALL کامل، میانگین اشتراک — بر — اجتماع نقاب‌های زیر شبکه و برای لایه‌ی تطبیق، نسبت بحرانی مشترک — پس مقایسه‌ی بزرگی شیب‌ها میان این دو بازنمایی نیازمند احتیاط است.

جدول ۴-۶: رگرسیون بیشترین افت علامت دار روی هم پوشانی اندازه گیری شده. بازه ها از خطای استاندارد مقاوم HC3 با مقادیر بحرانی توزیع t می آیند و اجراهای تکراری به آخرین اجرای کامل خود تجمیع شده اند. سنجی محور افقی میان دو خانواده یکسان نیست، پس بزرگی شیب ها مستقیما قابل مقایسه نیست.

داده	روش	سنجی محور x	n	شیب	بازه ی ۹۵٪	شامل صفر
CIFAR-100	PALL	اشتراک بر اجتماع نقاب	11	0.5173	[-1124.37, 1125.41]	بله
CIFAR-100	EPALL	اشتراک بر اجتماع نقاب	12	0.0652	[-0.2677, 0.3980]	بله
CIFAR-100	PALL-Adapter	نسبت بحرانی مشترک	86	0.0388	[0.0227, 0.0548]	خیر
CIFAR-10	PALL	اشتراک بر اجتماع نقاب	12	-35.9451	[-209.28, 137.39]	بله
CIFAR-10	EPALL	اشتراک بر اجتماع نقاب	14	3.8640	[-107.69, 115.42]	بله
CIFAR-10	PALL-Adapter	نسبت بحرانی مشترک	92	0.0085	[0.0003, 0.0166]	خیر

بازه های بسیار پهن سطرهای PALL کامل از آنجا ناشی می شوند که هم پوشانی اندازه گیری شده در آن اجراها فقط سه یا چهار مقدار متفاوت دارد. بنابراین، جدول کمبود تنوع در متغیر مستقل را نشان می دهد و نبود اثر را اثبات نمی کند. همین محدودیت، دلیل اصلی طراحی آزمون مبتنی بر سطح بود.

۴-۵ بررسی تنکی و هم پوشانی اندازه گیری شده

آزمون بخش ۴-۴ محدودیتی دارد که در همان بخش توضیح داده شد. سطوح آزمایش موقعیت درخواست را تغییر می دهند و هم پوشانی فقط به عنوان پیامد این تغییر جابه جا می شود. هویت وظیفه ی هدف، زمان سپری شده از آموزش آن و مقدار آموزش پس از آن نیز هم زمان تغییر می کنند. بنابراین، نتیجه ی آن آزمون با فرضیه سازگار است، اما آن را مستقیما نمی آزماید. در این بخش، موقعیت درخواست ثابت می ماند و تنکی زیر شبکه تغییر می کند. چون تغییر تنکی ظرفیت را نیز تغییر می دهد، این آزمایش هم اثر مستقل هم پوشانی را اندازه نمی گیرد.

طرح. دنباله ی درخواست، وظیفه ی هدف و موقعیت آن دقیقا ثابت نگه داشته می شوند و تنها تنکی زیر شبکه تغییر می کند. تنکی تعیین می کند هر نقاب وظیفه چند درایه بگیرد و در نتیجه با $|S_{share}|$

$|M_f \cap M_r|$ ارتباط مستقیم دارد، اما هم‌زمان ظرفیت هر وظیفه را نیز تغییر می‌دهد. پنج سطح تنکی از ۰/۹ تا ۰/۵، دو روش و پنج بذر، در مجموع ۱۰۰ اجرای هم‌تراز می‌سازند. این بررسی افراز و دنباله‌ی طرح آزمایشی استاندارد را به‌کار می‌برد، اما با بودجه‌ی ۳ دوره به‌ازای هر وظیفه اجرا شده است و نه ۲۰ دوره. بنابراین سطح مطلق دقت آن با جدول‌های بخش ۳-۴ قابل مقایسه نیست و تنها مقایسه‌ی درون‌جدولی دو حالت آزمایشی در هر سطح تنکی معتبر است. دو حالت آزمایشی هر خانه و بذر یکسان می‌بینند؛ هم‌پوشانی اندازه‌گیری‌شده‌ی آن‌ها کاملاً برابر نیست، از این‌رو میانگین جفت گزارش می‌شود. بیشترین اختلاف نسبی دو حالت آزمایشی کمتر از ۰/۰۵٪ است.

آزمون تنکی. برخلاف آزمون موقعیت درخواست که متغیر مستقل آن فقط سه یا چهار مقدار متفاوت داشت، هم‌پوشانی اندازه‌گیری‌شده در اینجا روی CIFAR-10 به اندازه‌ی ۱۹/۷ برابر و روی CIFAR-100 به اندازه‌ی ۱۰/۷ برابر تغییر می‌کند و با سطوح تنکی رابطه‌ای یکنواخت دارد. بنابراین، تنکی دامنه‌ی مناسبی از هم‌پوشانی ایجاد کرده است؛ با این حال، اثر هم‌پوشانی را از اثر ظرفیت جدا نمی‌کند.

جدول ۴-۷: بررسی تنکی زیر شبکه و هم‌پوشانی ساختاری اندازه‌گیری‌شده (پنج بذر در هر خانه). متغیر تغییرکرده تنکی است، نه خود هم‌پوشانی؛ بنابراین این جدول اثر مستقل هم‌پوشانی را نشان نمی‌دهد. دنباله‌ی درخواست، وظیفه‌ی هدف و موقعیت آن ثابت‌اند، اما تنکی هم $|S_{share}|$ و هم ظرفیت هر وظیفه را تغییر می‌دهد. مقدار $|S_{share}|$ میانگین دو حالت با بذر یکسان است؛ اختلاف نسبی دو حالت آزمایشی در همه‌ی جفت‌ها کمتر از ۰/۰۵٪ بود. «سود حفاظت» اختلاف بیشترین افت PALL منهای EPALL است؛ مقدار مثبت یعنی حفاظت کمک می‌کند. ستون دقت PALL برای بررسی اثر تغییر ظرفیت گزارش شده است.

مجموعه داده	تنکی	$ S_{share} $	بیشترین افت PALL	بیشترین افت EPALL	سود حفاظت	دقت PALL
CIFAR-10	0.9	169,815	0.0036	0.0018	+0.0018	0.8855
	0.8	642,863	0.0121	0.0030	+0.0091	0.8826
	0.7	1,365,591	0.0141	0.0012	+0.0129	0.8749
	0.6	2,285,622	0.0326	0.0040	+0.0286	0.8546
	0.5	3,347,700	0.0411	0.0062	+0.0349	0.8379
CIFAR-100	0.9	959,093	0.0176	0.0030	+0.0146	0.4919
	0.8	3,014,623	0.0610	0.0126	+0.0484	0.4759
	0.7	5,429,857	0.1124	0.0360	+0.0764	0.4160
	0.6	7,882,273	0.1454	0.0452	+0.1002	0.3577
	0.5	10,264,556	0.1550	0.0756	+0.0794	0.3292

جدول ۴-۷ نتیجه را نشان می‌دهد. روی CIFAR-10 سود حفاظت از ۰/۰۰۱۸ در کم‌ترین هم‌پوشانی به ۰/۰۳۴۹ در بیش‌ترین می‌رسد. روی CIFAR-100 از ۰/۰۱۴۶ آغاز می‌شود، در سطح تنکی ۰/۶ به بیشینه‌ی ۰/۱۰۰۲ می‌رسد و در بیشترین هم‌پوشانی ۰/۰۷۹۴ است؛ بنابراین روند مثبت است اما یکنواخت نیست. همبستگی رتبه‌ای اسپیرمن میان هم‌پوشانی اندازه‌گیری‌شده و سود حفاظت روی CIFAR-10 برابر ۱/۰۰+ و روی CIFAR-100 برابر ۰/۹۰+ است. چون تنها پنج سطح در کار است، به‌جای تقریب مجانبی، هر ۱۲۰ جایگشت ممکن شمرده شده و p دقیق به‌دست آمده است: به‌ترتیب ۰/۰۰۸۳ و ۰/۰۴۱۷. برای سود دقت نهایی، همبستگی روی هر دو مجموعه داده ۱/۰۰+ و p دقیق ۰/۰۰۸۳ است.

دو قید. نخست، تنکی علاوه بر هم‌پوشانی، ظرفیت را هم تغییر می‌دهد و این عامل مداخله‌گر با طراحی حذف‌شدنی نیست: دقت PALL در همین بررسی روی CIFAR-100 از ۰/۴۹۱۹ به ۰/۳۲۹۲ می‌افتد. همسان‌بودن تنکی اسمی در هر جفت، مقایسه‌ی دو روش را تفسیرپذیرتر می‌کند، اما اثر علی مستقل هم‌پوشانی را شناسایی نمی‌کند. دوم، آزمون علامت میان بذرها درون هر خانه با پنج بذر توان کمی دارد و تنها سه خانه از ده خانه به $p < ۰/۰۵$ می‌رسند؛ میانگین‌ها اختلاف بزرگی نشان می‌دهند اما پراکندگی بذرها بالاست. بنابراین شاهد اصلی این بخش در روند میان سطوح است و نه در تک‌تک خانه‌ها.

جمع‌بندی. با ثابت‌نگه‌داشتن هویت و موقعیت وظیفه‌ی هدف، بررسی تنکی یک رابطه‌ی رتبه‌ای مثبت میان هم‌پوشانی اندازه‌گیری‌شده و سود حفاظت نشان می‌دهد. این نتیجه از ادعای انگیزشی EPALL پشتیبانی می‌کند، اما به‌دلیل تغییر هم‌زمان ظرفیت و یکنواخت‌نبودن روند CIFAR-100 اثبات علی خالص اثر هم‌پوشانی نیست.

۴-۶ انتساب سازوکار EPALL

پرسش RQ4 می‌پرسد کدام جزء سازوکار واقعا منشأ بهبود است. جدول ۴-۸ پنج حالت آزمایشی هم‌تراز را نشان می‌دهد که طرح آزمایشی هم‌پوشانی سنگین، دنباله‌ها و بذرها را به اشتراک می‌گذارند و هر یک تنها در یک جزء تفاوت دارند؛ تعریف این حالت‌های آزمایشی در بخش ۳-۳-۵ آمد. جدول ۴-۹ نیز اختلاف‌های جفتی نسبت به حالت کامل را می‌دهد و تفسیر دقیق‌تری ممکن می‌سازد.

جدول ۴-۸: کنترل‌های مستقیم سازوکار EPALL روی هشت بذر، زیر طرح آزمایشی هم‌پوشانی سنگین و با دنباله‌های هم‌تراز. هر حالت آزمایشی دقیقاً یک جزء سازوکار محافظت را تغییر می‌دهد و هیچ سلولی رتبه‌بندی نشده است. سطح تصادفی دقت هدف ۰/۵ برای C10 و ۰/۲ برای C100 است.

داده	حالت کنترل	دقت نهایی	فراموشی	بیشترین افت	$ A_u - c $
C10	بدون جریمه‌ی ℓ_2	0.8822 ± 0.0358	0.2533 ± 0.0233	0.0025 ± 0.0029	0.0162 ± 0.0272
	فقط هم‌پوشانی	0.8767 ± 0.0429	0.2503 ± 0.0232	-0.0001 ± 0.0002	0.0127 ± 0.0203
	بودجه‌ی تصادفی	0.8747 ± 0.0383	0.2547 ± 0.0218	0.0097 ± 0.0107	0.0146 ± 0.0233
	رتبه‌بندی بدون اشتراک	0.8774 ± 0.0394	0.2502 ± 0.0222	0.0021 ± 0.0027	0.0136 ± 0.0281
	کامل	0.8774 ± 0.0394	0.2502 ± 0.0222	0.0021 ± 0.0027	0.0136 ± 0.0281
C100	بدون جریمه‌ی ℓ_2	0.4877 ± 0.0186	0.0889 ± 0.0179	0.0082 ± 0.0082	0.0083 ± 0.0084
	فقط هم‌پوشانی	0.4808 ± 0.0205	0.0904 ± 0.0186	0.0005 ± 0.0009	0.0080 ± 0.0077
	بودجه‌ی تصادفی	0.4897 ± 0.0197	0.0944 ± 0.0214	0.0227 ± 0.0082	0.0098 ± 0.0098
	رتبه‌بندی بدون اشتراک	0.4929 ± 0.0236	0.0923 ± 0.0206	0.0080 ± 0.0081	0.0155 ± 0.0170
	کامل	0.4929 ± 0.0236	0.0923 ± 0.0206	0.0080 ± 0.0081	0.0155 ± 0.0170

جدول ۴-۹: اختلاف‌های جفتی هر حالت کنترل نسبت به حالت کامل؛ مقدار مثبت به سود حالت کامل است. بازه‌های بازنمونه‌گیری روی هشت بذر هم‌تراز و توصیفی‌اند.

داده	حالت کنترل	Δ دقت نهایی	Δ بیشترین افت	$\Delta A_u - c $
CIFAR-10	بدون جریمه‌ی ℓ_2	$-0.0048 [-0.0113, 0.0008]$	$0.0004 [-0.0011, 0.0022]$	$0.0026 [-0.0007, 0.0083]$
	فقط هم‌پوشانی	$0.0007 [-0.0027, 0.0042]$	$-0.0022 [-0.0041, -0.0006]$	$-0.0009 [-0.0094, 0.0054]$
	بودجه‌ی تصادفی	$0.0027 [0.0009, 0.0042]$	$0.0076 [0.0024, 0.0134]$	$0.0010 [-0.0056, 0.0093]$
	رتبه‌بندی بدون اشتراک	$0.0000 [0.0000, 0.0000]$	$0.0000 [0.0000, 0.0000]$	$0.0000 [0.0000, 0.0000]$
CIFAR-100	بدون جریمه‌ی ℓ_2	$0.0052 [-0.0008, 0.0129]$	$0.0002 [-0.0078, 0.0083]$	$-0.0072 [-0.0170, 0.0038]$
	فقط هم‌پوشانی	$0.0120 [0.0065, 0.0191]$	$-0.0075 [-0.0127, -0.0022]$	$-0.0075 [-0.0160, -0.0000]$
	بودجه‌ی تصادفی	$0.0031 [-0.0029, 0.0091]$	$0.0148 [0.0102, 0.0210]$	$-0.0057 [-0.0137, 0.0018]$
	رتبه‌بندی بدون اشتراک	$0.0000 [0.0000, 0.0000]$	$0.0000 [0.0000, 0.0000]$	$0.0000 [0.0000, 0.0000]$

تفسیر این دو جدول چهار نتیجه می‌دهد. دو نتیجه به سود سازوکار پیشنهادی هستند و دو نتیجه چنین نیستند؛ هر چهار به‌صراحت گزارش می‌شوند.

یک. کیفیت انتخاب مهم است، نه فقط اندازه‌ی بودجه. این روشن‌ترین و پایدارترین یافته‌ی کنترل‌ها است و روی هر دو مجموعه‌داده برقرار می‌ماند. حالت آزمایشی بودجه‌ی تصادفی همان تعداد درایه را

محافظت می‌کند، اما بیشترین افت را $0/0076$ روی CIFAR-10 و $0/0148$ روی CIFAR-100 بدتر می‌کند و هر دو بازه صفر را در بر نمی‌گیرند؛ روی CIFAR-10 اختلاف دقت نیز $(+0/0027)$ از صفر جدا است. این مقایسه دقیقاً همان چیزی را جدا می‌کند که باید: با ثابت نگه داشتن اندازه‌ی بودجه، تفاوت باقی‌مانده تنها می‌تواند از کیفیت رتبه‌بندی بیاید.

دو. رتبه‌بندی نسبت به محافظت بدون رتبه، نگهداری بهتری می‌دهد اما در همه‌ی معیارها برتر نیست. روی CIFAR-100، حالت کامل دقت جفتی را نسبت به حالت فقط هم‌پوشانی به اندازه‌ی $0/0120$ با بازه‌ی $[0/0065, 0/0191]$ بهبود می‌دهد. با این حال، حالت فقط هم‌پوشانی روی هر دو مجموعه داده بیشترین افت کمتری دارد: $0/0022$ روی CIFAR-10 و $0/0075$ روی CIFAR-100، با بازه‌هایی که صفر را در بر نمی‌گیرند. بنابراین، میان حفظ بهتر دقت نهایی و کاهش افت آسیب‌پذیرترین وظیفه موازنه وجود دارد. اگر مهم‌ترین معیار سامانه کمینه کردن افت بدترین وظیفه باشد، محافظت بدون رتبه‌بندی انتخاب بهتری است.

سه. سهم مستقل جریمه‌ی ℓ_2 پشتیبانی نمی‌شود. این حالت آزمایشی تنها جمله‌ی جریمه را حذف می‌کند؛ شناسایی ناحیه‌ی بحرانی و ساخت پشتیبان‌های آن دست‌نخورده باقی می‌ماند، پس نتیجه‌ی آن درباره‌ی شدت مهاراست و نه درباره‌ی کل محافظت. این حالت آزمایشی روی هیچ‌یک از دو مجموعه داده به‌روشنی از حالت کامل جدا نمی‌شود: اختلاف دقت جفتی روی CIFAR-100 برابر $0/0052$ با بازه‌ی $[0/0008, 0/0129]$ است که صفر را در بر می‌گیرد، و روی CIFAR-10 برآورد نقطه‌ای $-0/0048$ است، یعنی حتی کمی به سود حذف لنگر. اختلاف بیشترین افت در هر دو مورد عملاً صفر است. بنابراین در پیکربندی آزمون‌شده، آنچه اثر دارد انتخاب ناحیه‌ی محافظت‌شده است و نه شدت مهار آن با جمله‌ی ℓ_2 . این یافته با نسخه‌ی مبتنی بر پنج بذر همین کنترل‌ها تفاوت دارد، جایی که بازه‌ی CIFAR-100 صفر را در بر نمی‌گرفت؛ افزودن بذر آن جدایی را از میان برد.

چهار. فیلتر صریح اشتراک در این پیاده‌سازی اضافی است. حالت آزمایشی رتبه‌بندی بدون اشتراک، حالت کامل را دقیقاً بازتولید می‌کند؛ همه‌ی اختلاف‌های جفتی صفرند. اما تفسیر این یکسانی باید دقیق باشد و ضرورت عمومی هم‌پوشانی را رد نمی‌کند. دلیلش ساختاری است: در این حالت آزمایشی رتبه‌بندی روی کل زیرشبکه‌ی هدف M_f انجام می‌شود، ولی نقاب ترمیم مستقل از حالت کنترل همان $M_f \cap M_r$ می‌ماند و شیب بیرون آن صفر می‌شود. پس هر درایه‌ای که رتبه‌بندی بیرون M_r انتخاب کند، در عمل هرگز حرکت نمی‌کند و لنگر روی آن بی‌اثر است. به بیان دیگر، خود پیاده‌سازی فیلتر اشتراک را در مرحله‌ی بعد اعمال می‌کند؛ بنابراین این آزمایش نشان می‌دهد اعمال دوباره‌ی آن در مرحله‌ی پیش اضافی است، نه اینکه

محدود کردن به ناحیه‌ی مشترک بی‌فایده باشد.

جمع‌بندی کنترل‌ها. آنچه این کنترل‌ها به‌طور تجربی پشتیبانی می‌کنند، باریک‌تر از توصیف کامل سازوکار است: رتبه‌بندی درایه‌های نامزد بر پایه‌ی حساسیت نگه‌داری، با یک بودجه‌ی ثابت. دو جزء دیگر سهم مستقل قابل‌اندازه‌گیری نشان نمی‌دهند، اما این به‌معنای بی‌فایده‌بودن آن‌ها نیست: جریمه‌ی l_2 تنها شدت مهار را تنظیم می‌کند در حالی که پشتیبان‌ها مستقل از آن ساخته می‌شوند، و فیلتر اشتراک در مرحله‌ی بعد پیاده‌سازی به‌هرحال اعمال می‌شود. این کنترل‌ها برای اثبات ضرورت همه‌ی اجزای طراحی کافی نیستند. این محدودیت در بخش ۴-۵ به‌عنوان محدودیت ادعای سازوکاری ثبت می‌شود و در بخش ۵-۵ به یک پیشنهاد ساده‌سازی تبدیل می‌شود.

۷-۴ وضعیت آزمایشی پیش‌آموزش‌دیده‌ی PEFT

جدول ۴-۱۰ فرض روش‌های کم‌پیراسنجه را برقرار می‌کند: LoRA و PALL-Adapter هر دو روی یک ResNet-18 منجمد و پیش‌آموزش‌دیده‌ی ImageNet می‌نشینند. ورودی‌های CIFAR از هنجارسازی مجموعه‌داده به آماره‌های ImageNet که بدنه انتظار دارد تبدیل می‌شوند؛ TinyImageNet از پیش همان آماره‌ها را دارد. این تصحیح هنجارسازی مهم است و در پیوست ۵-۶ توضیح داده شده است.

جدول ۴-۱۰: وضعیت آزمایشی اصلاح‌شده‌ی بدنه‌ی ثابت و پیش‌آموزش‌دیده (سه بذر در همه‌ی سطرها). ورودی CIFAR با آماره‌های ImageNet هنجارسازی می‌شود و TinyImageNet از پیش همان آماره‌ها را دارد. سطح تصادفی دقت هدف به‌ترتیب ۰/۵، ۰/۲ و ۰/۱ است. پررنگ فقط نتیجه‌ی بهتر در دقت نهایی و بیشترین افت علامت‌دار را نشان می‌دهد؛ دقت هدف بر پایه‌ی فاصله تا سطح تصادفی تفسیر می‌شود. R_{upd} نسبت اسمی پیراسنجه‌های آموزش‌پذیر در نقاب ترمیم است.

مجموعه‌داده	روش	دقت نهایی	بیشترین افت	دقت هدف	R_{upd}
CIFAR-10	LoRA	0.9848 ± 0.0154	0.0000 ± 0.0000	0.5203 ± 0.0966	0.0011
	Adapter	0.9841 ± 0.0172	-0.0002 ± 0.0003	0.5190 ± 0.0988	0.0030
CIFAR-100	LoRA	0.8215 ± 0.0083	0.0213 ± 0.0219	0.1613 ± 0.0613	0.0051
	Adapter	0.8277 ± 0.0061	0.0180 ± 0.0020	0.1907 ± 0.1066	0.0103
TinyImageNet	LoRA	0.8980 ± 0.0049	0.0153 ± 0.0110	0.0940 ± 0.0092	0.0163
	Adapter	0.9047 ± 0.0050	0.0127 ± 0.0042	0.0940 ± 0.0401	0.0273

با بدنه‌ی پیش‌آموزش دیده، هر دو روش به‌طور چشمگیری بهبود می‌یابند: PALL-Adapter به ۰/۹۸۴۱ روی CIFAR-10، ۰/۸۲۷۷ روی CIFAR-100 و ۰/۹۰۴۷ روی TinyImageNet می‌رسد و مقادیر متناظر LoRA برابر ۰/۹۸۴۸، ۰/۸۲۱۵ و ۰/۸۹۸۰ است. اختلاف CIFAR-10 نسبت به پراکندگی بذرها ناچیز است، در حالی که لایه‌ی تطبیق روی CIFAR-100 و TinyImageNet به‌طور متوسط کمی بالاتر می‌ایستد. مقایسه‌ی این نقطه‌های پایان با هم، مقایسه‌ی رفتار انتهایی دو معماری است و تفاوت را به نقاب نرم نسبت نمی‌دهد؛ آن پرسش، موضوع بخش بعد است.

این جدول در کنار جدول‌های ۱-۴ و ۲-۴ همان نکته‌ی مهم را روشن می‌کند: عملکرد پایین دو سطر PEFT در طرح آزمایشی از صفر، ناشی از سازوکار فراموشی آن‌ها نبود، بلکه ناشی از نشستن روی یک بازنمایی تصادفی بود.

۸-۴ انتساب مؤلفه‌های PALL-Adapter: یک نتیجه‌ی منفی

این بخش به RQ5 پاسخ می‌دهد و پاسخ، منفی است. پنج حالت آزمایشی هم‌تراز زیر روند اجرای پیش‌آموزش دیده‌ی تصحیح‌شده و با دنباله‌های یکسان (سه بذر) مؤلفه‌های زمان درخواست را جدا می‌کنند: فقط بازنشانی تنها لایه‌ی تطبیق هدف و برش طبقه‌بند آن را بازنشانی می‌کند؛ بازنشانی + ترمیم ترمیم نگه‌داری را اضافه می‌کند؛ یکنواخت محافظت هم‌پوشانی را از به‌روزرسانی مشترک برمی‌دارد؛ نقاب بدون صعود گام صعود ذخیره‌شده‌ی طبقه‌بند را حذف می‌کند؛ و کامل همه‌ی مؤلفه‌ها را دارد. جدول ۱۱-۴ نتیجه‌ی این پنج حالت آزمایشی و سه یافته‌ی اصلی آن‌ها را نشان می‌دهد.

جدول ۴-۱۱: کنترل‌های مؤلفه‌ای زمان درخواست برای PALL-Adapter زیر روند اجرای تصحیح‌شده‌ی پیش‌آموزش‌دیده و دنباله‌های هم‌تراز (سه بذر). حالت‌های آزمایشی از نظر مولد اعداد تصادفی هم‌ترازند، پس یکسان بودن مقادیر نشانه‌ی مؤلفه‌ی واقعا بی‌اثر است و نه نوسان تصادفی. سطح تصادفی دقت هدف ۰/۵ برای C10 و ۰/۲ برای C100 است.

داده	حالت کنترل	دقت نهایی	بیشترین افت	$ A_u - c $	T_f (ث)
	فقط بازنشانی	0.9836 ± 0.0168	0.0000 ± 0.0000	0.0675 ± 0.0573	0.0025
	بازنشانی + ترمیم	0.9840 ± 0.0171	0.0002 ± 0.0003	0.0677 ± 0.0569	0.8529
C10	یکنواخت (بی‌محافظت)	0.9840 ± 0.0171	0.0000 ± 0.0000	0.0667 ± 0.0577	0.9885
	نقاب، بدون صعود	0.9841 ± 0.0170	0.0000 ± 0.0000	0.0675 ± 0.0573	0.9991
	کامل	0.9841 ± 0.0170	0.0000 ± 0.0000	0.0658 ± 0.0586	0.9849
	فقط بازنشانی	0.8324 ± 0.0076	0.0000 ± 0.0000	0.0787 ± 0.0163	0.0021
	بازنشانی + ترمیم	0.8248 ± 0.0073	0.0187 ± 0.0070	0.0880 ± 0.0251	2.8273
C100	یکنواخت (بی‌محافظت)	0.8250 ± 0.0079	0.0153 ± 0.0196	0.0827 ± 0.0260	3.3232
	نقاب، بدون صعود	0.8244 ± 0.0091	0.0147 ± 0.0202	0.0887 ± 0.0212	3.1549
	کامل	0.8244 ± 0.0091	0.0147 ± 0.0202	0.0847 ± 0.0200	3.3178

نقاب نرم در نقطه‌ی پایان بی‌اثر است. حالت کامل و حالت آزمایشی یکنواخت حداکثر ۰/۰۰۰۶ در A_{final} یا بیشترین افت با هم اختلاف دارند، و حالت کامل و نقاب بدون صعود در هر دو معیار یکسان‌اند. چون حالت‌های آزمایشی از نظر مولد اعداد تصادفی هم‌تراز طراحی شده‌اند، این یکسانی نشانه‌ی نوسان تصادفی نیست؛ نشانه‌ی یک مؤلفه‌ی واقعا بی‌اثر است.

صعود طبقه‌بند تنها مؤلفه‌ی با اثر قابل اندازه‌گیری است. حذف آن، نگهداری را دست‌نخورده می‌گذارد اما وظیفه‌ی فراموش‌شده را به‌اندازه‌ی ۰/۰۰۴۰ روی CIFAR-100 و ۰/۰۰۱۷ روی CIFAR-10 از سطح تصادفی دور می‌کند. یعنی این مؤلفه در سرکوب سهم دارد، هرچند کوچک، و به دقت نگهداری آسیب نمی‌زند.

روی CIFAR-100 فقط بازنشانی در واقع بهتر است. نگهداری ۰/۸۳۲۴ در برابر ۰/۸۲۴۴، بیشترین افت ۰ در برابر ۰/۰۱۴۷، و فاصله‌ی میانگین کوچک‌تری تا سطح تصادفی. بازه‌های باز نمونه‌گیری جفتی روی سه دنباله برای اختلاف دقت و اختلاف فاصله تا سطح تصادفی صفر را در بر می‌گیرند، در حالی که

اختلاف بیشترین افت به سود فقط بازنشانی است.

نتایج نشان می‌دهند که سرکوب مشاهده‌شده در PALL-Adapter عمدتاً از بازنشانی لایه‌ی مخصوص وظیفه‌ی هدف ناشی می‌شود. به‌روزرسانی آگاه از هم‌پوشانی لایه‌ی مشترک، با وجود تحلیل نظری محدود در بخش ۳-۵، نتیجه‌ی نهایی را به‌طور قابل‌اندازه‌گیری بهبود نمی‌دهد. به همین دلیل، این روش فقط به‌عنوان یک گزینه‌ی اکتشافی و ارزیابی‌شده گزارش می‌شود و مشارکت اصلی پایان‌نامه نیست.

۴-۸-۱ نقاب نرم پیوسته: بررسی شدت

نتیجه‌ی منفی بخش پیش، نقاب نرم گسسته را ارزیابی می‌کند: افراز دودویی کامل/نرم/منجمد با یک ضریب ثابت. یک تبیین محتمل برای آن نتیجه این است که مشکل نه در ایده‌ی محافظت، بلکه در درشت‌دانگی افراز باشد. برای آزمودن این تبیین، نسخه‌ی پیوسته‌ای پیاده‌سازی و در چند سطح بررسی شد که در آن هر درایه‌ی زیرمجموعه‌ی فراموشی ضریب خاص خود را می‌گیرد:

$$m_i = \text{clamp}(1 - \gamma \hat{c}_i, 0, 1), \quad \hat{c}_i = \frac{\text{relu}(-g_i^f g_i^r)}{\max_j \text{relu}(-g_j^f g_j^r)}, \quad (3-4)$$

که در آن g^f و g^r شیب فراموشی و نگه‌داری روی لایه‌ی تطبیق مشترک‌اند و $\hat{c}_i$ انرژی تعارض مقیاس‌بندی‌شده است. مقدار $\gamma = 0$ به‌روزرسانی کامل را بازمی‌گرداند، پس حالت کنترل درون خود این بررسی قرار دارد و این آزمایش به هیچ جدول دیگری تکیه نمی‌کند.

جدول ۴-۱۲: بررسی شدت γ در نقاب نرم پیوسته‌ی وزن‌دار به انرژی تعارض، روی طرح آزمایشی پیش‌آموزش دیده (سه بذر). ضریب هر درایه $m_i = \text{clamp}(1 - \gamma \hat{c}_i, 0, 1)$ است و $\gamma = 0$ به‌روزرسانی کامل را بازمی‌گرداند، پس حالت کنترل درون همین جدول است. ستون‌های سمت راست وضعیت پایانی و ستون‌های سمت چپ آمار خود نقاب در لحظه‌ی درخواست‌اند؛ این دو باید کنار هم خوانده شوند، چون معنای نبود تغییر بسته به آنکه نقاب تغییر کرده باشد یا نه، کاملاً متفاوت است. «٪تعارض» سهم درایه‌های زیرمجموعه‌ی فراموشی با انرژی تعارض ناصفر و «٪ $m < 0.5$ » سهم درایه‌هایی است که ضریبشان واقعا زیر یک‌دوم افتاده است.

مجموعه داده	γ	دقت نهایی	بیشترین افت	دقت هدف	کامل	نرم	٪ $m < 0.5$	٪تعارض
CIFAR-10	0	0.9840	0.0000	0.5210	4916	0	0.00	40.62
	0.25	0.9840	0.0000	0.5210	3103	1813	0.00	40.74
	0.5	0.9840	0.0000	0.5208	3069	1847	0.00	40.74
	1	0.9840	0.0000	0.5208	3044	1872	0.07	40.68
	2	0.9840	0.0000	0.5210	3026	1886	0.28	40.66
CIFAR-100	0	0.8250	0.0153	0.1893	4916	0	0.00	44.13
	0.25	0.8250	0.0147	0.1873	2729	2187	0.00	44.50
	0.5	0.8251	0.0153	0.1907	2714	2202	0.00	44.80
	1	0.8252	0.0153	0.1887	2747	2168	0.19	44.12
	2	0.8256	0.0147	0.1900	2723	2183	0.85	44.62

جدول ۴-۱۲ هم وضعیت پایانی و هم آمار خود نقاب را کنار هم می‌دهد؛ این دو باید با هم خوانده شوند، چون معنای نبود تغییر بسته به آنکه نقاب تغییر کرده باشد یا نه کاملاً متفاوت است.

وضعیت پایانی تغییر نمی‌کند. در سراسر بررسی، دامنه‌ی تغییر دقت نهایی روی CIFAR-10 صفر و روی CIFAR-100 تنها ۰/۰۰۰۶ است؛ بیشترین افت و دقت هدف نیز در همین حد جابه‌جا می‌شوند. با سه بذر، هیچ‌کدام از این دامنه‌ها از نوسان ناشی از بذر قابل‌تفکیک نیستند.

اما نقاب واقعا تغییر می‌کند. این نکته، تفاوت میان یک نتیجه‌ی منفی معنادار و یک اشکال پیاده‌سازی است. در $\gamma = 0$ هر ۴۹۱۶ درایه‌ی زیرمجموعه‌ی فراموشی به‌روزرسانی کامل می‌گیرند، و از ۰/۲۵ γ به بعد حدود یک‌سوم آن‌ها به دسته‌ی «نرم» منتقل می‌شوند. اطلاعات تعارض هم وجود دارد و ساختگی نیست: میان ۴۰ تا ۴۵ درصد درایه‌ها انرژی تعارض ناصفر دارند. پس نه نقاب ثابت مانده و نه اطلاعات تعارض غایب است.

تبیین: تمرکز در بخش باریکی از توزیع. توضیح در توزیع $\hat{c}$ نهفته است. این کمیت بر بیشینه تقسیم می‌شود، پس $\max_i \hat{c}_i = 1$ است؛ اما میانگین آن تنها 0.0106 روی CIFAR-10 و حدود 0.004 روی CIFAR-100 است، یعنی سه مرتبه‌ی بزرگی کمتر از بیشینه. انرژی تعارض بنابراین در بخش بسیار باریکی از توزیع متمرکز است و اکثریت قاطع درایه‌ها $\hat{c}_i \approx 0$ دارند. با ضریب خطی رابطه‌ی (۳-۴)، چنین درایه‌ای حتی در بزرگ‌ترین γ آزموده‌شده ضریبی نزدیک به یک می‌گیرد. سهم درایه‌هایی که ضریبشان واقعا زیر یک‌دوم می‌افتد، در $\gamma = 2$ هنوز کمتر از یک درصد است. برچسب «نرم» در جدول بنابراین گمراه‌کننده است: آن درایه‌ها از نظر تعریف نرم‌اند اما از نظر عددی تقریبا به‌طور کامل به‌روز می‌شوند.

نتیجه. تبیین درشت‌دانگی رد می‌شود. ریزکردن افراز به یک ضریب پیوسته‌ی هر-درایه، رفتار آغاز تا پایان را تغییر نمی‌دهد، و دلیلش نیز مشخص است: با این صورت‌بندی، γ باید دو تا سه مرتبه‌ی بزرگی بزرگ‌تر باشد تا درایه‌ی نوعی را به‌طور محسوس تضعیف کند. این یافته نتیجه‌ی منفی بخش پیش را تقویت می‌کند و هم‌زمان یک مسیر مشخص برای کارهای آینده باز می‌گذارد: نقابی که به‌جای مقدار $\hat{c}$ بر رتبه‌ی آن بنا شود، از این مشکل مقیاس مصون است. همچنین این بررسی همان سنجه‌ی جهت‌داری را که در بخش ۳-۱۱-۴ غایب بود فراهم می‌کند: نسبت هنجار شیب تنها بزرگی را می‌سنجید، در حالی که $\hat{c}$ از ضرب داخلی درایه‌ای ساخته شده و جهت را در بر دارد.

۹-۴ نسخه‌های PALL زیر طرح آزمایشی هم‌پوشانی سنگین

این طرح آزمایشی از صفر و با سه دوره به‌ازای هر وظیفه، تنها سه نسخه‌ی PALL را مقایسه می‌کند و وضعیت آزمایشی یا دنباله‌ی طرح آزمایشی استاندارد را به اشتراک نمی‌گذارد؛ بنابراین اعداد آن با جدول‌های ۱-۴ و ۲-۴ مخلوط نمی‌شوند. جدول ۱۳-۴ این مقایسه را نشان می‌دهد.

جدول ۴-۱۳: نسخه‌های PALL در وضعیت آزمایشی مجزای هم‌پوشانی سنگین و از صفر (۳ دوره به‌ازای هر وظیفه). سطرهای CIFAR سه بذر دارند؛ سطرهای TinyImageNet از برجسب مجزای خود می‌آیند و توصیفی‌اند. سطح تصادفی دقت هدف به‌ترتیب ۰/۵، ۰/۲ و ۰/۱ است. اعداد این جدول با جدول‌های ۴-۱ و ۴-۲ مخلوط نمی‌شوند.

مجموعه داده	روش	بذر	دقت نهایی	بیشترین افت	دقت هدف
CIFAR-10	PALL	3	0.9087 ± 0.0266	0.0040 ± 0.0069	0.5000 ± 0.0000
	EPALL	3	0.9152 ± 0.0291	0.0008 ± 0.0033	0.5000 ± 0.0000
	PALL-Adapter	3	0.7829 ± 0.0610	0.0107 ± 0.0101	0.4802 ± 0.0816
CIFAR-100	PALL	3	0.5013 ± 0.0107	0.0187 ± 0.0095	0.2033 ± 0.0058
	EPALL	3	0.5093 ± 0.0148	0.0047 ± 0.0050	0.2033 ± 0.0058
	PALL-Adapter	3	0.3284 ± 0.0257	0.0427 ± 0.0333	0.2147 ± 0.0261
TinyImageNet	PALL	3	0.3365	0.0853	0.0973
	EPALL	3	0.4533	0.0840	0.0893
	PALL-Adapter	3	0.3332	0.0060	0.0993

روی هر دو مجموعه‌ی CIFAR، EPALL بالاترین دقت نگهداری میان سه نسخه را دارد (۰/۹۱۵۲ در برابر ۰/۹۰۸۷ و ۰/۵۰۹۳ در برابر ۰/۵۰۱۳) و هم‌زمان بیشترین افت را از ۰/۰۰۴۰ به ۰/۰۰۰۸ و از ۰/۰۱۸۷ به ۰/۰۰۴۷ کاهش می‌دهد. PALL-Adapter در جهت مخالف معاوضه می‌کند: دامنه‌ی ترمیم کوچک‌تر و A_u نزدیک به سطح تصادفی، به بهای دقت نگهداری وقتی آموزش از صفر آغاز می‌شود.


روی TinyImageNet، دشوارترین مجموعه‌داده‌ی ارزیابی این پایان‌نامه با ۲۰ وظیفه، EPALL دقت بیشتری دارد (۰/۴۵۳۳ در برابر ۰/۳۳۶۵). با این حال، بیشترین افت هر دو نسخه‌ی کامل همچنان زیاد است (۰/۰۸۴۰ و ۰/۰۸۵۳). این نتیجه نشان می‌دهد که در محیط دارای بیست وظیفه و سه دوره‌ی آموزش، ظرفیت شبکه برای همه‌ی وظیفه‌ها کافی نیست و مشکل فقط از هم‌پوشانی ناشی نمی‌شود. بازه‌های میان بذرها هم‌پوشانی دارند؛ بنابراین نتایج سه بذر این جدول فقط روندی توصیفی را نشان می‌دهند و رتبه‌بندی روش‌ها را تأیید نمی‌کنند.

۴-۱۰ هزینه: دامنه‌ی ترمیم و حافظه‌ی موردنیاز

۴-۱۰-۱ نسبت اسمی دامنه‌ی ترمیم

PALL-Adapter دامنه‌ی اسمی ترمیم نگه‌داری را نسبت به نسخه‌های کل شبکه به شدت کاهش می‌دهد: از ۰/۰۲۴۰ به ۰/۰۰۳۰ روی CIFAR-10 (کاهش ۸۷/۵ درصدی)، از ۰/۰۲۱۰ به ۰/۰۰۵۵ روی CIFAR-100 (کاهش ۷۴ درصد) و از ۰/۰۹۶۰ به ۰/۰۲۹۲ روی TinyImageNet (حدود ۷۰ درصد).

باید تصریح شود این نسبت‌ها چه چیزی را نمی‌سنجند. آن‌ها تنها دامنه‌ی پیراسنجه‌های آموزش‌پذیر در نقاب ترمیم را می‌پوشانند و بنابراین محاسبات آغاز تا پایان، حافظه‌ی اوج، زمان دیواری یا تعداد کل درایه‌های تغییر یافته را اثبات نمی‌کنند؛ به علاوه، ذخیره‌سازی لایه‌های تطبیق مخصوص وظیفه با تعداد وظایف رشد می‌کند. به همین دلیل این نسبت‌ها در این پایان‌نامه شاخص پیاده‌سازی نامیده می‌شوند و نه معیار کارایی. شکل ۴-۵ این نسبت را در برابر دو معیار کیفیت نشان می‌دهد.



(آ) در برابر دقت نهایی

(ب) در برابر بیشترین افت

شکل ۴-۵: موازنه‌ی میان نسبت اسمی دامنه‌ی ترمیم و دو معیار کیفیت، به تفکیک مجموعه‌داده و وضعیت آزمایشی. محور افقی یک شاخص پیاده‌سازی است و نه سنجی کارایی آغاز تا پایان.

۴-۱۰-۲ محاسبه‌ی حافظه‌ی موردنیاز

چون نسبت دامنه‌ی ترمیم مقدار حافظه را نشان نمی‌دهد، جدول ۴-۱۴ حافظه‌ی موردنیاز را روی دنباله‌های هم‌تراز بذر صفر مستقیماً محاسبه می‌کند. EPALL همه‌ی وظیفه‌ها را در یک مدل مشترک همراه با نقاب‌های تنک و پشتیبان‌ها نگه می‌دارد، در حالی که CLPU برای هر وظیفه‌ی فعال یک شبکه‌ی کامل دارد.

جدول ۴-۱۴: حافظه‌ی موردنیاز روی دنباله‌های هم‌تراز بذر صفر و در بیشترین تعداد وظیفه‌ی فعال محاسبه شده است (بر حسب مبی‌بایت، ۲^{۲۰} بایت). این محاسبه وزن‌های نگه‌داری شده در حافظه، شبکه‌های جداگانه‌ی CLPU، نقاب‌های زیر شبکه، شاخص‌ها و مقادیر پشتیبان‌های تنک و نیز تصویر، برجسب و امتیاز خام نمونه‌های بازپخش را در بر می‌گیرد. حالت بهینه‌ساز، فعال‌سازی‌ها، ذخیره‌سازی داده‌ها و سربار مفسر در این مقدار محاسبه نشده‌اند؛ بنابراین جدول فقط حافظه‌ی حالت پیاده‌سازی را مقایسه می‌کند و درباره‌ی پاک‌شدن دیسک یا بیشترین حافظه‌ی لحظه‌ای ادعایی ندارد.


داده	روش	وظیفه‌ی فعال	مدل پایه	شبکه‌ی وظیفه	نقاب و پشتیبان	مجموع به‌ازای وظیفه
CIFAR-10	EPALL	4	85.16	0.00	45.99	135.85
	CLPU	4	42.59	170.35	0.00	212.94
CIFAR-100	EPALL	8	162.30	0.00	169.29	336.35
	CLPU	8	81.20	649.58	0.00	730.78

در نتیجه، CLPU به ۱/۶ تا ۲/۲ برابر حافظه‌ی بیشتر نیاز دارد و حافظه‌ی آن با افزودن هر وظیفه‌ی فعال، ۳/۴ تا ۳/۸ برابر سریع‌تر افزایش می‌یابد. برتری اندک این روش در دقت، با حافظه‌ای به دست می‌آید که با تعداد وظیفه‌ها به‌صورت خطی رشد می‌کند. شکل ۴-۶ اجزای این حافظه را نشان می‌دهد.

۴-۱۱ ارزیابی حریم خصوصی و ماندگاری

۴-۱۱-۱ حمله‌ی استنتاج عضویت اصلاح‌شده

جدول ۴-۱۵ نتیجه‌ی MIA با پیش‌پردازش هم‌تراز را برای EPALL و PALL اصلی نشان می‌دهد. در این ارزیابی، نمونه‌های عضو و غیرعضو بدون افزایش داده و با پیش‌پردازش یکسان سنجیده می‌شوند و امتیازهای مساوی رتبه‌ی میانگین می‌گیرند.




شکل ۴-۶: اجزای حافظه‌ی موردنیاز در بیشترین تعداد وظیفه‌ی فعال. حافظه‌ی EPALL میان مدل پایه، نقاب‌ها و پشتیبان‌های تنک تقسیم می‌شود، در حالی که بخش اصلی حافظه‌ی CLPU به شبکه‌ی جداگانه‌ی هر وظیفه اختصاص دارد.

جدول ۴-۱۵: حمله‌ی استنتاج عضویت مبتنی بر آستانه‌ی زیان با پیش‌پردازش هم‌تراز. نمونه‌های عضو و غیر‌عضو پیش‌پردازش یکسان و بدون افزایش داده دارند. نتایج EPALL بر پایه‌ی سه بذر و نتایج PALL اصلی بر پایه‌ی دو بذر است. مقدار AUC نزدیک به ۰/۵ فقط نشان می‌دهد این آزمون با توان تشخیص پایین تفاوتی نیافته است و شاهد حذف نیست.

مجموعه داده	روش	تعداد بذر	AUC پیش	AUC پس	Δ فاصله تا ۰/۵
CIFAR-10	EPALL	3	0.5006 ± 0.0205	0.4959 ± 0.0155	0.0027 ± 0.0115
	PALL	2	0.5075 ± 0.0098	0.5091 ± 0.0063	-0.0016 ± 0.0162
CIFAR-100	EPALL	3	0.5015 ± 0.0169	0.4998 ± 0.0033	0.0098 ± 0.0088
	PALL	2	0.5054 ± 0.0169	0.5059 ± 0.0302	-0.0094 ± 0.0008

برای هر دو روش، مقادیر پیش و پس از درخواست به ۰/۵ نزدیک‌اند. تفسیر درست این نتیجه محتاطانه است: حمله‌ی آستانه‌ی زیان در این تنظیم توان تفکیک کافی ندارد، پس نبود تفاوت در این آزمون شاهد حذف نیست و فقط نشان می‌دهد که این آزمون خاص تفاوتی پیدا نکرده است. برای ادعای قوی‌تر، حمله‌های مبتنی بر مدل سایه [۱۱] یا ارزیابی رسمی [۲۰] لازم است. شکل ۴-۷ مقادیر EPALL را در سه وضعیت آزمایشی نشان می‌دهد؛ نتایج PALL اصلی در جدول همین بخش آمده است.



شکل ۴-۷: AUC حمله‌ی استنتاج عضویت پیش و پس از درخواست فراموشی، به تفکیک مجموعه داده و وضعیت آزمایشی. خط افقی سطح ۰/۵ را نشان می‌دهد. نزدیکی به این خط فقط نبود تفاوت در یک آزمون با توان تشخیص پایین را نشان می‌دهد.

۴-۱۱-۲ آماره‌ی تفکیک‌پذیری حمله‌ی آستانه

نبود تفاوت در بخش پیش تنها می‌گوید یک آزمون با توان تشخیص پایین چیزی پیدا نکرد. سنجه‌ی حساس‌تر آن است که به جای AUC میانگین، بدترین نقطه‌ی کاری همان حمله را ببینیم. برای این کار عضو را کلاس مثبت می‌گیریم و روی شبکه‌ای از آستانه‌ها، کران پایین یک‌طرفه‌ی ۹۵ درصد کلاپر-پیرسون برای نرخ مثبت درست و کران بالای همان‌گونه برای نرخ مثبت نادرست را می‌سازیم؛ آنگاه

$$S = \max_{\text{آستانه}} \log \frac{\text{TPR}_{\text{کران پایین}}}{\text{FPR}_{\text{کران بالا}}}, \quad (4-4)$$

که در صفر بریده می‌شود. این کمیت، پیراسنجه‌ی حریم خصوصی تفاضلی یا کران پایین آن نیست. در بازخورد بررسی، ارزیابی تجربی حریم خصوصی و گزارش (ϵ, δ) درخواست شده بود. آزمایش انجام شد و نتیجه‌ی آن در همین جدول آمده است، اما نمی‌توان مقدار به‌دست‌آمده را به‌صورت (ϵ, δ) تفسیر کرد. سه شرط لازم برقرار نیست: آستانه روی همان داده‌ای انتخاب می‌شود که آماره روی آن سنجیده می‌شود؛ ساختار مجموعه داده‌های همسایه وجود ندارد؛ و شمول تصادفی و پیراسنجه‌ی δ تعریف نشده‌اند. بنابراین، فقط آماره‌ی تفکیک‌پذیری همین حمله‌ی خاص است. ارزیابی رسمی به روش [۲۰] انجام نشده و در بخش ۵-۵ به‌عنوان کار آینده پیشنهاد می‌شود. جدول ۴-۱۶ نتیجه را نشان می‌دهد.

جدول ۴-۱۶: آماره‌ی تفکیک‌پذیری S پیش و پس از درخواست فراموشی، بر پایه‌ی امتیازهای هر- نمونه‌ی حمله‌ی عضویت و کران‌های کلاپر- پیرسون یک‌طرفه‌ی ۹۵ درصد. هر خانه روی شش رکورد (بذر $\times$ وظیفه‌ی حذف‌شده) خلاصه شده است. این کمیت پیراسنجه حریم خصوصی تفاضلی نیست و کران پایین معتبری برای آن هم نیست: آستانه روی همان داده انتخاب می‌شود و هیچ‌یک از شرط‌های مجموعه‌داده‌های همسایه، δ و شمول تصادفی برقرار نیست. مقدار بزرگ‌تر تنها یعنی همین حمله‌ی خاص، عضو و غیرعضو را بهتر تفکیک کرده است. سطر $PALL$ خط پایه‌ی مستقیم این مقایسه است و روی همان بذرها، همان وظیفه‌های حذف‌شده و همان روند اجرای حمله محاسبه شده است.

مجموعه‌داده	روش	میانگین S پیش	بیشینه‌ی S پیش	میانگین S پس	بیشینه‌ی S پس
	$PALL$	0.0005	0.0029	0.0013	0.0079
	EPALL	0.0000	0.0000	0.0993	0.4555
CIFAR-10	PALL-Adapter	0.0005	0.0029	0.0058	0.0169
	LoRA	0.0002	0.0014	0.0080	0.0249
	CLPU	0.0023	0.0132	0.0000	0.0000
	$PALL$	0.0000	0.0000	0.0000	0.0000
	EPALL	0.0000	0.0000	0.0995	0.5544
CIFAR-100	PALL-Adapter	0.0075	0.0263	0.0000	0.0000
	LoRA	0.0016	0.0076	0.0018	0.0108
	CLPU	0.0000	0.0000	0.0000	0.0000

این جدول نتیجه‌ای نامطلوب برای روش پیشنهادی نشان می‌دهد. پیش از درخواست، S برای EPALL روی هر دو مجموعه‌داده صفر است؛ پس از درخواست، میانگین آن به ۰/۰۹۹۳ و ۰/۰۹۹۵ و بیشینه‌ی آن به ۰/۴۵۵۵ و ۰/۵۵۴۴ می‌رسد. بنابراین، عملیات حذف در این ارزیابی نمونه‌های وظیفه‌ی هدف را تفکیک‌پذیرتر کرده است. یک توضیح احتمالی آن است که بازنشانی و ترمیم، رفتار مدل روی نمونه‌های حذف‌شده را از الگوی نمونه‌های دیده‌نشده دور می‌کند و این تفاوت برای حمله قابل استفاده می‌شود. نزدیک‌بودن دقت هدف به حدس تصادفی با این یافته ناسازگار نیست؛ مدل ممکن است پاسخ درست ندهد، اما همچنان روی نمونه‌های عضو و غیرعضو به شکل متفاوتی اشتباه کند.

$PALL$ اصلی، که با همان بذرها، وظیفه‌های حذف‌شده و روند حمله سنجیده شده است، این افزایش را نشان نمی‌دهد. میانگین S آن پس از درخواست روی CIFAR-10 برابر ۰/۰۰۱۳ و روی CIFAR-100 صفر است. بنابراین، افزایش تفکیک‌پذیری به بخش محافظت و ترمیم لنگردار EPALL مربوط است و باید

به عنوان هزینه‌ای در کنار بهبود نگهداری در نظر گرفته شود. CLPU پس از حذف کامل شبکه‌ی وظیفه‌ی هدف در هر دو مجموعه داده به $S = 0$ می‌رسد. LoRA و PALL-Adapter نیز با بدنه‌ی ثابت مقادیر بسیار کوچک‌تری دارند که با دامنه‌ی محدود به‌روزرسانی آن‌ها سازگار است. مقدار بزرگ S تفکیک‌پذیری را نشان می‌دهد، اما مقدار کوچک تضمینی برای حذف نیست؛ زیرا ممکن است حمله‌ی به‌کاررفته توان کافی نداشته باشد. از این رو، این جدول می‌تواند شاهده‌ی علیه حذف موفق فراهم کند، اما به‌تنهایی حذف را تأیید نمی‌کند.

۳-۱۱-۴ نسبت هنجار شیب

معیار آخر این بخش، شدت *تداخل* را در لحظه‌ی درخواست می‌سنجد و نه کیفیت فراموشی را: نسبت هنجار ℓ_2 شیب وظیفه‌ی هدف به شیب وظایف نگهداری شده، هر دو روی زیرشبکه‌ی مشترک و پیش از بازنشانی. جدول ۴-۱۷ این نسبت را می‌دهد.

جدول ۴-۱۷: نسبت هنجار ℓ_2 شیب فراموشی به شیب نگهداری روی زیرشبکه‌ی مشترک، در لحظه‌ی درخواست و پیش از بازنشانی (طرح آزمایشی استاندارد، هشت بذر). مقدار نزدیک به یک یعنی دو شیب هم‌مرتبه‌اند. این معیار در بازخورد بررسی با هدف *سنجش تداخل* پیشنهاد شده بود و گزارش می‌شود، اما همان هدف را برآورده نمی‌کند: نسبت هنجار تنها نسبت بزرگی است و هیچ اطلاعاتی از جهت ندارد، پس تعارض یا هم‌راستایی دو شیب را نمی‌سنجد؛ برای آن به کسینوس، ضرب داخلی یا درصد علامت‌های مخالف نیاز است.

مجموعه داده	روش	بذر	نسبت هنجار شیب
CIFAR-10	PALL	8	0.7986 ± 0.3257
	EPALL	8	0.7432 ± 0.6284
CIFAR-100	PALL	8	0.6715 ± 0.2313
	EPALL	8	0.7663 ± 0.3624

مقادیر در بازه‌ی ۰/۶۷ تا ۰/۸۰ قرار می‌گیرند، یعنی دو شیب هم‌مرتبه هستند: شیب فراموشی نه آن‌قدر بزرگ است که شیب نگهداری را بی‌اثر کند و نه آن‌قدر کوچک که نادیده گرفته شود.

اما این معیار تعارض را نمی‌سنجد. چون $\|g_f\|_2 / \|g_r\|_2$ تنها نسبت بزرگی است و هیچ اطلاعاتی از جهت ندارد، دو شیب می‌توانند این نسبت را برابر یک داشته باشند و در عین حال کاملاً هم‌راستا یا کاملاً متضاد باشند. بنابراین این جدول تنها نشان می‌دهد دو شیب در ناحیه‌ی مشترک قابل مقایسه‌اند، و ادعای «رقابت» یا «تعارض» از آن بیرون نمی‌آید. سنجش تعارض به معیارهای جهت‌دار نیاز دارد — کسینوس

زاویه، ضرب داخلی، یا درصد درایه‌هایی که علامت مخالف دارند — که هیچ‌کدام در این کار محاسبه نشده‌اند و در بخش ۵-۵ به‌عنوان کار آینده ثبت می‌شوند. تفاوت میان EPALL و PALL اصلی در این معیار کوچک و در حد انحراف معیار است، که انتظار هم همین بود: این نسبت پیش از اعمال محافظت اندازه‌گیری می‌شود و ویژگی مسئله است و نه ویژگی روش.

۴-۱۱-۴ مرجع بازآموزی هم‌روش

آزمون سخت‌گیرانه‌تر، مقایسه با یک نمونه‌ی تازه از همان روش و همان معماری است که از ابتدا بدون وظیفه‌ی هدف آموزش دیده باشد. جدول ۴-۱۸ نتیجه را برای دو بذر می‌دهد.

جدول ۴-۱۸: ارزیابی مرجع بازآموزی هم‌روش برای EPALL. هر مرجع نمونه‌ای تازه از همان روش و معماری است که از ابتدا بدون وظیفه‌ی فراموش‌شده آموزش دیده است. هر خانه به‌صورت «وظیفه‌ی فراموش‌شده / وظیفه‌های نگه‌داری‌شده» گزارش می‌شود و همه‌ی معیارهای خروجی از برش کلاس محلی وظیفه استفاده می‌کنند. این مقایسه برای تشخیص تفاوت‌ها است و فراموشی دقیق را اثبات نمی‌کند.

مجموعه داده	بذر	توافق	JS	ℓ_2 امتیاز خام	کسینوس ویژگی
CIFAR-10	0	0.0920 / 0.9295	0.0219 / 0.0194	0.8111 / 1.4991	0.9085 / 0.7497
CIFAR-10	1	0.9550 / 0.9576	0.0044 / 0.0119	0.3204 / 1.4175	0.9114 / 0.7580
CIFAR-100	0	0.0000 / 0.6000	0.0769 / 0.0644	2.3804 / 1.8112	0.9211 / 0.8352
CIFAR-100	1	0.9820 / 0.5998	0.0133 / 0.0573	0.8028 / 1.7347	0.9032 / 0.8342

توافق روی وظیفه‌های نگه‌داری‌شده در بازه‌ی ۰/۶۰ تا ۰/۹۶ است؛ بنابراین مدل فراموش‌کرده و مرجع بازآموزی روی وظیفه‌های فعال رفتار نسبتاً مشابهی دارند. توافق روی وظیفه‌ی فراموش‌شده میان ۰/۰ و ۰/۹۸ تغییر می‌کند. این ارزیابی با دو بذر، هم‌ارزی با بازآموزی دقیق را نشان نمی‌دهد؛ زیرا ممکن است هر دو مدل در سطح حدس تصادفی باشند، اما روی نمونه‌های یکسان اشتباه نکنند. با این حال، بدون مقایسه‌ی دو اجرای مستقل بازآموزی نمی‌توان فقط بر پایه‌ی این تغییر، حذف دقیق توزیعی را رد کرد.

۴-۱۱-۵ ماندگاری سرکوب

پژوهش‌هایی مانند UnCLE [۵۷] و CATA [۵۸] نشان می‌دهند که دقت بلافاصله پس از درخواست کافی نیست. جدول ۴-۱۹ وظیفه‌ی فراموش‌شده را از لحظه‌ی حذف تا پایان دنباله‌ی درخواست‌ها دنبال

می‌کند. معیار این ارزیابی فاصله تا حدس تصادفی $|A_u - c|$ است، نه دقت خام. هدف حذف، نزدیک کردن عملکرد به حدس تصادفی است؛ بنابراین فاصله گرفتن در هر دو جهت نامطلوب است.

در دو بذریه ارزیابی (۰ و ۱)، پس از نخستین حذف درخواست آموزشی نیز وجود دارد. برای بذریه ۰، الگوی CIFAR-10 برابر T T T T F T F F و الگوی CIFAR-100 برابر T T F T F T F T × 7 است. این الگو در همه‌ی بذرها یکسان نیست؛ برای نمونه، در بذریه ۵ مجموعه داده‌ی CIFAR-100 هر سه حذف در پایان دنباله قرار دارند (T × 10 F F F) و پس از نخستین حذف هیچ آموزشی انجام نمی‌شود. رانش وظیفه‌ی فراموش شده به دو بخش تقسیم می‌شود: تغییر ناشی از درخواست‌های آموزشی میان دو حذف و تغییر ناشی از درخواست‌های حذف بعدی. این دو بخش با استفاده از شناسه‌ی رویداد و مقادیر پیش و پس از هر حذف محاسبه می‌شوند؛ اگر میان دو حذف آموزشی انجام نشده باشد، سهم آموزش صفر است.


جدول ۴-۱۹: ماندگاری سرکوب وظیفه‌ی فراموش شده تا پایان دنباله‌ی درخواست‌ها (دو بذریه، شش وظیفه‌ی حذف شده برای هر مجموعه داده و روش). همه‌ی سنجها بر پایه‌ی فاصله تا حدس تصادفی $|A_u - c|$ محاسبه شده‌اند، نه دقت خام. برای وظیفه‌ی حذف شده، پایین رفتن از دقت حدس تصادفی نیز مانند بالارفتن از آن به معنای فاصله گرفتن از هدف فراموشی است. «بازگشت» بیشترین افزایش $|A_u - c|$ نسبت به لحظه‌ی بلافاصله پس از حذف است. در دو بذریه ارزیابی (۰ و ۱)، پس از نخستین حذف درخواست آموزشی نیز وجود دارد؛ این ویژگی در همه‌ی بذرها برقرار نیست. رانش کل به سهم درخواست‌های آموزشی میان دو حذف و سهم درخواست‌های حذف بعدی تقسیم می‌شود و مجموع این دو سهم برابر رانش خالص است. ستون‌های بازگشت و سهم فقط برای چهار وظیفه‌ای گزارش می‌شوند که پس از حذف همچنان رویداد دیگری دارند.

مجموعه داده	روش	$ A_u - c $ بی‌درنگ	$ A_u - c $ نهایی	میانگین بازگشت	بدترین بازگشت	سهم آموزش	سهم حذف
CIFAR-10	PALL	0.0011	0.0097	0.0179	0.0490	+0.0019	+0.0111
	EPALL	0.0018	0.0024	0.0136	0.0370	+0.0063	-0.0053
	PALL-Adapter	0.0182	0.0098	0.0024	0.0060	-0.0150	+0.0024
	LoRA	0.0071	0.0071	0.0000	0.0000	0.0000	0.0000
	CLPU	0.0198	0.0198	0.0000	0.0000	0.0000	0.0000
CIFAR-100	PALL	0.0087	0.0017	0.0030	0.0100	-0.0090	-0.0015
	EPALL	0.0137	0.0040	0.0040	0.0100	-0.0120	-0.0025
	PALL-Adapter	0.0230	0.0260	0.0145	0.0500	+0.0100	-0.0055
	LoRA	0.0053	0.0053	0.0000	0.0000	0.0000	0.0000
	CLPU	0.0140	0.0140	0.0000	0.0000	0.0000	0.0000

بدترین بازگشت مشاهده شده روی CIFAR-10 برابر ۰/۰۴۹۰ برای PALL و ۰/۰۳۷۰ برای EPALL و ۰/۰۰۶۰ برای PALL-Adapter است؛ روی CIFAR-100 برابر ۰/۰۵۰۰ برای PALL-Adapter و ۰/۰۱۰۰ برای PALL و EPALL. LoRA و CLPU بازگشت دقیقاً صفر دارند، چون پیراسنجه‌های

وظیفه‌ی حذف‌شده در آن‌ها از پیراسنجه‌های وظایف بعدی جدا هستند و هیچ درخواست بعدی آن‌ها را لمس نمی‌کند.

تفکیک سهم‌ها نتیجه‌ی غیرمنتظره‌ای می‌دهد. روی CIFAR-100، سهم درخواست‌های آموزشی برای هر دو نسخه‌ی PALL منفی است (-0.0090 و -0.0120)؛ یعنی یادگیری وظایف تازه، وظیفه‌ی فراموش‌شده را به شانس نزدیک‌تر می‌کند نه دورتر. روی CIFAR-10 همین سهم اندکی مثبت است ($+0.0019$ و $+0.0063$) اما بخش عمده‌ی رانش PALL از درخواست‌های حذف بعدی می‌آید ($+0.0111$)، در حالی که همین سهم برای EPALL منفی است (-0.0053). تفسیر این تفاوت آن است که حفاظت رتبه‌بندی‌شده، علاوه بر مهار آسیب به وظایف نگه‌داری‌شده، مانع از آن می‌شود که حذف‌های بعدی وظیفه‌ی پیش‌تر حذف‌شده را دوباره از سطح تصادفی دور کنند. با این حال هیچ‌کدام از این تفاوت‌ها با دو بذر و چهار وظیفه‌ی دارای افق پیگیری، آزمون معناداری را برنمی‌تابد؛ آن‌ها را باید مشاهده‌ی توصیفی خواند. جمع‌بندی این است که سرکوب ماندگار است اما کاملاً ثابت نمی‌ماند، و علت اصلی تغییر آن درخواست‌های حذف بعدی است نه یادگیری تازه. شکل ۴-۸ مسیرها را نشان می‌دهد.



شکل ۴-۸: مسیر فاصله تا شانس $|A_u - c|$ برای وظیفه‌ی فراموش‌شده، از لحظه‌ی حذف به بعد. منحصرأ نخستین وظیفه‌ی حذف‌شده‌ی هر اجرا دنبال می‌شود. برجسب هر نقطه‌ی محور افقی نشان می‌دهد که تغییر تا آن نقطه از درخواست‌های آموزشی میان‌راهی آمده است یا از یک درخواست حذف بعدی. چون موقعیت درخواست‌های حذف با بذر تغییر می‌کند، طول و ترکیب افق پیگیری میان بذرها یکسان نیست؛ منحنی‌ها تا آخرین نقطه‌ای رسم شده‌اند که همه‌ی اجراهای آن مجموعه‌داده در آن هم حاضرند و هم نوع رویداد یکسانی دارند، و پس از آن قطع می‌شوند تا میانگین‌گیری روی رویدادهای ناهمگون رخ ندهد. به همین دلیل CIFAR-10 سه نقطه و CIFAR-100 پنج نقطه دارد. هر نقطه‌ی هر منحنی میانگین دو بذر همان روش است. جدول ۴-۱۹ از این محدودیت مصون است، چون آماره‌های آن به‌ازای هر اجرا و مستقل از شکل دنباله محاسبه می‌شوند.

۱۲-۴ مطالعات حساسیت

۱-۱۲-۴ انتخاب لنگر

بخش ۳-۳-۳ اشاره کرد که لنگرزدن به θ^{old} یک ایراد مفهومی دارد: آن وزن‌ها خودشان اطلاعاتی از وظیفه‌ی فراموش‌شونده حمل می‌کنند. جدول ۲۰-۴ جایگزین θ^{reinit} را روی هشت بذر هم‌تراز از طرح آزمایشی استاندارد می‌سنجد. چون protect_anchor فقط روی EPALL اثر دارد، دو حالت آزمایشی تنها در همین یک تنظیم تفاوت دارند و بذرها جفت می‌شوند؛ حالت آزمایشی reinit زیر برچسب آزمایش مستقل *_standard_reinit_v1 اجرا شده تا جدول‌های اصلی دست‌نخورده بمانند.

جدول ۲۰-۴: مطالعه‌ی جمله‌ی لنگر ℓ_2 رابطه‌ی (۱۱-۳) روی هشت بذر هم‌تراز از طرح آزمایشی استاندارد. گزینه‌ی old به وزن‌های پیش از درخواست لنگر می‌زند و reinit به نمونه‌ای تازه از مقدارگذاری اولیه. دو حالت آزمایشی تنها در همین یک تنظیم تفاوت دارند و به‌ازای هر بذر دنباله‌ی درخواست یکسانی می‌بینند، پس هر بذر یک جفت هم‌تراز می‌سازد. ستون آخر تعداد بذرها به سود old از هشت بذر است، به ترتیب برای دقت نهایی، فراموشی، بیشترین افت و دقت هدف؛ A_u بر حسب فاصله تا شانس امتیازدهی شده و مجموع کمتر از هشت به معنای وجود گره است. هیچ‌یک از ده آزمون این خانواده پس از اصلاح Holm در سطح ۰/۰۵ باقی نمی‌ماند، پس این جدول توصیفی است.

مجموعه داده	لنگر	دقت نهایی	فراموشی	بیشترین افت	دقت هدف	جفت به سود old
CIFAR-10	old	0.9433 ± 0.0160	0.2872 ± 0.0249	0.0027 ± 0.0031	0.4863 ± 0.0216	3 / 3 / 3 / 3
	reinit	0.9446 ± 0.0199	0.2787 ± 0.0125	0.0009 ± 0.0015	0.4923 ± 0.0147	
CIFAR-100	old	0.7371 ± 0.0093	0.1958 ± 0.0121	0.0056 ± 0.0062	0.0959 ± 0.0075	6 / 7 / 6 / 2
	reinit	0.7340 ± 0.0126	0.1987 ± 0.0120	0.0145 ± 0.0105	0.1001 ± 0.0037	

نتیجه‌ی حاصل از هشت بذر با مطالعه‌ی پیشین با دو بذر هم‌خوان نیست و جهت آن روی دو مجموعه داده یکسان نیست. روی CIFAR-100 برتری با θ^{old} است: فراموشی در هفت جفت از هشت جفت به سود آن است ($d_z = 1/06$)، بیشترین افت در شش جفت ($d_z = 1/04$)، میانگین اختلاف $0/089$ و دقت نهایی در شش جفت. روی CIFAR-10 تفاوت‌ها در حد نوسان بذرهاست و اندکی به سود θ^{reinit} می‌چرخد، اما هیچ معیاری بیش از پنج جفت از هشت جفت را نمی‌گیرد و بزرگی اختلاف دقت $0/013$ است. تنها معیاری که در هر دو مجموعه داده به سود θ^{reinit} می‌ماند، فاصله‌ی دقت هدف تا شانس است و آن هم با اختلاف میانگین $0/030$ روی CIFAR-100. مهم‌تر از همه، این خانواده ده آزمون دارد و پس از اصلاح Holm هیچ معیاری در هیچ جهتی در سطح $0/05$ باقی نمی‌ماند؛ کوچک‌ترین

p خام برابر ۰/۰۳۵ است که پس از اصلاح به ۰/۳۵ می‌رسد.

پیش‌فرض پیاده‌سازی θ^{old} است و همه‌ی جدول‌های این پایان‌نامه با همان تولید شده‌اند. سه دلیل پشت این انتخاب است. نخست، لنگر تنها روی $S_{\text{crit}} \subseteq M_f \cap M_r$ عمل می‌کند و فراموشی از راه بازنشانی ناحیه‌ی انحصاری $M_f \setminus M_r$ رخ می‌دهد؛ پس لنگر یک اهرم نگه‌داری است نه اهرم فراموشی، و باید عمدتاً با معیارهای نگه‌داری داوری شود — جایی که روی CIFAR-100 برتری با θ^{old} است و روی CIFAR-10 تفاوتی نیست. دوم، θ^{reinit} آن استقلال از داده‌ای را که وعده می‌دهد در عمل فراهم نمی‌کند: شاخه‌های بازنشانی ارثی همچنان به پشتیبان‌های تنک وابسته به داده‌ی قدیمی تکیه دارند، پس مسیر نشت از راه دیگری باز می‌ماند و محدودیت دامنه‌ی ادعای حذف (بخش ۴-۵) همچنان برقرار است. سوم، θ^{old} در زمان درخواست نیز سریع‌تر است (۳/۸۷ ثانیه روی CIFAR-100 و ۰/۴۷ ثانیه روی CIFAR-10 به‌طور میانگین). ایراد مفهومی θ^{old} سر جای خود باقی است و در بخش ۴-۵ به‌عنوان محدودیت ثبت می‌شود، اما شاهد حاصل از هشت بذر آن را به توصیه‌ی عملی تبدیل نمی‌کند.

در بازخورد بررسی، θ^{reinit} به‌عنوان مرجع جمله‌ی لنگر پیشنهاد شده بود؛ زیرا توزیع مقدارگذاری اولیه از داده‌ها مستقل است و اطلاعات وظیفه‌ی حذف‌شونده را دوباره وارد نمی‌کند. این استدلال برای خود جمله‌ی لنگر درست است، اما در سطح کل سامانه کافی نیست. مسیر بازنشانی PALL همچنان از پشتیبان‌های تنک وابسته به داده‌های پیشین استفاده می‌کند؛ بنابراین، مستقل‌کردن لنگر فقط یکی از مسیرهای وابستگی را حذف می‌کند. افزون بر این، تضمین حذف دقیق فقط زمانی برقرار است که حذف روی پیراسنجه‌های غیرمشترک نیز دقیق باشد. ارزیابی مرجع بازآموزی در بخش ۴-۱۱-۴ این شرط را تأیید نمی‌کند؛ توافق روی وظیفه‌ی هدف میان ۰/۰۰ و ۰/۹۸ تغییر می‌کند. مقایسه‌ی هشت بذر نیز هیچ برتری تجربی برای θ^{reinit} نشان نداد. به همین دلیل، پیشنهاد بررسی شد اما در روش نهایی پذیرفته نشد.

۴-۱۲-۲ معیار اهمیت: بزرگی شیب در برابر انرژی تعارض

برای روشن شدن اینکه انتخاب معیار اهمیت تا چه اندازه بر نتیجه‌ی حذف اثر می‌گذارد، جدول ۴-۲۱ دو معیار رتبه‌بندی معرفی شده در معادلات (۳-۸) و (۳-۱۰) را در شرایط آزمایشی یکسان مقایسه می‌کند.

جدول ۴-۲۱: مقایسه‌ی دو معیار رتبه‌بندی اهمیت روی دو بذر هم‌تراز؛ توصیفی. بزرگی شیب رابطه‌ی (۳-۸) پیش‌فرض است و انرژی تعارض گزینه‌ی جانشین رابطه‌ی (۳-۱۰).

مجموعه داده	روش	معیار اهمیت	دقت نهایی	بیشترین افت
CIFAR-10	PALL-Adapter	بزرگی شیب	0.8166 ± 0.0249	0.0160 ± 0.0057
		انرژی تعارض	0.8259 ± 0.0136	0.0063 ± 0.0110
CIFAR-100	EPALL	بزرگی شیب	0.4933 ± 0.0083	0.0060 ± 0.0028
		انرژی تعارض	0.5040 ± 0.0085	0.0230 ± 0.0099

نتیجه وابسته به مسیر و مجموعه داده است: انرژی تعارض به مسیر لایه‌ی تطبیق روی CIFAR-10 کمک می‌کند (بیشترین افت از ۰/۰۱۶۰ به ۰/۰۰۶۳) اما به EPALL روی CIFAR-100 آسیب می‌زند (بیشترین افت از ۰/۰۰۶۰ به ۰/۰۲۳۰). به همین دلیل بزرگی شیب معیار پیش‌فرض می‌ماند. نکته‌ی عملی مهم این است که معیار تعارض به شیب وظیفه‌ی هدف نیاز دارد و بنابراین باید در پنجره‌ی دسترسی پیش از حذف محاسبه شود؛ یعنی حتی اگر سود می‌داشت، هزینه‌ی معماری بیشتری داشت.

۳-۱۲-۴ انتقال میان معماری با ViT

برای سنجش اینکه نتیجه‌ها به معماری شبکه‌ی هم‌پیچشی محدود نیستند، جدول ۴-۲۲ همان مقایسه‌ی EPALL و PALL اصلی را روی بدنه‌ی مبدل بینایی ViT-T/8 [۳۰] تکرار می‌کند.

جدول ۴-۲۲: انتقال میان معماری روی بدنه‌ی ViT-T/8 با دو بذر هم‌تراز؛ توصیفی و بدون ادعای معناداری.

مجموعه داده	روش	دقت نهایی	بیشترین افت	دقت هدف
CIFAR-10	PALL	0.8346 ± 0.0366	0.0192 ± 0.0159	0.5135 ± 0.1846
	EPALL	0.8364 ± 0.0592	0.0193 ± 0.0230	0.5585 ± 0.0778
CIFAR-100	PALL	0.3921 ± 0.0010	0.0190 ± 0.0071	0.2160 ± 0.0792
	EPALL	0.3990 ± 0.0063	0.0100 ± 0.0028	0.2120 ± 0.0764

روی Split-CIFAR-100، EPALL بیشترین افت میانگین را از ۰/۰۱۹۰ به ۰/۰۱۰۰ کاهش می‌دهد و دقت را کمی بهبود می‌دهد (۰/۳۹۹۰ در برابر ۰/۳۹۲۱)، در حالی که A_u نزدیک به سطح تصادفی می‌ماند. روی Split-CIFAR-10 میانگین‌ها تقریباً برابرند. بنابراین انتقال به معماری مبدل وابسته به مجموعه داده

است و با دو بذر هیچ ادعای معناداری مطرح نمی‌شود.

۴-۱۲-۴ عرض گلوگاه لایه‌ی تطبیق


جدول ۲۳-۴ بررسی عرض گلوگاه را نشان می‌دهد. نتیجه یکنواخت نیست: نه دقت و نه بیشترین افت با افزایش عرض روند مشخصی ندارند. بنابراین انتخاب ۱۶ یک پیش‌فرض فشرده است و نه یک بهینه‌ی ادعا شده.

جدول ۲۳-۴: بررسی عرض گلوگاه مخصوص وظیفه روی CIFAR-10 با دو بذر هم‌تراز؛ توصیفی. گلوگاه مشترک روی ۱۶ ثابت است. هیچ‌یک از معیارها نسبت به عرض یکنواخت نیست، پس ۱۶ یک پیش‌فرض فشرده است و نه بهینه‌ی ادعا شده.


گلوگاه وظیفه	دقت نهایی	بیشترین افت	دقت هدف	R_{upd}
4	0.8220	0.0035	0.5215	0.0024
8	0.8197	0.0097	0.5425	0.0031
16	0.8166	0.0160	0.5247	0.0045
32	0.8266	0.0028	0.5058	0.0074
64	0.8170	-0.0218	0.5085	0.0130
128	0.8251	-0.0003	0.5000	0.0237

شکل‌های ۹-۴ و ۱۰-۴ نمای گرافیکی این بررسی و نقشه‌ی حرارتی دقت یک اجرای نماینده را نشان می‌دهند. علاوه بر این، بررسی ابرپیراسنجه‌ای پیش‌آموزش‌دیده‌ی مبتنی بر هنجارسازی قدیمی از شواهد تصحیح‌شده کنار گذاشته شده است، چون پیش‌پردازش ورودی آن با بدنه‌ی ImageNet هم‌خوان نبود.

ترکیب هم‌پوشانی. گزارش‌های اجرای مسیر لایه‌ی تطبیق نسبت $|S_{\text{crit}}|/|S_{\text{forget}}|$ را در بازه‌ی ۰/۳۵ تا ۰/۵۶ و سهم درایه‌های دارای حفاظت سخت را در بازه‌ی ۰/۰۷ تا ۰/۱۱ ثبت می‌کنند. این مقادیر نشان می‌دهند ناحیه‌ی بحرانی در لایه‌ی تطبیق مشترک بخش قابل‌توجهی از ناحیه‌ی هدف است — یعنی شرایط برای اثرگذاری نقاب نرم فراهم بود — و بی‌اثر بودن آن در نقطه‌ی پایان (بخش ۴-۸) به کوچک بودن ناحیه ربطی ندارد.




(آ) گلوگاه مخصوص وظیفه



(ب) گلوگاه مشترک

شکل ۴-۹: بررسی عرض گلوگاه مخصوص وظیفه و گلوگاه مشترک روی CIFAR-10. هیچ‌یک از دو منحنی یکنواخت نیست.



شکل ۴-۱۰: نقشه‌ی حرارتی دقت وظیفه‌ها در طول یک اجرای نماینده‌ی PALL-Adapter. سطرها وظیفه‌ها و ستون‌ها درخواست‌ها هستند؛ افت ستونی در نقطه‌ی هر درخواست فراموشی دیده می‌شود.

۱۳-۴ تهدیدهای اعتبار

اعتبار درونی. خطر اصلی، انتساب بهبود به مؤلفه‌ی نادرست است. کاهش این خطر با سه سازوکار انجام شده است: جفت‌شدگی دنباله‌ها بر اساس بذر، کنترل‌های مؤلفه‌ای که هر بار فقط یک جزء را عوض می‌کنند، و هم‌ترازی مولد اعداد تصادفی در حالت‌های لایه‌ی تطبیق که باعث شد بی‌اثر بودن نقاب نرم از نوسان تصادفی قابل تفکیک باشد.

اعتبار آماری. کف p قابل‌دستیابی برای هر آزمون جداگانه است و به تعداد جفت‌های بدون تساوی بستگی دارد؛ برای سطرهای بدون تساوی CIFAR-100 برابر 0.003906 و برای دقت نهایی CIFAR-10 برابر 0.007812 است. شش آزمون هم‌زمان با اصلاح Holm تصحیح شده‌اند و چهار مورد از آن‌ها در سطح 0.05 باقی می‌مانند. تحلیل‌های مبتنی بر دو و سه بذر صریحا توصیفی برجسته‌اند و در هیچ ادعای معناداری وارد نشده‌اند. بازه‌های باز نمونه‌گیری نیز توصیفی‌اند و آزمون فرض نیستند.

ناپایداری نتیجه با افزودن بذر. یک هشدار روش‌شناختی مشخص از همین کار بیرون آمد: افزودن سه بذر به کنترل‌های مؤلفه‌ای، جدایی جمله‌ی لنگر روی CIFAR-100 را از میان برد (بخش ۴-۶). این نشان می‌دهد بازه‌های باز نمونه‌گیری نمونه‌ی کوچک تا چه اندازه می‌توانند شکننده باشند و چرا نباید انتساب سازوکار را تنها بر پایه‌ی کمترین تعداد بذری گزارش کرد که نتیجه در آن پایدار به نظر می‌رسد.

اعتبار بیرونی. همه‌ی نتایج روی سه مجموعه داده‌ی تصویری با تقسیم مصنوعی وظیفه‌ها به دست آمده‌اند. تعمیم به داده‌های واقعی با مرزهای نامشخص وظیفه، داده‌های چندحالتی یا مقیاس‌های بزرگ‌تر آزموده نشده است. آزمون ViT فقط نشانه‌ای اولیه از انتقال میان معماری‌ها فراهم می‌کند.

اعتبار سازه‌ای. خطر جدی‌تر، گرفتن معیارها به‌جای مفهوم است. سه نمونه‌ی مشخص: A_u نزدیک به سطح تصادفی معیار حذف نیست، R_{upd} معیار کارایی نیست، و AUC نزدیک به 0.5 در MIA معیار حریم خصوصی نیست. تمام متن این فصل بر همین تفکیک‌ها اصرار کرده است.

اعتبار محاسباتی. زمان درخواست روی یک پیکربندی سخت‌افزاری مشخص اندازه‌گیری شده و برای سخت‌افزارهای متفاوت مقیاس‌بندی نشده است. بنابراین، فقط برای مقایسه‌ی تقریبی روش‌ها در همین محیط مناسب است.

۱۴-۴ جمع‌بندی یافته‌ها

پاسخ‌های تجربی به پرسش‌های پژوهش در پنج بند زیر جمع‌بندی می‌شوند؛ هر پاسخ فقط در محدوده‌ی طرح‌های آزمایشی و تعداد بذرها‌ی گزارش‌شده معتبر است.

RQ1 — بله، با دامنه‌ی مشخص. EPALL هم‌زمان A_u را به سطح تصادفی می‌رساند و دقت نگه‌داری را نسبت به PALL اصلی بهبود می‌دهد؛ این بهبود روی هر دو مجموعه‌داده پس از اصلاح Holm باقی می‌ماند. بیشترین افت تنها روی CIFAR-100 معنادار می‌ماند.

RQ2 — دقت نزدیک، با زمان پردازش بیشتر. دقت EPALL روی CIFAR-10 کمتر از یک واحد درصد پایین‌تر از CLPU است و روی CIFAR-100 در محدوده‌ی پراکندگی بذرها با آن تفاوت اندکی دارد. در مقابل، CLPU به $1/6$ تا $2/2$ برابر حافظه‌ی بیشتر نیاز دارد و EPALL درخواست را کندتر از PALL اصلی پردازش می‌کند.

RQ3 — شواهد مثبت اما مشروط؛ اثر مستقل هم‌پوشانی اثبات نشده است. آزمون موقعیت درخواست روندی توصیفی نشان می‌دهد: بیشترین افت PALL اصلی با افزایش سطح بالا می‌رود و EPALL تقریباً ثابت می‌ماند، اما سطوح آزمایش هم‌پوشانی واقعی را کنترل نمی‌کنند. در بررسی تنکی (بخش ۴-۵) هویت و موقعیت وظیفه‌ی هدف ثابت می‌ماند و هم‌پوشانی اندازه‌گیری‌شده بیش از ده برابر تغییر می‌کند. میان هم‌پوشانی و میزان بهبود، همبستگی رتبه‌ای مثبت و معناداری وجود دارد؛ اما چون تنکی ظرفیت را نیز تغییر می‌دهد، اثر مستقل هم‌پوشانی قابل تعیین نیست.

RQ4 — تنها رتبه‌بندی با بودجه‌ی ثابت. کیفیت انتخاب به‌روشنی و روی هر دو مجموعه‌داده مؤثر است. دو جزء دیگر سهم مستقل نشان نمی‌دهند، اما کنترل‌های موجود برای رد ضرورت آن‌ها کافی نیستند. افزون بر این، رتبه‌بندی در همه‌ی معیارها برتر نیست: محافظت بدون رتبه‌بندی بیشترین افت کمتری دارد.

RQ5 — نه. نقاب نرم در نقطه‌ی پایان مسیر لایه‌ی تطبیق اثر قابل اندازه‌گیری ندارد و سرکوب به بازنشانی مسیر هدف نسبت داده می‌شود.

فصل ۵

جمع‌بندی و کارهای آینده

۵-۱ خلاصه‌ی کار انجام‌شده

این پایان‌نامه مسئله‌ی فراموشی انتخابی در یادگیری پیوسته را از زاویه‌ی هم‌پوشانی پیراسنجه‌ها بررسی کرد. نقطه‌ی شروع، این مشاهده بود که آسیب جانبی یک درخواست حذف، تصادفی و غیرقابل توضیح نیست: بسط مرتبه‌ی اول بخش ۲-۳ نشان داد که بخش عمده‌ی این آسیب از ناحیه‌ی مشترک میان زیرشبکه‌ی وظیفه‌ی هدف و زیرشبکه‌های فعال انتظار می‌رود، و درون همان ناحیه هم توزیع یکنواخت نیست؛ بخش بالایی توزیع حساسیت، بخش غالب مجموع را می‌سازد.

این تحلیل به طراحی EPALL انجامید. روش پیشنهادی، هم‌پوشانی ساختاری $S_{\text{share}} = M_f \cap M_r$ را از نقاب‌های دودویی ذخیره‌شده محاسبه می‌کند، وزن‌های مشترک را بر پایه‌ی بزرگی شیب زیان وظیفه‌های نگه‌داری شده رتبه‌بندی می‌کند و مهم‌ترین بخش را با نسبت ρ انتخاب می‌کند. سپس هنگام ترمیم، همین وزن‌ها با یک جمله‌ی لنگر ℓ_2 محافظت می‌شوند. منطق بازنشانی PAL بدون تغییر باقی می‌ماند و نوآوری در انتخاب و محافظت از وزن‌های مهم است.

در کنار روش اصلی، PAL-Adapter برای کاهش دامنه‌ی به‌روزرسانی طراحی و ارزیابی شد. این روش از یک بدنه‌ی ثابت، یک لایه‌ی تطبیق مشترک، یک لایه‌ی تطبیق مخصوص هر وظیفه و یک فرایند فراموشی سه‌مرحله‌ای با نقاب نرم استفاده می‌کند. لم ۳-۴ یک کران بالای محدود برای افت یکی از زیرمرحله‌ها ارائه می‌دهد و نشان می‌دهد این کران با افزایش شدت محافظت p بیشتر نمی‌شود. با این حال، مقایسه‌ی دو کران رابطه‌ای میان افت‌های واقعی دو حالت اثبات نمی‌کند (مشاهده‌ی ۳-۶) و این کران به افت عملکرد آغاز تا پایان گسترش نمی‌یابد (بخش ۳-۵-۴).

ارزیابی روی سه مجموعه داده و در چند طرح آزمایشی انجام شد: مقایسه‌ی یازده روش با هشت بذر، آزمون موقعیت درخواست با ۳۰۰ اجرا، دو بررسی جداگانه‌ی اجزای روش با هشت و سه بذر، محاسبه‌ی مستقیم حافظه‌ی موردنیاز و ارزیابی‌های حریم خصوصی و ماندگاری.

۵-۲ پاسخ به پرسش‌های پژوهش

RQ1: آیا محافظت از وزن‌های مشترک و مهم، هم‌زمان سرکوب و نگهداری را ممکن می‌کند؟ بله. EPALL دقت وظیفه‌ی هدف را به حدس تصادفی نزدیک می‌کند و دقت وظیفه‌های نگهداری شده را نسبت به PALL افزایش می‌دهد. اختلاف جفتی دقت روی هر دو مجموعه داده برابر $p = 0.007812$ است و پس از اصلاح هولم برای آزمون‌های متعدد نیز معنادار می‌ماند. بیشترین افت روی هر دو مجموعه داده کاهش می‌یابد، اما این کاهش فقط روی CIFAR-100 پس از اصلاح هولم معنادار است. معیار F_{avg} روی CIFAR-10 تنها معیاری است که بهبود پیوسته نشان نمی‌دهد.

RQ2: روش دارای مدل مشترک تا چه اندازه به مرجع جداسازی نزدیک می‌شود؟ دقت دو روش نزدیک است، اما هم‌ارزی آماری آن‌ها اثبات نشده است؛ زیرا آزمون هم‌ارزی انجام نشده است. فاصله‌ی دقت روی CIFAR-10 کمتر از یک واحد درصد است و مقادیر CIFAR-100 نیز از نظر عددی نزدیک‌اند. CLPU درخواست را سریع‌تر پردازش می‌کند، اما به $1/6$ تا $2/2$ برابر حافظه‌ی بیشتر نیاز دارد و حافظه‌ی آن با تعداد وظیفه‌ها سریع‌تر رشد می‌کند. بنابراین، اگر نگهداری یک شبکه‌ی کامل برای هر وظیفه ممکن باشد، CLPU انتخاب مناسبی است؛ در غیر این صورت، EPALL با یک مدل مشترک به دقتی نزدیک می‌رسد.

RQ3: آیا با افزایش هم‌پوشانی، محافظت اهمیت بیشتری پیدا می‌کند؟ شواهد از این فرض پشتیبانی می‌کنند، اما اثر مستقل هم‌پوشانی اثبات نشده است. در بخش ۴-۵، دنباله و وظیفه‌ی هدف ثابت می‌مانند و تنگی زیرشبکه تغییر می‌کند؛ در نتیجه، $|S_{share}|$ بیش از ده برابر تغییر می‌کند و با میزان بهبود همبستگی رتبه‌ای مثبت و معناداری دارد. این رابطه روی CIFAR-10 یکنواخت است، اما روی CIFAR-100 روند کاملاً یکنواختی ندارد. چون تنگی ظرفیت را نیز تغییر می‌دهد و هر حالت فقط پنج بذر دارد، نمی‌توان اثر هم‌پوشانی را مستقل از ظرفیت تعیین کرد. آزمون موقعیت درخواست در بخش ۴-۴ نیز روندی سازگار با این فرض نشان می‌دهد.

RQ4: کدام جزء روش باعث بهبود می‌شود؟ مهم‌ترین عامل، کیفیت انتخاب وزن‌ها است. انتخاب تصادفی همان تعداد وزن روی هر دو مجموعه داده نتیجه‌ی ضعیف‌تری دارد و بازه‌ی اختلاف آن صفر را

در بر نمی‌گیرد؛ بنابراین رتبه‌بندی حساسیت مؤثر است، نه فقط اندازه‌ی بودجه. دو جزء دیگر بهبود مستقل نشان نمی‌دهند، اما این نتیجه باید با احتیاط تفسیر شود. حذف فیلتر اشتراک نتیجه را تغییر نمی‌دهد، زیرا نقاب ترمیم در مرحله‌ی بعد همچنان $M_f \cap M_r$ است. حذف جمله‌ی جریمه‌ی ℓ_2 نیز پشتیبان‌ها را حفظ می‌کند؛ بنابراین فقط اثر مستقل جمله‌ی جریمه را می‌سنجد و کل محافظت را حذف نمی‌کند. همچنین، حالت مبتنی بر هم‌پوشانی به‌تنهایی بیشترین افت کمتری دارد؛ پس رتبه‌بندی در همه‌ی معیارها برتر نیست و میان معیارها موازنه وجود دارد.

RQ5: آیا سازوکار آگاه از هم‌پوشانی در مسیر کم‌پیراسنجه کار می‌کند؟ نه. حالت‌های آزمایشی کامل و یکنواخت عملاً یکسان‌اند و حالت‌های آزمایشی کامل و نقاب بدون صعود در دقت و بیشترین افت تفاوتی ندارند. چون حالت‌های آزمایشی از نظر مولد اعداد تصادفی هم‌تراز طراحی شده‌اند، این یکسانی ناشی از نوسان تصادفی نیست. تنها مؤلفه‌ی با اثر قابل‌اندازه‌گیری، گام صعود طبقه‌بند است. روی CIFAR-100 حالت آزمایشی فقط بازنشانی حتی بهتر است. سرکوب مشاهده‌شده در این مسیر به بازنشانی مسیر هدف نسبت داده می‌شود و نه به نقاب نرم. بررسی شدت نقاب پیوسته در بخش ۴-۸-۱ این نتیجه را تقویت می‌کند و علت آن را نیز روشن می‌سازد: نقاب با تغییر γ واقعا جابه‌جا می‌شود و اطلاعات تعارض هم وجود دارد، اما انرژی تعارض مقیاس‌بندی‌شده در بخش بسیار باریکی از توزیع متمرکز است، پس یک ضریب خطی عملاً هیچ درایه‌ای را به‌طور محسوس تضعیف نمی‌کند. مسیر پیشنهادی برای کار آینده، نقابی مبتنی بر رتبه است و نه بر مقدار.

۳-۵ مشارکت‌های نهایی

با توجه به یافته‌های بالا، مشارکت‌های تاییدشده‌ی این پایان‌نامه در پنج محور زیر جمع‌بندی می‌شوند؛ این فهرست فقط مواردی را در بر می‌گیرد که نتایج تجربی یا تحلیل نظری از آن‌ها پشتیبانی کرده‌اند:

۱. یک سازوکار محافظت از وزن‌های مشترک حساس به نگهداری که در تنظیم مدل مشترک به مرجع جداسازی کامل می‌رسد و برتری خود را هم با رشد موقعیت درخواست و هم با رشد هم‌پوشانی اندازه‌گیری‌شده در بررسی تنگی حفظ می‌کند. جزء تاییدشده‌ی این سازوکار، رتبه‌بندی حساسیت با بودجه‌ی ثابت است.

۲. ارزیابی هم‌تراز با تحلیل جفتی و آزمون دقیق روی هشت بذر، همراه با دو آزمون مکمل برای هم‌پوشانی: آزمون موقعیت درخواست که سطوح آن با طراحی دنباله از پیش تعیین می‌شوند و فقط

نشانه‌ای تقریبی از هم‌پوشانی هستند، و بررسی تنکی که هم‌پوشانی اندازه‌گیری شده را بیش از ده برابر تغییر می‌دهد، اما ظرفیت را نیز هم‌زمان تغییر می‌دهد.

۳. بررسی جداگانه‌ی اجزای روش که جزء مؤثر روش اصلی را از دو جزء بدون بهبود مستقل جدا می‌کند و برای مسیر لایه‌ی تطبیق نتیجه‌ای منفی به دست می‌دهد.

۴. محاسبه‌ی مستقیم هزینه که تفاوت میان نسبت دامنه‌ی ترمیم و حافظه‌ی موردنیاز واقعی را نشان می‌دهد و مانع تفسیر نسبت اسمی به عنوان معیار کامل کارایی می‌شود.

۵. یک تحلیل نظری با دامنه‌ی صریحاً محدود: یک کران بالای جانشین برای افت زیرمرحله به همراه اثبات یکنوایی آن نسبت به شدت محافظت، و در کنارش تصریح اینکه این کران نه رابطه‌ای میان افت‌های واقعی برقرار می‌کند و نه به نقطه‌ی پایان درخواست تعمیم می‌یابد.

۴-۵ محدودیت‌ها

برای جلوگیری از نتیجه‌گیری فراتر از شواهد، محدودیت‌های روش، داده، توان آماری، حریم خصوصی و دامنه‌ی ارزیابی در ادامه بیان می‌شوند.

رابط و حالت. روش به شناسه‌ی وظیفه در استنتاج نیاز دارد و حالت افزایشی کلاس را پوشش نمی‌دهد. واحد حذف، یک وظیفه‌ی کامل است و حذف در سطح رکورد یا کلاس بررسی نشده است.

دامنه‌ی ادعای حذف. فقط نمونه‌های وظیفه‌ی هدف از حافظه‌ی بازپخش مدل حذف می‌شوند. داده‌های خام، نقاط واری، نسخه‌های پشتیبان و نسخه‌های بیرونی در دامنه‌ی ادعاها نیستند. هیچ نتیجه‌ای حذف دقیق، گواهی‌شده یا حذف در سطح ذخیره‌سازی را اثبات نمی‌کند. ارزیابی مرجع بازآموزی در بخش ۴-۱۱، با تغییر توافق میان ۰/۰۰ و ۰/۹۸ روی وظیفه‌ی هدف، هم‌ارزی با بازآموزی دقیق را تأیید نمی‌کند. این ارزیابی برای رد قطعی حذف توزیعی نیز کافی نیست؛ زیرا هر سطر فقط یک مدل فراموش‌کرده را با یک مرجع بازآموزی مقایسه می‌کند و پراکندگی طبیعی میان دو اجرای مستقل بازآموزی محاسبه نشده است.

توان آماری و چندگانگی. کف p قابل دستیابی برای هر آزمون جداگانه است (۰/۰۰۳۹۰۶ برای سطرهای بدون تساوی در CIFAR-100 و ۰/۰۰۷۸۱۲ برای دقت نهایی CIFAR-10)، پس مقادیر مشاهده‌شده روی کف نایستاده‌اند. شش آزمون با اصلاح Holm تصحیح شده‌اند و چهار مورد باقی می‌مانند؛ بیشترین افت

CIFAR-10 پس از اصلاح از دست می‌رود. تحلیل لنگر با هشت بذر انجام شده است؛ تحلیل‌های معیار تعارض، ViT، ماندگاری و عرض گلوگاه با دو بذر انجام شده‌اند و توصیفی‌اند. یک هشدار مشخص نیز باید ثبت شود: افزودن سه بذر به کنترل‌های مؤلفه‌ای، جدایی جمله‌ی لنگر را از میان برد؛ بنابراین بازه‌های نمونه‌ی کوچک در این حوزه شکننده‌اند.

ارزیابی حریم خصوصی و یک یافته‌ی نامطلوب. حمله‌ی آستانه‌ی زیان نتیجه‌ی نزدیک به $0/5$ می‌دهد؛ یعنی این آزمون با توان تشخیص پایین تفاوتی نیافته است. اما آماره‌ی تفکیک‌پذیری بدترین آستانه (بخش ۴-۱۱-۲) تصویر نگران‌کننده‌تری می‌دهد: S برای EPALL از صفر پیش از درخواست به میانگین حدود $0/10$ و بیشینه‌ی $0/55$ پس از درخواست می‌رسد، یعنی عملیات فراموشی نمونه‌های وظیفه‌ی هدف را تفکیک‌پذیرتر می‌کند. خط پایه‌ی PAL روی همان بذرها و همان روند اجرای حمله این افزایش را نشان نمی‌دهد ($0/0013$ و $0/0000$)، پس این اثر مخصوص لایه‌ی افزوده‌ی EPALL است. این یافته با دقت هدف نزدیک به سطح تصادفی در تضاد نیست، اما نشان می‌دهد سرکوب رفتاری با حذف اثر یکی نیست. تأکید می‌شود که S پیراسنجه حریم خصوصی تفاضلی نیست؛ ارزیابی رسمی و حمله‌های مبتنی بر مدل سایه [۱۱] هر دو انجام نشده‌اند و مقدار کوچک S برای هیچ روشی تضمین محسوب نمی‌شود.

ادعای سازوکاری باریک‌تر از توصیف روش. آنچه به‌طور تجربی تایید شده «رتبه‌بندی حساسیت نگه‌داری با بودجه‌ی ثابت» است. دو جزء دیگر سهم مستقل نشان ندادند، اما کنترل‌های موجود برای رد آن‌ها هم کافی نیستند: حالت آزمایشی بدون جریمه پشتیبان‌ها را نگه می‌دارد و حالت آزمایشی بدون اشتراک همچنان از نقاب ترمیم $M_f \cap M_r$ عبور می‌کند. بنابراین نتیجه‌ی محتاطانه این است که شواهد از رتبه‌بندی حساسیت پشتیبانی می‌کنند و درباره‌ی ضرورت سایر اجزا ساکت‌اند. این یک محدودیت واقعی و مهم در انتساب سازوکار است: روش کار می‌کند، اما نه به‌تمامی به دلیلی که در طراحی برای آن پیش‌بینی شده بود.

مسیر لایه‌ی تطبیق بی‌اثر است. با وجود طراحی و تحلیل نظری، نقاب نرم نتیجه‌ی نهایی را تغییر نمی‌دهد. این مسیر فقط یک گزینه‌ی اکتشافی و ارزیابی‌شده است و به‌عنوان راه‌حل اصلی ارائه نمی‌شود.

ارزیابی محدود ماندگاری. این ارزیابی با دو بذر انجام شده است. پس از نخستین حذف فقط یک یا دو درخواست آموزشی وجود دارد و هر وظیفه‌ی حذف‌شده حداکثر چند درخواست دنبال می‌شود. این وضعیت به همه‌ی بذرها تعمیم‌پذیر نیست و در دست‌کم یک بذر، پس از نخستین حذف هیچ آموزشی انجام نمی‌شود. اگرچه بخش ۴-۱۱-۵ اثر یادگیری تازه را از اثر حذف‌های بعدی جدا می‌کند، این بازه‌ی

کوتاه برای رد بازگشت پس از یادگیری طولانی مدت کافی نیست.

هزینه‌ها. زمان درخواست فقط روی یک سخت‌افزار مشخص اندازه‌گیری شده و برای سخت‌افزارهای متفاوت مقیاس‌بندی نشده است. EPALL از PALL اصلی کندتر است و تنظیم ابرپیراسنجه‌های لایه‌ی تطبیق نیز خودکار نیست. روی TinyImageNet با بیست وظیفه، بیشترین افت هر دو نسخه‌ی کامل زیاد باقی می‌ماند که نشان‌دهنده‌ی محدودیت ظرفیت است و فقط به هم‌پوشانی مربوط نمی‌شود.

۵-۵ کارهای آینده

ساده‌سازی روش بر پایه‌ی یافته‌ی کنترل‌ها. دو یافته‌ی منفی کنترل‌ها یک مسیر تحقیقی مستقیم پیشنهاد می‌دهند: آیا می‌توان هم عملیات اشتراک نقاب‌ها و هم جمله‌ی لنگر l_2 را کنار گذاشت و به رتبه‌بندی حساسیت با بودجه‌ی ثابت — مثلاً به صورت صفرکردن ساده‌ی شیب روی مجموعه‌ی انتخاب‌شده — بسنده کرد؟ چنین نسخه‌ای هم ارزان‌تر است و هم یک ابرپیراسنجه (۸) کمتر دارد. آزمون این فرضیه روی پیکربندی‌های متنوع‌تر — سطوح تنکی مختلف، تعداد وظیفه‌ی بیشتر، و دنباله‌های با ترتیب متفاوت — می‌تواند روش را ساده‌تر کند یا شرایطی را پیدا کند که در آن آن دو جزء واقعا لازم می‌شوند.

لنگر مستقل از داده‌ی واقعی. مقایسه‌ی بخش ۴-۱۲-۱ با هشت بذر نشان داد که جایگزینی θ^{old} با θ^{reinit} ایراد مفهومی را برطرف نمی‌کند و در عمل هم بهبودی نمی‌آورد. مسیر درست، حذف همه‌ی وابستگی‌های به داده‌ی قدیمی از مسیر درخواست است و نه فقط لنگر: تا وقتی شاخه‌های بازنشانی ارثی به پشتیبان‌های تنک تکیه دارند، هر لنگر مستقل از داده تنها یکی از دو مسیر نشت را می‌بندد. طراحی نسخه‌ای که هر دو مسیر را ببندد، و سنجش هزینه‌ی نگه‌داری آن، کار آینده است.

معیارهای جهت‌دار و مقایسه‌ی مرجع. دو کمبود اندازه‌گیری باقی مانده است. نخست، برای پشتیبانی از ادعای «تعارض» باید کسینوس زاویه‌ی g_f و g_r ، ضرب داخلی آن‌ها و درصد وزن‌های دارای علامت مخالف گزارش شوند. دوم، ارزیابی مرجع بازآموزی باید با مقایسه‌ی دو اجرای مستقل بازآموزی تکمیل شود تا سهم نوسان تصادفی آموزش در تغییر توافق مشخص شود. هر دو تحلیل با هزینه‌ی محاسباتی اندک قابل انجام‌اند.

یک آزمایش هم‌پوشانی ظرفیت‌همتراز. بررسی تنکی بخش ۴-۵ هویت وظیفه‌ی هدف و ترتیب درخواست‌ها را ثابت نگه می‌دارد و دامنه‌ی گسترده‌ای در هم‌پوشانی ساختاری ایجاد می‌کند، اما همان

عامل آزمایشی ظرفیت در دسترس هر وظیفه را هم تغییر می‌دهد. گام بعدی باید هم‌پوشانی را با ظرفیت ثابت دستکاری کند — برای نمونه با افراز یا اتصال نقاب‌های ظرفیت‌همتراز — و برهم‌کنش $WorstDrop \sim Method \times MeasuredOverlap$ را در سطح بذریازماید. تنها چنین طرحی می‌تواند اثر هم‌پوشانی را از اثر ظرفیت جدا کند.

ارزیابی حریم خصوصی با توان بالاتر. جایگزینی حمله‌ی آستانه‌ی زیان با حمله‌های مبتنی بر مدل سایه و افزودن ارزیابی رسمی، ضروری‌ترین گام بعدی است. تنها با چنین ابزاری می‌توان از ادعای «سرکوب رفتاری» به ادعایی درباره‌ی اطلاعات باقی‌مانده حرکت کرد.

بودجه‌ی محافظت تطبیقی. نسبت ρ و ضریب λ در این کار ثابت‌اند. یک نسخه‌ی تطبیقی که بودجه را بر پایه‌ی هم‌پوشانی اندازه‌گیری‌شده‌ی هر درخواست تعیین کند، از نظر مفهومی جذاب است و در پیاده‌سازی نیز به‌صورت یک گزینه موجود است، اما ارزیابی هم‌تراز آن انجام نشده و می‌تواند موضوع کار بعدی باشد.

ماندگاری زیر یادگیری تازه. افزودن درخواست‌های آموزشی پس از حذف به دنباله‌ها، سنجش بازگشت پس از یادگیری را ممکن می‌کند. این پرسش برای سامانه‌های واقعی که پس از حذف به کار خود ادامه می‌دهند، عملی‌ترین پرسش باقی‌مانده است.

حذف زیر-وظیفه‌ای. گسترش واحد حذف از یک وظیفه‌ی کامل به یک کلاس یا زیرمجموعه‌ای از نمونه‌ها، هم مسئله‌ی جدیدی در تعریف نقاب ایجاد می‌کند و هم به حالت‌های واقعی حق فراموش شدن نزدیک‌تر است.

مقیاس و دامنه. ارزیابی روی معماری‌های بزرگ‌تر، مدل‌های چندحالتی و داده‌های واقعی با مرزهای وظیفه‌ی نامشخص، آزمون واقعی تعمیم‌پذیری این سازوکار است.

۵-۶ سخن پایانی

پیام اصلی این پایان‌نامه آن است که آسیب جانبی فراموشی در یک مدل مشترک ساختاریافته و با شناخت ساختار مهارشدنی است. در عین حال، طراحی معقول و تحلیل درست اثرگذاری تجربی را تضمین نمی‌کنند: مسیر لایه‌ی تطبیق با وجود سازوکار منطقی، گزاره‌ی نظری درست و شرایط اندازه‌گیری مناسب، در نقطه‌ی

پایان بی‌اثر بود. این واقعیت تنها با کنترل‌هایی آشکار شد که برای رد فرضیه طراحی شده بودند. گزارش این نتیجه‌ی منفی، در کنار نتیجه‌ی مثبت EPALL، بخشی از دستاورد این کار است.

مراجع

- [1] Y. LeCun, Y. Bengio, and G. Hinton. Deep learning. *Nature*, 521(7553):436–444, 2015.
- [2] I. Goodfellow, Y. Bengio, and A. Courville. *Deep Learning*. MIT Press, 2016.
- [3] S. Thrun. Lifelong learning algorithms. In S. Thrun and L. Pratt, editors, *Learning to Learn*, pages 181–209. Springer, Boston, MA, 1998.
- [4] G. I. Parisi, R. Kemker, J. L. Part, C. Kanan, and S. Wermter. Continual lifelong learning with neural networks: A review. *Neural Networks*, 113:54–71, 2019.
- [5] M. De Lange, R. Aljundi, M. Masana, S. Parisot, X. Jia, A. Leonardis, G. Slabaugh, and T. Tuytelaars. A continual learning survey: Defying forgetting in classification tasks. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(7):3366–3385, 2022.
- [6] M. McCloskey and N. J. Cohen. Catastrophic interference in connectionist networks: The sequential learning problem. In *Psychology of Learning and Motivation*, volume 24, pages 109–165. Academic Press, 1989.
- [7] J. Kirkpatrick, R. Pascanu, N. Rabinowitz, J. Veness, G. Desjardins, A. A. Rusu, K. Milan, J. Quan, T. Ramalho, A. Grabska-Barwinska, D. Hassabis, C. Clopath, D. Kumaran, and R. Hadsell. Overcoming catastrophic forgetting in neural networks. *Proceedings of the National Academy of Sciences*, 114(13):3521–3526, 2017.
- [8] European Union. Regulation (EU) 2016/679 of the European Parliament and of the Council (General Data Protection Regulation). Official Journal of the European Union, 2016.
- [9] California State Legislature. California civil code title 1.81.5, the California Consumer Privacy Act of 2018 (CCPA), 2018.

- [10] R. Shokri, M. Stronati, C. Song, and V. Shmatikov. Membership inference attacks against machine learning models. In *2017 IEEE Symposium on Security and Privacy (SP)*, pages 3–18. IEEE, 2017.
- [11] N. Carlini, S. Chien, M. Nasr, S. Song, A. Terzis, and F. Tramèr. Membership inference attacks from first principles. In *2022 IEEE Symposium on Security and Privacy (SP)*, pages 1897–1914. IEEE, 2022.
- [12] Y. Cao and J. Yang. Towards making systems forget with machine unlearning. In *2015 IEEE Symposium on Security and Privacy*, pages 463–480. IEEE, 2015.
- [13] L. Bourtole, V. Chandrasekaran, C. A. Choquette-Choo, H. Jia, A. Travers, B. Zhang, D. Lie, and N. Papernot. Machine unlearning. In *2021 IEEE Symposium on Security and Privacy (SP)*, pages 141–159. IEEE, 2021.
- [14] A. Golatkar, A. Achille, and S. Soatto. Forgetting outside the box: Scrubbing deep networks of information accessible from input-output observations. In *European Conference on Computer Vision*, pages 383–398. Springer, 2020.
- [15] O. Özdenizci, E. Rueckert, and R. Legenstein. Privacy-aware lifelong learning. In *International Conference on Learning Representations (ICLR)*, 2025.
- [16] B. Liu, Q. Liu, and P. Stone. Continual learning and private unlearning. In *Proceedings of the 1st Conference on Lifelong Learning Agents (CoLLAs)*, pages 243–254. PMLR, 2022.
- [17] C. Guo, T. Goldstein, A. Hannun, and L. van der Maaten. Certified data removal from machine learning models. In *Proceedings of the 37th International Conference on Machine Learning*, pages 3832–3842. PMLR, 2020.
- [18] S. Neel, A. Roth, and S. Sharifi-Malvajerdi. Descent-to-delete: Gradient-based methods for machine unlearning. In *Proceedings of the 32nd International Conference on Algorithmic Learning Theory*, pages 931–962. PMLR, 2021.
- [19] A. Sekhari, J. Acharya, G. Kamath, and A. T. Suresh. Remember what you want to forget: Algorithms for machine unlearning. In *Advances in Neural Information Processing Systems*, volume 34, 2021.
- [20] T. Steinke, M. Nasr, and M. Jagielski. Privacy auditing with one (1) training run. In *Advances in Neural Information Processing Systems*, volume 36, pages 49268–49280, 2023.

- [21] G. M. van de Ven, T. Tuytelaars, and A. S. Tolias. Three types of incremental learning. *Nature Machine Intelligence*, 4:1185–1197, 2022.
- [22] L. Wang, X. Zhang, H. Su, and J. Zhu. A comprehensive survey of continual learning: Theory, method and application, 2023.
- [23] T. T. Nguyen, T. T. Huynh, Z. Ren, P. L. Nguyen, A. W.-C. Liew, H. Yin, and Q. V. H. Nguyen. A survey of machine unlearning, 2022.
- [24] H. Xu, T. Zhu, L. Zhang, W. Zhou, and P. S. Yu. Machine unlearning: A survey, 2023.
- [25] H. Robbins and S. Monro. A stochastic approximation method. *The Annals of Mathematical Statistics*, 22(3):400–407, 1951.
- [26] F. Zenke, B. Poole, and S. Ganguli. Continual learning through synaptic intelligence. In *Proceedings of the 34th International Conference on Machine Learning*, pages 3987–3995. PMLR, 2017.
- [27] R. Aljundi, F. Babiloni, M. Elhoseiny, M. Rohrbach, and T. Tuytelaars. Memory aware synapses: Learning what (not) to forget. In *European Conference on Computer Vision*, pages 139–154, 2018.
- [28] P. W. Koh and P. Liang. Understanding black-box predictions via influence functions. In *International Conference on Machine Learning (ICML)*, pages 1885–1894, 2017.
- [29] K. He, X. Zhang, S. Ren, and J. Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016.
- [30] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations (ICLR)*, 2021.
- [31] K. He, X. Zhang, S. Ren, and J. Sun. Delving deep into rectifiers: Surpassing human-level performance on ImageNet classification. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pages 1026–1034, 2015.
- [32] Z. Li and D. Hoiem. Learning without forgetting. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 40(12):2935–2947, 2017.

- [33] G. Hinton, O. Vinyals, and J. Dean. Distilling the knowledge in a neural network. In *NIPS Deep Learning and Representation Learning Workshop*, 2015.
- [34] S.-A. Rebuffi, A. Kolesnikov, G. Sperl, and C. H. Lampert. iCaRL: Incremental classifier and representation learning. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2001–2010, 2017.
- [35] P. Buzzega, M. Boschini, A. Porrello, D. Abati, and S. Calderara. Dark experience for general continual learning: A strong, simple baseline. In *Advances in Neural Information Processing Systems*, volume 33, pages 15920–15930, 2020.
- [36] H. Shin, J. K. Lee, J. Kim, and J. Kim. Continual learning with deep generative replay. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [37] D. Lopez-Paz and M. Ranzato. Gradient episodic memory for continual learning. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [38] A. Chaudhry, M. Ranzato, M. Rohrbach, and M. Elhoseiny. Efficient lifelong learning with A-GEM. In *International Conference on Learning Representations (ICLR)*, 2019.
- [39] A. Mallya and S. Lazebnik. PackNet: Adding multiple tasks to a single network by iterative pruning. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 7765–7773, 2018.
- [40] J. Serra, D. Surís, M. Miron, and A. Karatzoglou. Overcoming catastrophic forgetting with hard attention to the task. In *Proceedings of the 35th International Conference on Machine Learning*, pages 4548–4557. PMLR, 2018.
- [41] M. Wortsman, V. Ramanujan, R. Liu, A. Kembhavi, M. Rastegari, J. Yosinski, and A. Farhadi. Supermasks in superposition. In *Advances in Neural Information Processing Systems*, volume 33, 2020.
- [42] A. A. Rusu, N. C. Rabinowitz, G. Desjardins, H. Soyer, J. Kirkpatrick, K. Kavukcuoglu, R. Pascanu, and R. Hadsell. Progressive neural networks, 2016.
- [43] J. Frankle and M. Carbin. The lottery ticket hypothesis: Finding sparse, trainable neural networks. In *International Conference on Learning Representations (ICLR)*, 2019.
- [44] V. Ramanujan, M. Wortsman, A. Kembhavi, A. Farhadi, and M. Rastegari. What’s hidden in a randomly weighted neural network? In *Proceedings of the IEEE/CVF*

- Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 11893–11902, 2020.
- [45] H. Kang, R. J. L. Mina, S. R. H. Madjid, J. Yoon, M. Hasegawa-Johnson, S. J. Hwang, and C. D. Yoo. Forget-free continual learning with winning subnetworks. In *Proceedings of the 39th International Conference on Machine Learning*, pages 10734–10750. PMLR, 2022.
 - [46] L. Graves, V. Nagisetty, and V. Ganesh. Amnesiac machine learning. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 35, 2021.
 - [47] A. Ginart, M. Y. Guan, G. Valiant, and J. Zou. Making ai forget you: Data deletion in machine learning. In *Advances in Neural Information Processing Systems*, volume 32, 2019.
 - [48] Z. Izzo, M. A. Smart, K. Chaudhuri, and J. Zou. Approximate data deletion from machine learning models. In *International Conference on Artificial Intelligence and Statistics*, pages 2008–2016. PMLR, 2021.
 - [49] M. Chen, W. Gao, G. Liu, K. Peng, and C. Wang. Boundary unlearning: Rapid forgetting of deep networks via shifting the decision boundary. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 7766–7775, 2023.
 - [50] V. S. Chundawat, A. K. Tarun, M. Mandal, and M. Kankanhalli. Can bad teaching induce forgetting? unlearning in deep networks using an incompetent teacher. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 37, pages 7214–7222, 2023.
 - [51] C. Fan, J. Liu, Y. Zhang, E. Wong, D. Wei, and S. Liu. SalUn: Empowering machine unlearning via gradient-based weight saliency in both image classification and generation. In *International Conference on Learning Representations (ICLR)*, 2024.
 - [52] J. Foster, S. Schoepf, and A. Brintrup. Fast machine unlearning without retraining through selective synaptic dampening. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 38, pages 12043–12051, 2024.
 - [53] C. Dwork and A. Roth. *The Algorithmic Foundations of Differential Privacy*. Now Publishers, 2014.
 - [54] Y. Qu, X. Yuan, M. Ding, W. Ni, T. Rakotoarivelo, and D. Smith. Learn to unlearn: A survey on machine unlearning, 2023.

- [55] T. Shibata, G. Irie, D. Ikami, and Y. Mitsuzumi. Learning with selective forgetting. In Z.-H. Zhou, editor, *Proceedings of the Thirtieth International Joint Conference on Artificial Intelligence, IJCAI-21*, pages 989–996. International Joint Conferences on Artificial Intelligence Organization, 8 2021. Main Track.
- [56] L. Shan, W. Zhou, W. Li, and X. Ding. Lifelong learning and selective forgetting via contrastive strategy, 2024.
- [57] S. Adhikari, V. Kumaravelu, and P. K. Srijith. An unlearning framework for continual learning, 2025.
- [58] S. Lin, J. Dong, R. Chen, X. Zhang, L. Xu, and X. Chen. CATA: Continual machine unlearning via conflict-averse task arithmetic, 2026.
- [59] R. Chatterjee, V. Chundawat, A. Tarun, A. Mali, and M. Mandal. A unified framework for continual learning and unlearning, 2024.
- [60] N. Houlsby, A. Giurghi, S. Jastrzebski, B. Morrone, Q. de Laroussilhe, A. Gesmundo, M. Attariyan, and S. Gelly. Parameter-efficient transfer learning for NLP. In *Proceedings of the 36th International Conference on Machine Learning*, pages 2790–2799. PMLR, 2019.
- [61] V. Nair and G. E. Hinton. Rectified linear units improve restricted Boltzmann machines. In *Proceedings of the 27th International Conference on Machine Learning (ICML)*, pages 807–814, 2010.
- [62] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen. LoRA: Low-rank adaptation of large language models. In *International Conference on Learning Representations (ICLR)*, 2022.
- [63] S.-A. Rebuffi, H. Bilen, and A. Vedaldi. Learning multiple visual domains with residual adapters. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [64] J. Pfeiffer, A. Rücklé, C. Poth, A. Kamath, I. Vulić, S. Ruder, K. Cho, and I. Gurevych. Adapterhub: A framework for adapting transformers. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pages 46–54, 2020.
- [65] R. K. Mahabadi, J. Henderson, and S. Ruder. Compacter: Efficient low-rank hypercomplex adapter layers. In *Advances in Neural Information Processing Systems*, volume 34, pages 1022–1035, 2021.

- [66] A. Rüclé, G. Geigle, M. Glöckner, T. Beck, J. Pfeiffer, N. Reimers, and I. Gurevych. Adapterdrop: On the efficiency of adapters in transformers. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pages 7930–7946, 2021.
- [67] X. L. Li and P. Liang. Prefix-tuning: Optimizing continuous prompts for generation. In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics*, pages 4582–4597, 2021.
- [68] B. Lester, R. Al-Rfou, and N. Constant. The power of scale for parameter-efficient prompt tuning. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pages 3045–3059, 2021.
- [69] J. Rachapudi, R. Vatsi, P. Hambarde, and A. Shukla. BID-LoRA: A parameter-efficient framework for continual learning and unlearning, 2026.
- [70] S. Yeom, I. Giacomelli, M. Fredrikson, and S. Jha. Privacy risk in machine learning: Analyzing the connection to overfitting. In *2018 IEEE 31st Computer Security Foundations Symposium (CSF)*, pages 268–282. IEEE, 2018.
- [71] M. Nasr, R. Shokri, and A. Houmansadr. Comprehensive privacy analysis of deep learning: Passive and active white-box inference attacks against centralized and federated learning. In *2019 IEEE Symposium on Security and Privacy*, pages 739–753. IEEE, 2019.
- [72] M. Fredrikson, S. Jha, and T. Ristenpart. Model inversion attacks that exploit confidence information and basic countermeasures. In *Proceedings of the 22nd ACM SIGSAC Conference on Computer and Communications Security*, pages 1322–1333, 2015.
- [73] N. Carlini, F. Tramèr, E. Wallace, M. Jagielski, A. Herbert-Voss, K. Lee, A. Roberts, T. Brown, D. Song, U. Erlingsson, A. Oprea, and C. Raffel. Extracting training data from large language models. In *30th USENIX Security Symposium*, pages 2633–2650, 2021.
- [74] A. Krizhevsky and G. Hinton. Learning multiple layers of features from tiny images. Technical report, University of Toronto, 2009.
- [75] Y. Le and X. Yang. Tiny ImageNet visual recognition challenge. Technical report, CS 231N, Stanford University, 2015.

- [76] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei. Imagenet: A large-scale hierarchical image database. In *2009 IEEE Conference on Computer Vision and Pattern Recognition*, pages 248–255. IEEE, 2009.

واژه‌نامه

Reset بازنشانی

Bootstrap Interval بازه‌ی بازنمونه‌گیری

Backbone بدنه‌ی اصلی

WorstDrop بیشترین افت

Gradient Magnitude بزرگی شیب

پ

Module پیمانه

Fisher-based Scrubbing ... پاک‌سازی مبتنی بر فیشر

Sparsity تنگی

Shared Support پشتیبان مشترک

ت

Loss Function تابع زیان

Influence Function تابع نفوذ

Knowledge Distillation تقطیر دانش

Prefix-Tuning تنظیم پیشوند

Prompt-Tuning تنظیم راهنمای ورودی

Regularization منظم‌سازی

Gradient Projection تصویر شیب

Uniform Distribution توزیع یکنواخت

ا

End-to-End آغاز تا پایان

Benchmark آزمون ارزیابی

Formal Privacy Audit ارزیابی رسمی حریم خصوصی

Logits امتیاز خام

Residual Connection اتصال باقی‌مانده

Low-Rank Adaptation انطباق کم‌رتبه

Critical Interference Energy .. انرژی تداخل بحرانی

Gradient-Conflict Energy ... انرژی تعارض شیب‌ها

Learnable Score امتیاز قابل یادگیری

Parameter Importance اهمیت پیراسنجه

ب

Entropy بی‌نظمی

Cross-Entropy بی‌نظمی متقاطع

Trade-off موازنه

Batch Normalization هنجارسازی دسته‌ای

Experience Replay بازپخش تجربه

Dark Experience Replay ... بازپخش تجربه‌ی تاریک

Generative Replay بازپخش مولد

Winning Subnetwork زیرشبکه‌ی برنده

ح

Resident State حافظه‌ی موردنیاز در زمان اجرا

Replay Buffer حافظه‌ی بازپخش

Episodic Memory حافظه‌ی رویدادی

Gradient Episodic Memory حافظه‌ی مبتنی بر شیب رویدادی

Right to be Forgotten حق فراموش شدن

Certified Data Removal ... حذف داده‌ی گواهی شده

Membership Inference Attack حمله‌ی استنتاج عضویت

Model Inversion Attack ... حمله‌ی وارون‌سازی مدل

Privacy حریم خصوصی

Differential Privacy حریم خصوصی تفاضلی

د

Hard-Protected دارای حفاظت سخت

Coordinate درایه‌ی وزن

Epoch دوره

Forgetting Request درخواست فراموشی

Request Schedule دنباله‌ی درخواست

ر

Ranking رتبه‌بندی

Risk مخاطره

Empirical Risk مخاطره‌ی تجربی

ز

Sparse Subnetwork زیرشبکه‌ی تنک

س

Adapter لایه‌ی تطبیق

Bottleneck Adapter لایه‌ی تطبیق گلوگاهی

Shared Adapter لایه‌ی تطبیق مشترک

Task-Specific Adapter لایه‌ی تطبیق مخصوص وظیفه

Residual Adapter لایه‌ی تطبیق باقی‌مانده

Memory Aware Synapses سیناپس‌های آگاه از حافظه

ش

Residual Network شبکه‌ی باقی‌مانده

Convolutional Network شبکه‌ی هم‌پیچشی

Progressive Network شبکه‌ی پیش‌رونده

ص

Gradient Ascent صعود مبتنی بر شیب

Unconstrained Gradient Ascent صعود مبتنی بر شیب بی‌قید

ض

Soft-Scaling Multiplier ضرب‌گر نقاب نرم

ف

Selective Forgetting فراموشی انتخابی

Catastrophic Forgetting فراموشی فاجعه‌بار

Approximate Unlearning فراموشی تقریبی

Exact Unlearning فراموشی دقیق

Boundary Unlearning فراموشی مرزی

Shared Region ناحیه‌ی اشتراک	Lottery Ticket فرضیه‌ی بلیت بخت‌آزمایی
Protection Ratio نسبت محافظت	Hypothesis
Updated Parameter Ratio نسبت پیراسنجه به‌روزشده	گ
ه	Stochastic Gradient Descent . شیب‌کاهشی تصادفی
Parameter Overlap هم‌پوشانی پیراسنجه‌ها	ل
Critical Overlap هم‌پوشانی بحرانی	لنگر Anchor
Structural Overlap هم‌پوشانی ساختاری	م
Synaptic Intelligence هوشمندی سیناپسی	مبدل بینایی Vision Transformer
و	Fisher Information Matrix . ماتریس اطلاعات فیشر
Calibration واسنجی	مرجع بازآموزی Retraining Reference
Retained Task وظیفه‌ی نگه‌داری‌شده	مدل سایه Shadow Model
ی	مقدارگذاری کایمینگ Kaiming Initialization
Continual Learning یادگیری پیوسته	مزیت عضویت Membership Advantage
Lifelong Learning یادگیری مادام‌العمر	میراکردن انتخابی سیناپسی Selective Synaptic
Privacy-Aware . یادگیری مادام‌العمر حریم خصوصی‌آگاه	Dampening
Lifelong Learning	ثابت Frozen
Parameter-Efficient یادگیری کم‌پیراسنجه	ن
Fine-Tuning	نقاب Mask
Task-Incremental Learning . یادگیری افزایشی وظیفه	نقاب ترکیبی Combined Mask
Domain-Incremental Learning . یادگیری افزایشی دامنه	نقاب دودویی Binary Mask
Class-Incremental Learning . یادگیری افزایشی کلاس	نقاب نرم Soft Mask
Machine Unlearning یادگیری‌زدایی ماشینی	نقاب توجه سخت Hard Attention to the Task
Saliency Unlearning یادگیری‌زدایی برجستگی	

پیوست

کد روش EPALL، تنظیمات آزمایش‌ها و همه‌ی برنامه‌های لازم برای بازتولید نتایج در مخزن زیر در دسترس است؛ این مخزن نسخه‌ی اجرایی روش اصلی پایان‌نامه را نگه می‌دارد:

<https://github.com/Fatemerjn/EPALL>

روش اصلی در متن این پایان‌نامه EPALL نامیده می‌شود و در کد و برجسب‌های آزمایش با شناسه‌ی `pall_modified` ثبت شده است؛ این دو نام به یک الگوریتم اشاره می‌کنند. پیکربندی کامل آزمایش‌ها در جدول ۵-۱ آمده است.

جدول ۵-۱: پیکربندی کامل آزمایش‌ها. مقادیر میان روش‌ها مشترک‌اند مگر آنکه سطری مخصوص یک روش آن‌ها را بازنویسی کند.

گروه	تنظیم	مقدار
بهینه‌سازی	بهینه‌ساز	SGD، تکانه‌ی 0.9
	نرخ یادگیری	10^{-2} (LoRA) روی Split-CIFAR-100
		10^{-3}
	تنظیم وزن	5×10^{-4}
	اندازه‌ی دسته	32
آزمون‌های ارزیابی	دوره هر وظیفه	20 (استاندارد)، 3 (هم‌پوشانی سنگین و پیش‌آموزش دیده)
	CIFAR-10	5 وظیفه $2 \times$ کلاس، سطح تصادفی 0.5
	CIFAR-100 استاندارد	10 وظیفه $10 \times$ کلاس مجزای تصادفی، سطح تصادفی 0.1

ادامه در صفحه‌ی بعد

گروه	تنظیم	مقدار
معماری	CIFAR-100 هم‌پوشانی	10 وظیفه $5 \times$ کلاس، سطح تصادفی 0.2
	TinyImageNet	20 وظیفه $10 \times$ کلاس، سطح تصادفی 0.1
	CIFAR-10	ResNet-18 نسخه‌های /
	TinyImageNet	/
بازپخش	پیش‌آموزش دیده	ResNet-34 نسخه‌های
	CIFAR-100 اصلی	ViT-T/8
	آزمون میان‌معماری	
	بودجه‌ی حافظه	500 نمونه
زیرشبکه	تخصیص	از پیش افرازشده؛ بدون بازتوزیع پس از حذف
	تنکی / C10	0.8
	تنکی C100	0.9
	نسبت محافظت ρ	0.2
EPALL	ضریب لنگر λ	1.0
	معیار اهمیت	بزرگی شیب (پیش‌فرض)؛ انرژی تعارض (مطالعه)
	هدف لنگر	old (پیش‌فرض و همه‌ی اجراهای گزارش‌شده)؛ reinit فقط در مطالعه‌ی بخش ۴-۱۲-۱
PAL-Adapter	گلگاه وظیفه / مشترک	16 / 16
	نسبت فراموشی مشترک α_f	0.3
	نسبت محافظت مشترک α_p	0.2
	شدت نقاب نرم p	$ S_{\text{crit}} / S_{\text{forget}} $
LoRA	گام فراموشی / ترمیم	50 / 10
	رتبه α	16 / 8
	EWC	$100 : \lambda$
	LwF	$2.0 : T$ ؛ $1.0 : \alpha$ دمای تقطیر

گروه	تنظیم	مقدار
	DER++	α (امتیاز خام): 0.5؛ β (بی‌نظمی متقاطع): 1.0
	ER	فقط بازپخش؛ بدون جمله‌ی اضافی
	SSD	آستانه‌ی نسبت فیشر 1.0، شدت میرایی 1.0
	SalUn	نسبت نقاب 0.1، هدف یکنواخت، 50 گام فراموشی
دنباله‌ها	درخواست فراموشی هر اجرا	3
	ساختار	هر وظیفه حداکثر یک‌بار آموزش؛ بدون معرفی دوباره
	الگوی درخواست	CIFAR-10: T T T T F T F F CIFAR-100: T×7 F T T F T F

محیط اجرا. همه‌ی اجراهای گزارش‌شده روی یک NVIDIA RTX 3070 Ti با ۸ گیگابایت حافظه‌ی گرافیکی، دو پردازنده‌ی Xeon E5-2620 v4، ۳۱ گیگابایت حافظه‌ی اصلی، Ubuntu 24.04.4، Python 3.12.3 و PyTorch 2.5.1 انجام شده‌اند. برای بازتولید یک مجموعه نتیجه، گروه متناظر از برنامه‌ی tools/run_server_experiments.sh اجرا می‌شود؛ برای نمونه bash tools/run_server_experiments.sh g6_standard --dry-run. هر گروه پیش از اجرا با گزینه --dry-run فرمان‌های دقیق خود را بدون اجرا چاپ می‌کند. هر مجموعه نتیجه زیر یک برچسب آزمایش مستقل ثبت می‌شود و نگاشت گروه‌ها، برچسب‌ها و تنظیمات در README مخزن آمده است. برچسب محلی thesis-final نسخه‌ی کنونی پایان‌نامه را نشان نمی‌دهد؛ بنابراین تا زمان تثبیت نسخه‌ی تحویلی، هیچ ادعای بازتولیدپذیری به آن برچسب وابسته نیست.

دنباله‌های درخواست. دنباله‌ها از پیش تولید و در پوشه‌ی schedules/ ذخیره شده‌اند تا همه‌ی روش‌ها در هر بذر دقیقاً یک دنباله را ببینند. الگو به بذر وابسته است: در بذر *، دنباله‌های CIFAR-10 و CIFAR-100 به ترتیب T T T T F T F F و T×7 F T T F T F هستند؛ در مقابل، دنباله‌ی CIFAR-100 بذر ۵ به صورت T×10 F F F است و پس از نخستین حذف آموزشی ندارد. درهم‌سازی SHA-256 فایل‌های بذر * (شانزده نویسه‌ی نخست) چنین است:

904b860aa0d75436:cifar10_t5_f3_fixed_seed0.json

17ae55e7bf4d629f :cifar100_t10_f3_seed0.json

Abstract

Continual learning systems may need to unlearn specific information while retaining other tasks. In task-incremental selective forgetting, *parameter overlap* makes this difficult: resetting or repairing weights for one task can damage the others. The Privacy-Aware Lifelong Learning (PALL) framework modularizes task knowledge with stored subnetworks, but at request time it does not distinguish shared coordinates by retained-task sensitivity.

This thesis introduces Enhanced PALL (EPALL), which identifies the shared support between the target subnetwork and the union of the active subnetworks, ranks those coordinates by retained-task gradient magnitude, and anchors the high-sensitivity subset with an ℓ_2 penalty during the repair phase. In addition, an exploratory parameter-efficient pathway, PALL-Adapter, is designed and audited through matched component controls.

On Split-CIFAR benchmarks, an eleven-method eight-seed comparison shows that EPALL drives forgotten-task accuracy to the chance level (0.4863 on CIFAR-10 and 0.0959 on CIFAR-100) while matching the full-isolation CLPU reference in retained accuracy to within seed spread. Against the original PALL algorithm, the paired accuracy difference is positive and excludes zero on both datasets (exact one-sided Wilcoxon raw $p = 0.0078$; Holm-adjusted $p = 0.0469$), and survives Holm correction across the six simultaneous tests; WorstDrop on CIFAR-100 falls from 0.0222 to 0.0056, but its CIFAR-10 counterpart does not survive the correction. A 300-run request-position benchmark over five pre-specified grades — a proxy for expected overlap rather than a direct control of it — shows that PALL’s WorstDrop grows with the grade while EPALL stays comparatively flat. A complementary sparsity sweep, which moves measured structural overlap by more than tenfold at a fixed target task, finds a positive and significant rank correlation between that overlap and the benefit of protection, though the same knob also changes capacity. Resident-state accounting shows CLPU using 1.6–2.2 $\times$ as much accounted state.

Matched component controls narrow the mechanism claim, and these limits are reported explicitly: what the evidence supports is retention-sensitivity ranking under a fixed budget, whereas the explicit mask-intersection filter is redundant and the anchor term shows no measurable independent contribution. For PALL-Adapter, the controls attribute task suppression primarily to target-path reset rather than to the overlap-aware soft mask. In the membership-inference audit, the post-request distinguishability increase appears for EPALL but not for the original PALL baseline. No result establishes exact, certified, or storage-level removal, and all claims are empirical.

Keywords: Continual Learning, Machine Unlearning, Selective Forgetting, Parameter

Overlap, Protected Subnetworks, Parameter-Efficient Fine-Tuning



Sharif University of Technology
Department of Computer Engineering

M.Sc. Thesis

Forgetting Management in Continual Learning Using Deep Learning Methods

By:

Fatemeh Raeejian

Supervisor:

Prof. Hamid Beigy

September 2026